

Universidade de Aveiro

*Inteligência Artificial (LEI, LECI)*

Tópicos de Inteligência Artificial

Ano lectivo 2021/2022

Regente: Luís Seabra Lopes

# Definição de “Inteligência” - I

- Segundo [www.dictionary.com](http://www.dictionary.com), “inteligência” é:
  - Capacidade de adquirir e aplicar conhecimento
  - Capacidade de pensar e raciocinar
  - O conjunto de capacidades superiores da mente.

# Definição de “Inteligência” - II

- O estudo da inteligência envolve [Albus,1995]:
  - Como adquirir, representar e armazenar conhecimento
  - Como gerar comportamento inteligente
  - Como surgem e são utilizadas as motivações, emoções e prioridades
  - Como as percepções (sinais) dão origem a entidades simbólicas
  - Como raciocinar sobre o passado
  - Como planear acções no futuro
  - Como surgem fenómenos como a ilusão, crença, esperança, amor, etc.

# Definição de “Inteligência Artificial”

- “Inteligência Artificial” é a disciplina que estuda as teorias e técnicas necessárias ao desenvolvimento de “artefactos” inteligentes. [Nilsson, 1998]
- Direcções seguidas [Russell & Norvig, 1995]:

Pensar como o ser humano	Pensar racionalmente
Agir como o ser humano	Agir racionalmente

# História até à “Inteligência Artificial”

- Século IV a.C. – Aristóteles estabelece os fundamentos da lógica e do pensamento puramente racional.
- Séculos XVI-XVII – Bacon e Locke estabelecem os fundamentos do “empirismo”: “Nada está na compreensão que não tenha estado primeiro nos sentidos”.
- Séculos XIX-XX – Duas correntes na psicologia: “comportamentalismo” e “cognitivismo”.
- 1940 – início da era dos computadores
- 1943 – McCulloch & Pitts propõem um modelo de computação vagamente inspirado no cérebro humano: redes de unidades chamadas “neurónios” podiam implementar qualquer função.
- 1951 – primeiro programa que joga xadrez
- 1956 – a expressão “Inteligência Artificial” foi usada pela primeira vez.

# História da “Inteligência Artificial” - I

- 1958 – McCarthy usa lógica de primeira ordem para representar conhecimento numa espécie de “sistema pericial”.
- 1959 – *GPS*: *General Problem Solver* – aqui surge um assunto hoje clássico – pesquisa para resolução de problemas
- 1962 – Rosenblatt propõe o uso do “perceptrão” (rede de neurónios) para aprendizagem e reconhecimento de padrões
- 1966 – *CLS*: *Concept Learning System* – primeiro sistema de aprendizagem simbólica

# História da “Inteligência Artificial” - II

- 1970 – Surge o Prolog, uma linguagem de programação em lógica
- 1971 – DENDRAL: primeiro sistema pericial (reconstruia a estrutura de moléculas orgânicas)
- 1986 – Robôs comportamentalistas
- 1986 – Ressurgimentos das redes neurais
- 1997 – O IBM Deep Blue vence uma partida de xadrez contra Kasparov
- 1997 – Primeiro campeonato mundial de futebol robótico

# Tópicos de Inteligência Artificial

- Agentes
  - Noção de agente
  - Objectivo da Inteligência Artificial
  - Agentes reactivos e deliberativos
  - Propriedades do mundo de um agente
  - Arquitecturas de agentes
- Representação do conhecimento
- Técnicas de resolução de problemas

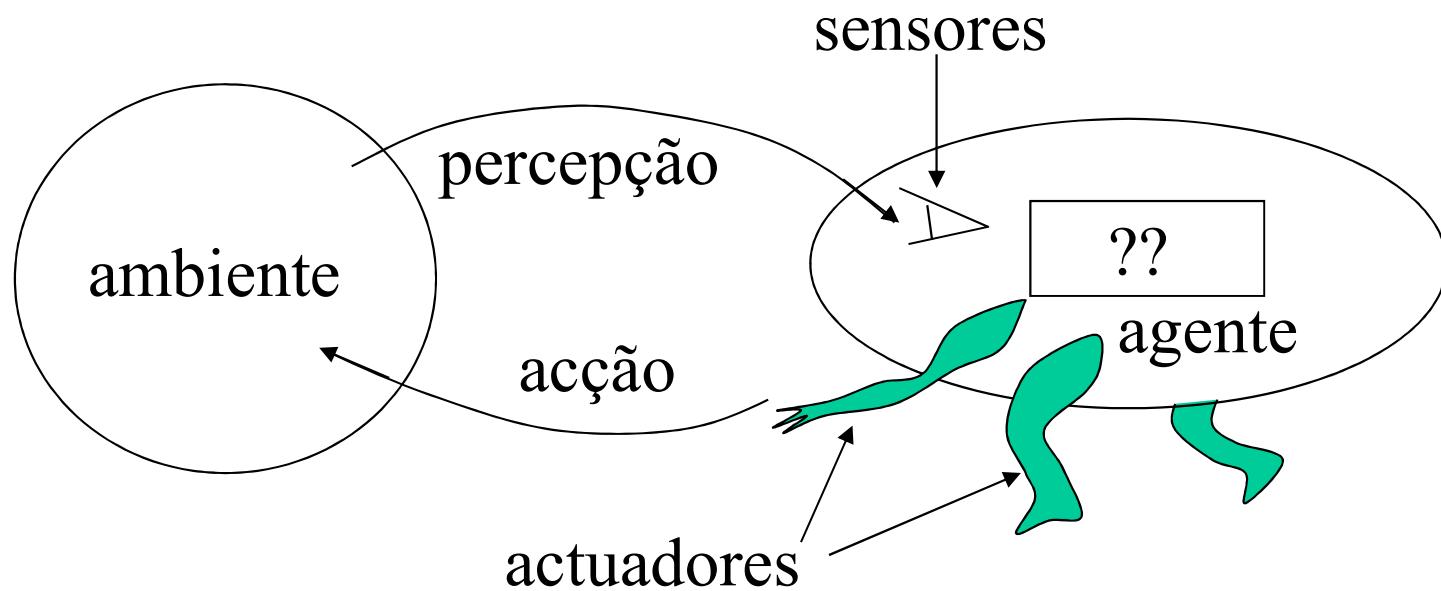
# Definição de “Agente”

- Nesta disciplina estudamos técnicas úteis no desenvolvimento de “agentes inteligentes”
- Segundo [www.dictionary.com](http://www.dictionary.com), um “agente” pode ser uma:
  - Entidade com poder ou autoridade de agir
  - Entidade que actua em representação de outrem

# Definição de “Agente”

- Agente – uma entidade com capacidade de obter informação sobre o seu ambiente (através de “sensores”) e de executar acções em função dessa informação (através de “actuadores”). [Russell & Norvig, 1995]
- Exemplos:
  - Agente físico: robô anfitrião
  - Agente de software: agente móvel de pesquisa de informação na internet

# Agente

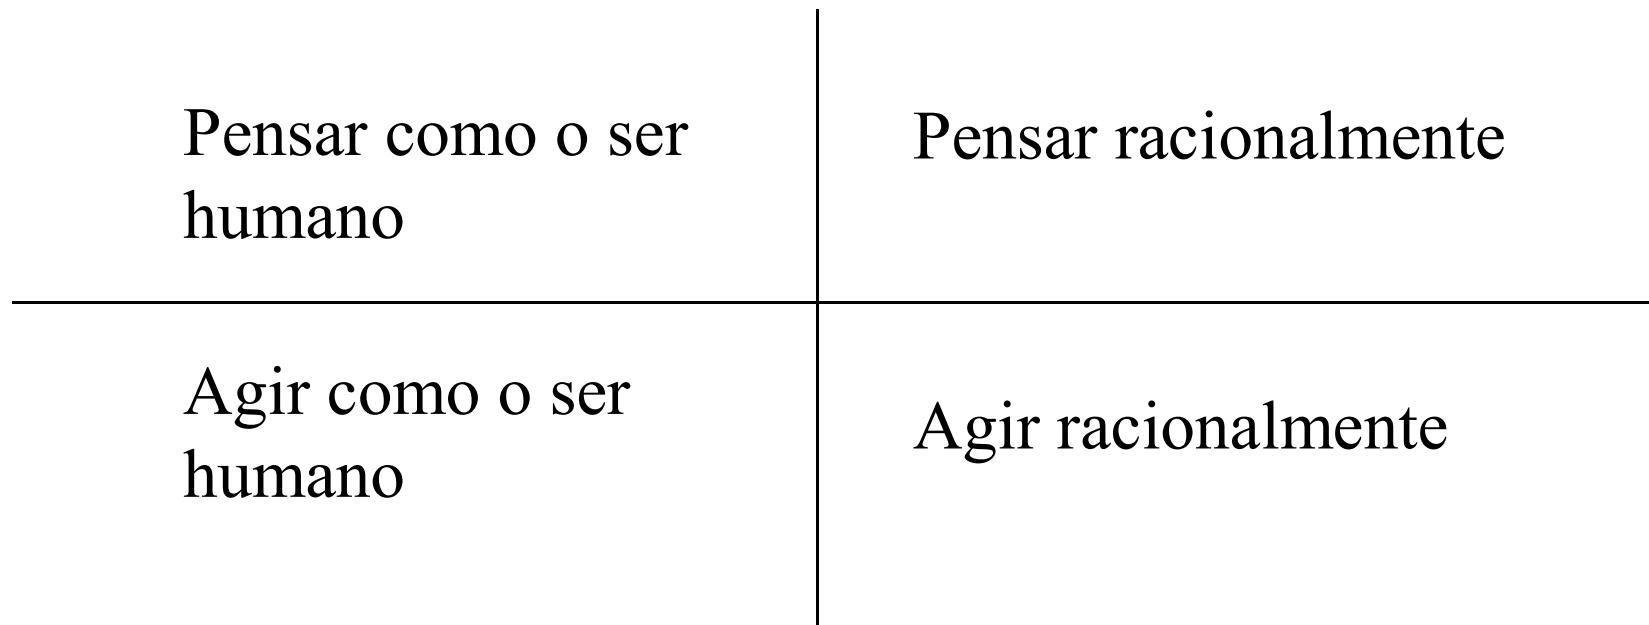


# Exemplos de agentes

Tipo de agente	Percepção	Acção	Objectivos	Ambiente
Sistema de diagnóstico médico	Sintomas, respostas do paciente	Perguntas, testes, tratamentos	Saúde do paciente, custo mínimo	Paciente, hospital
Sistema de análise de imagens de satélite	Imagen	Devolver uma categorização da cena	Categorização correcta	Imagens de um satélite em órbita
Braço robótico para em embalagem	Imagen, sinal de força	Colocar peças em caixas	Colocar as peças na posição correcta	Alimentador de peças, caixas
Controlador de refinaria	Temperatura, pressão	Abrir e fechar válvulas; ajustar temperatura	Pureza, segurança	Refinaria
Tutor de inglês interactivo	Palavras introduzidas	Propôr exercícios, corrigi-los, dar sugestões	Maximizar o resultado dos alunos num teste	Conjunto de alunos

# Voltando à definição de “Inteligência Artificial”

- “Inteligência Artificial” é a disciplina que estuda as teorias e técnicas necessárias ao desenvolvimento de “artefactos” inteligentes. [Nilsson, 1998]
- Direcções seguidas [Russell & Norvig, 1995]:



# Agir como o ser humano

## – o Teste de Turing

- “Comportamento inteligente” – a capacidade de um artefacto obter desempenho comparável ao desempenho humano em todas as actividades cognitivas. [Turing, 1950]
- Teste de Turing – é uma definição operacional de comportamento inteligente de nível humano:
  - Consiste em submeter o artefacto a um interrogatório realizado por um ser humano através de um terminal de texto.
  - Se o humano não conseguir concluir se está a interrogar um artefacto ou outro ser humano, então, esse artefacto é inteligente.
- Os sistemas deste tipo serão o objectivo principal da “Inteligência Artificial”?

# A “sala chinesa” de Searle

- Um humano, que apenas fala uma língua ocidental, documentado com um conjunto de regras escritas num livro nessa língua, e dispondo de folhas de papel, está fechado numa sala.
- Através de uma abertura na sala, o humano recebe folhas de papel com símbolos indecifráveis.
- De acordo com as regras, e em função do que recebe, o humano escreve outros símbolos (que igualmente desconhece) nas folhas brancas e envia-as para o exterior da sala.
- No exterior, no entanto, o que se observa é folhas de papel com mensagens escritas em caractéres chineses a serem introduzidas na sala e respostas inteligentes a essas mensagens a serem devolvidas do interior da sala.

# O argumento de Searle

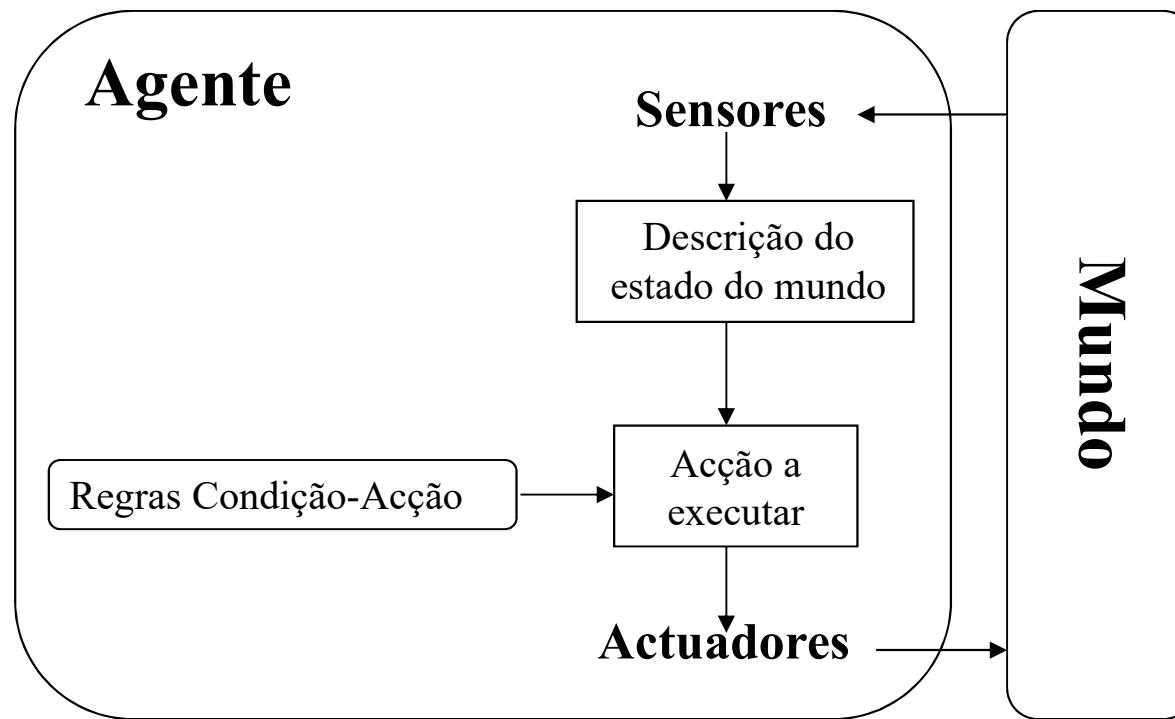
- O humano não percebe chinês
- A sala não percebe chinês
- O livro de regras e as folhas de papel também não percebem chinês
- Logo, não há qualquer compreensão de chinês naquela sala
- No entanto, podemos contra-argumentar: embora, individualmente, os componentes do sistema (a sala, o humano, o livro, as folhas de papel) não compreendam chinês, o sistema no seu conjunto comprehende chinês

Logo, Searle searle enfatiza o facto de que os computadores usam regras para manipular: Tópicos de Inteligência Artificial → tem conhecimento do significado das símbolos.

# Tipos e arquitecturas de agentes

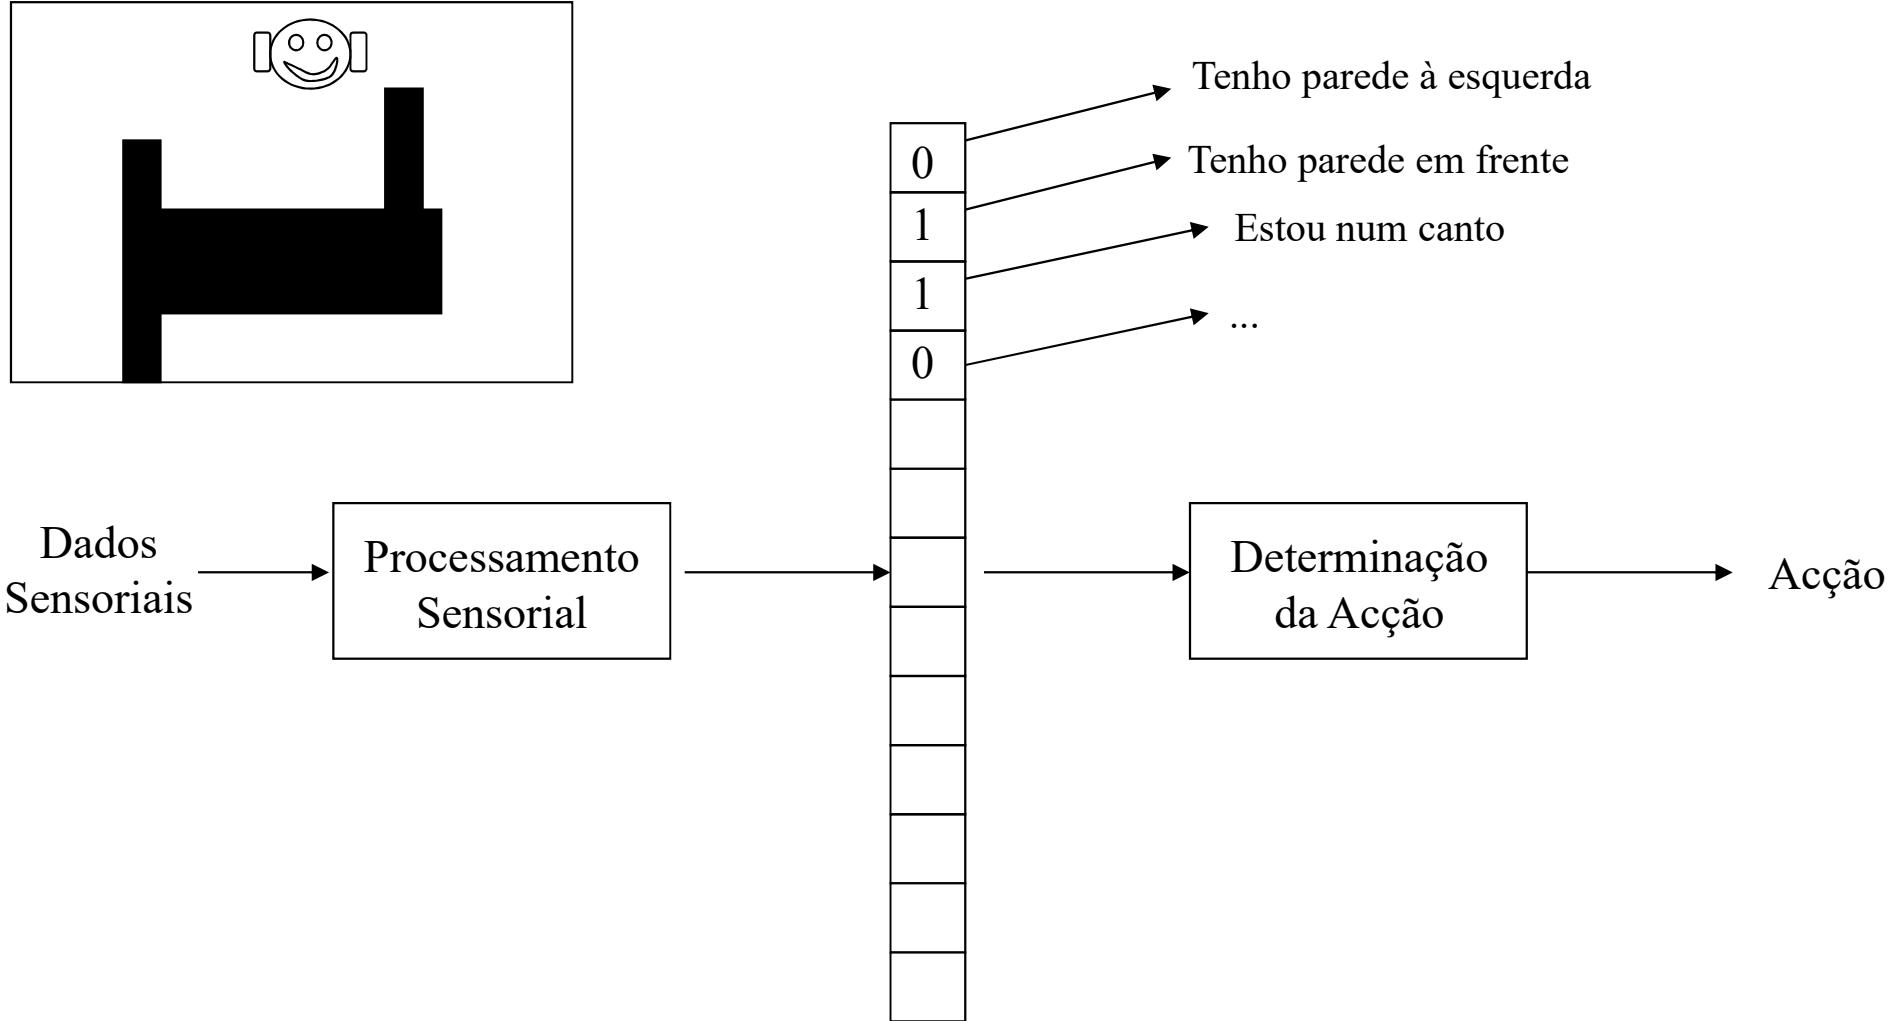
- Tipos de agentes
  - Reactivos simples
  - Reactivos com estado
  - Deliberativos orientados por objectivos
  - Deliberativos orientados por funções de utilidades
- Arquitecturas
  - Subsunção
  - Três torres
  - Três camadas
  - CARL

# Agente reactivo: simples

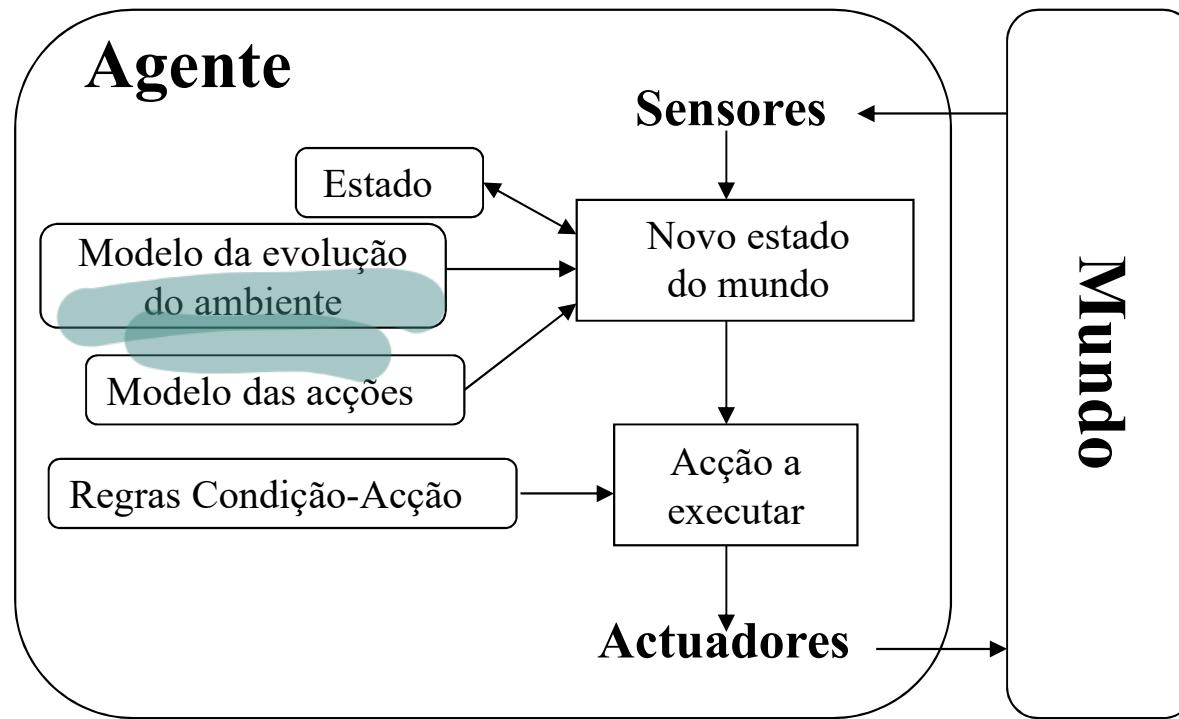


- O conceito de “regra de condição-acção” é também conhecido como “regra de situação-acção” ou “regra de produção”.
- Os agentes ou sistemas reactivos simples são também conhecidos como “sistemas de estímulo-resposta” ou “sistemas de produção”

# Representando a percepção através de um vector de características

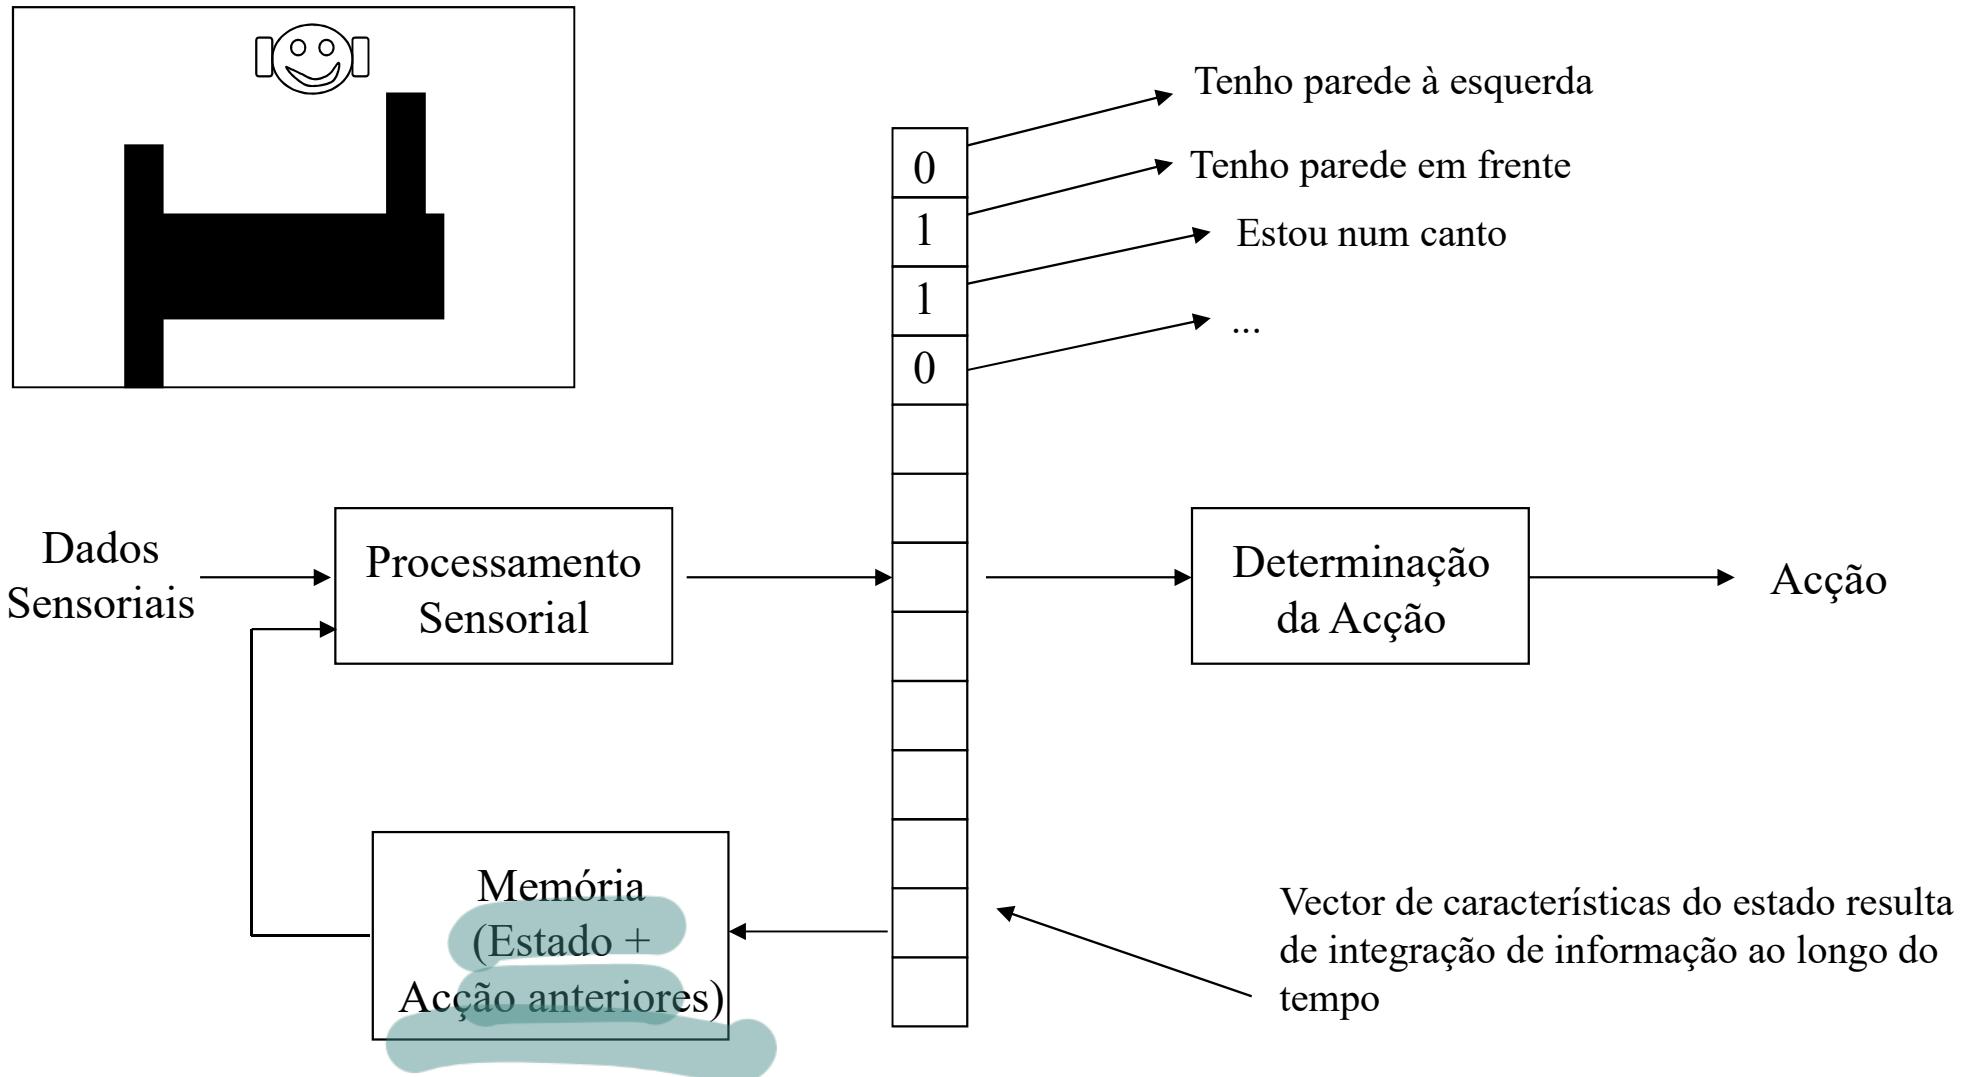


# Agente reactivo: com estado interno

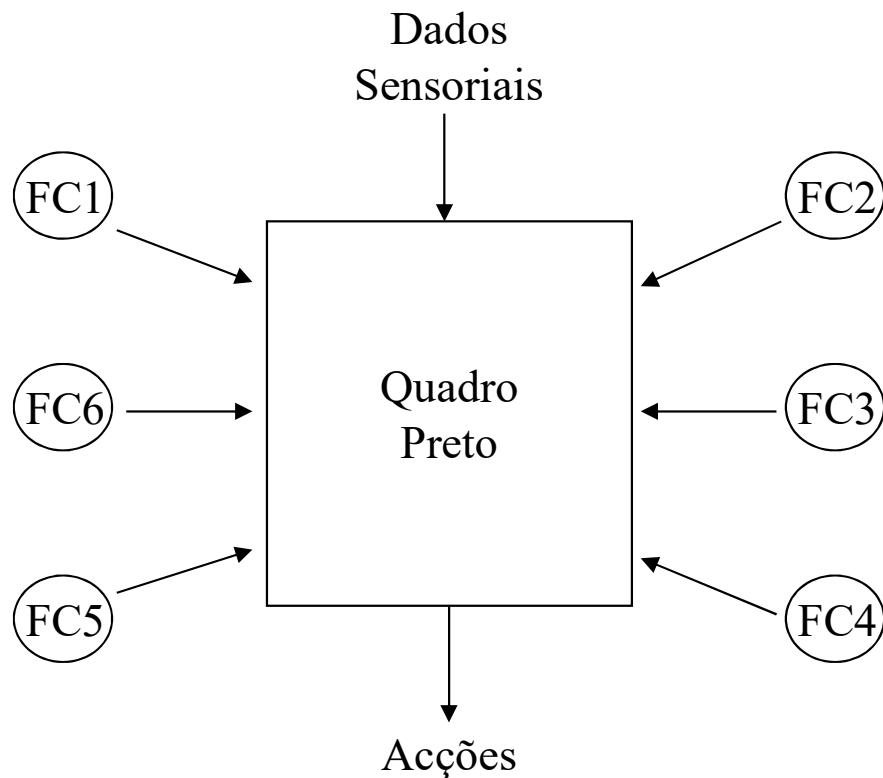


atualizar o estado com base no que vê, no que  
ja viu e nos modelos que tem do mundo

# Representando a percepção através de um vector de características: agente com estado

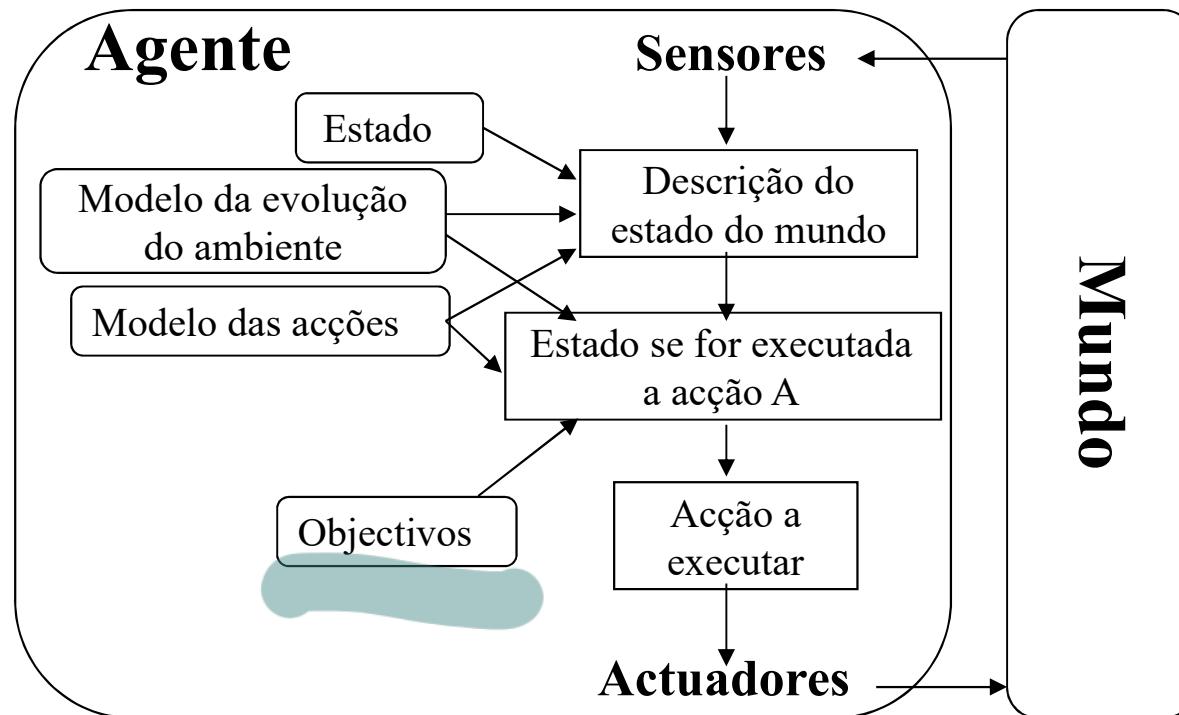


# Sistemas de Quadro Preto

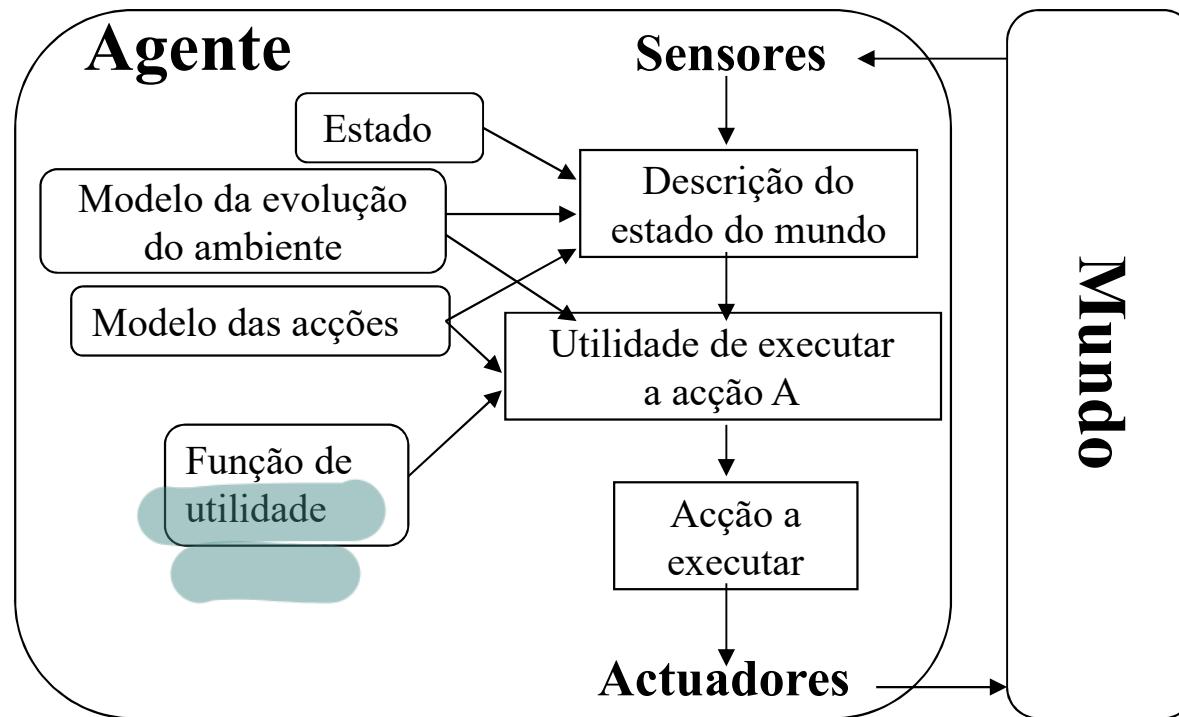


- Podem ser vistos como uma elaboração dos sistemas reactivos com estado interno.
- Uma “fonte de conhecimento” (FC) é um programa que vai fazendo alterações no Quadro Preto.
- Uma FC pode ser vista como um especialista num dado domínio.
- Tipicamente, cada FC rege-se por um conjunto de regras de situação-acção.

# Agente deliberativo: orientado por objectivos



# Agente deliberativo: orientado por função de utilidade



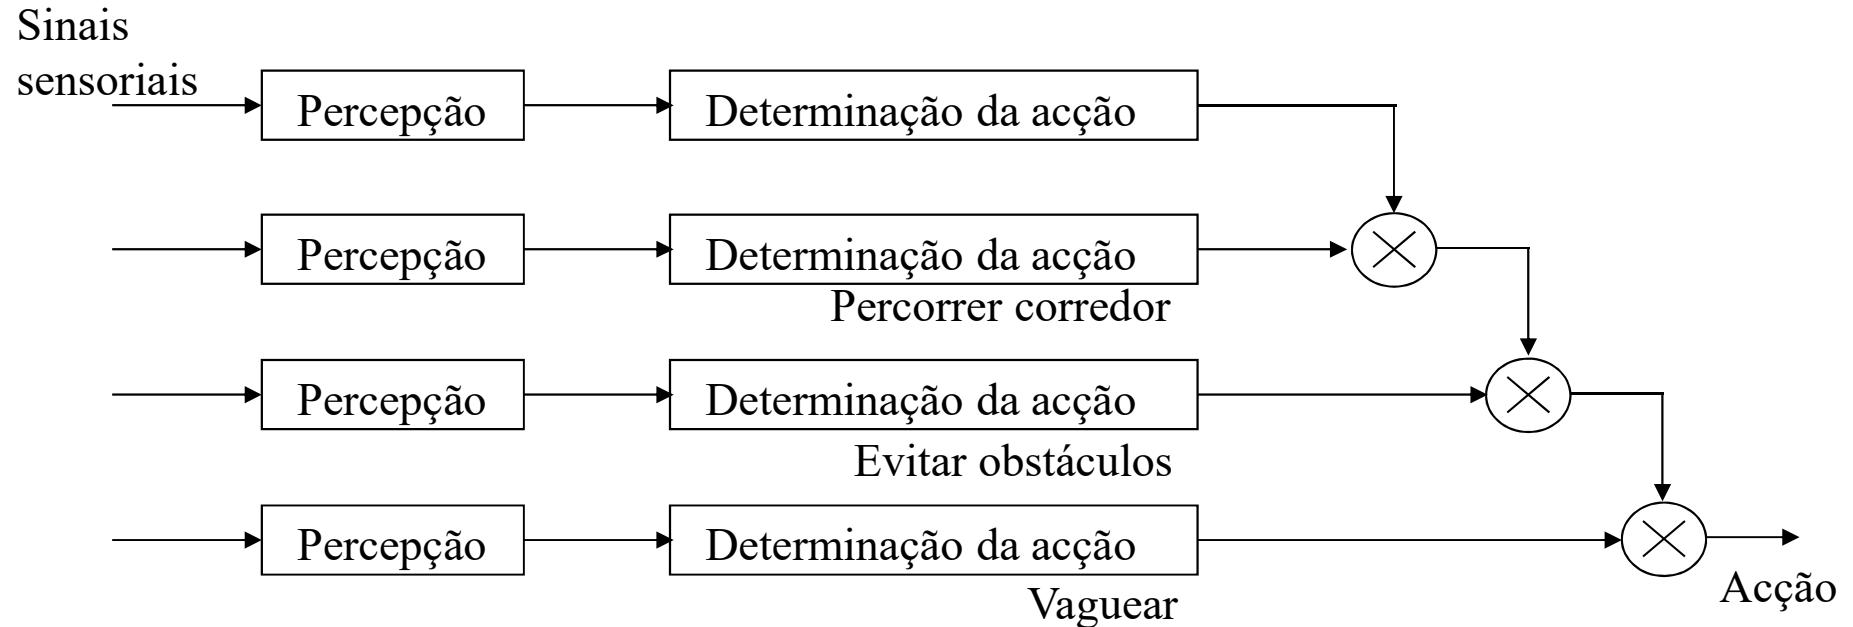
# Propriedades do mundo de um agente

- as percepções do agente captam toda a informação necessária para*
- Acessibilidade – o mundo é “acessível” se os sensores do agente permitem obter uma descrição completa do estado do mundo; o mundo será “efectivamente acessível” se é possível obter toda a informação relevante ao processo de escolha das acções.
  - Determinismo – o mundo é “determinístico” se o estado resultante da execução de uma acção é totalmente determinado pelo estado actual e pelos efeitos esperados da acção.
  - Mundo episódico – no caso em que cada episódio de percepção-acção é totalmente independente dos outros.
  - Dinamismo – o mundo é “dinâmico” se o seu estado pode mudar enquanto o agente delibera; caso contrário, o mundo diz-se “estático”.
  - Continuidade – o mundo é “continuo” quando a evolução do estado do mundo é um processo continuo ou sem saltos; caso contrário o mundo diz-se “discreto”.

# Mundo de um agente: Exemplos

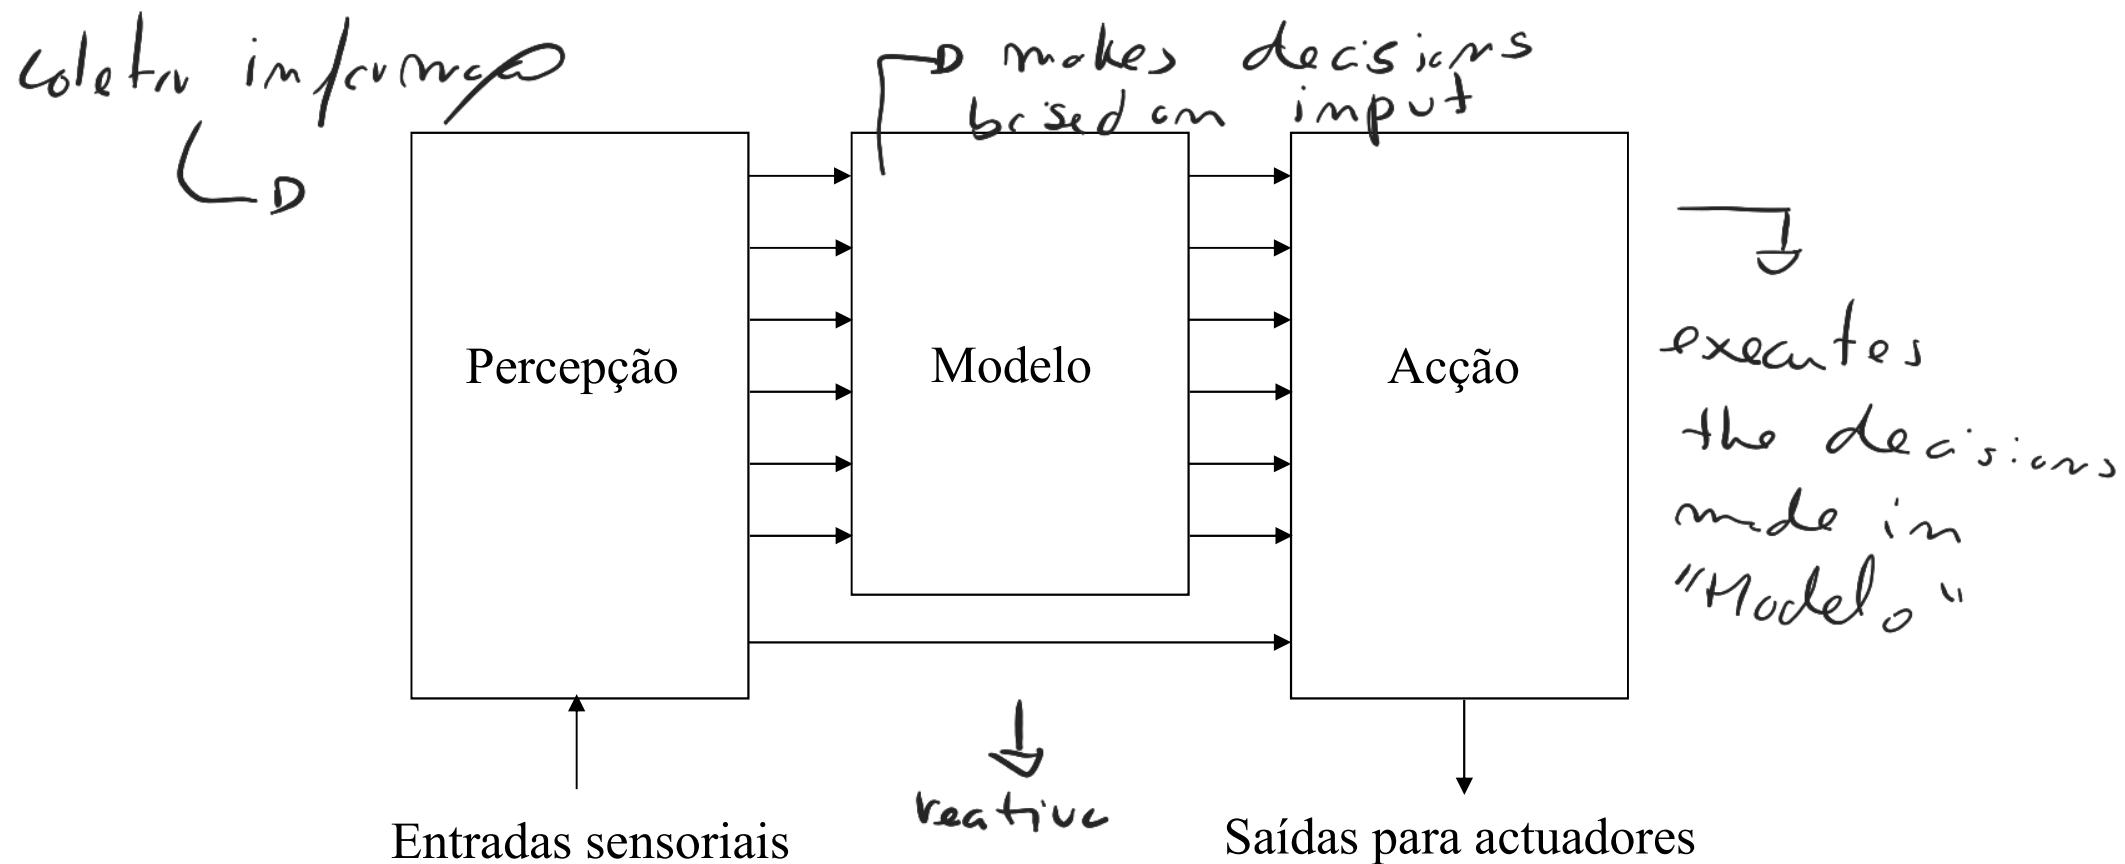
Mundo	Acessível	Determinístico	Episódico	Dinâmico	Continuo
Xadrês s/ relógio	Sim	Sim	Não	Não	Não
Xadrês c/ relógio	Sim	Sim	Não	Semi	Não
Poker	Não	Não	Não	Não	Não
Condução de carro	Não	Não	Não	Sim	Sim
Diagnóstico médico	Não	Não	Não	Não	Sim
Sistema de análise de imagem	Sim	Sim	Sim	Semi	Sim
Manipulação robótica	Não	Não	Sim	Sim	Sim
Controlo de refinaria	Não	Não	Não	Sim	Sim
Tutor de Inglês interactivo	Não	Não	Não	Sim	Não

# Arquitecturas de agentes: Subsunção



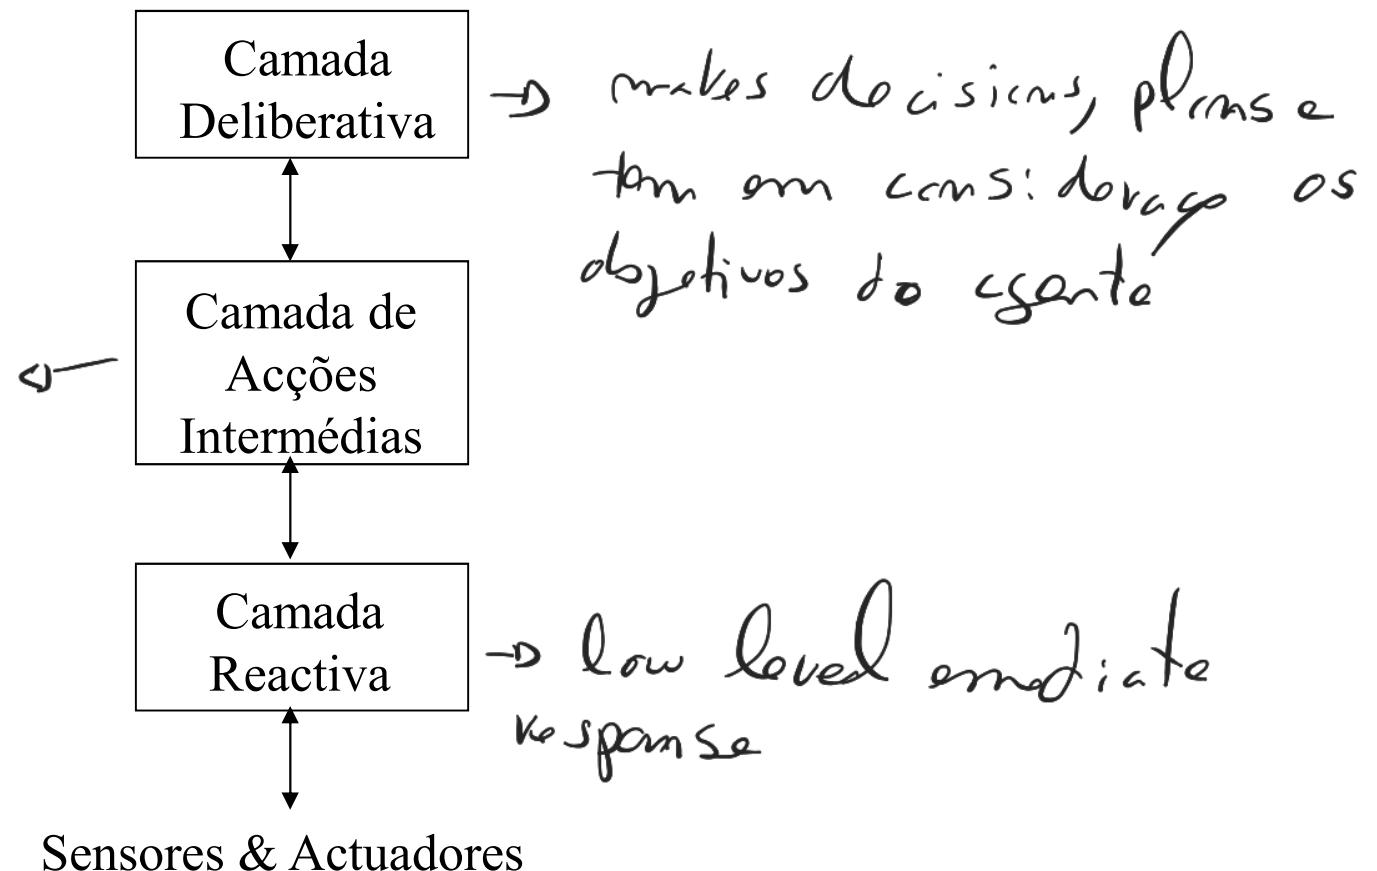
- A arquitectura de subsunção [Brooks, 1986; Connell, 1990] procura estabelecer a ligação entre percepção e acção a vários níveis – daqui resulta uma organização em camadas.
- A camada mais baixa é a mais reactiva.
- O peso da componente deliberativa aumenta à medida que se sobe na estrutura de camadas.

# Arquitecturas de Agentes: Três Torres



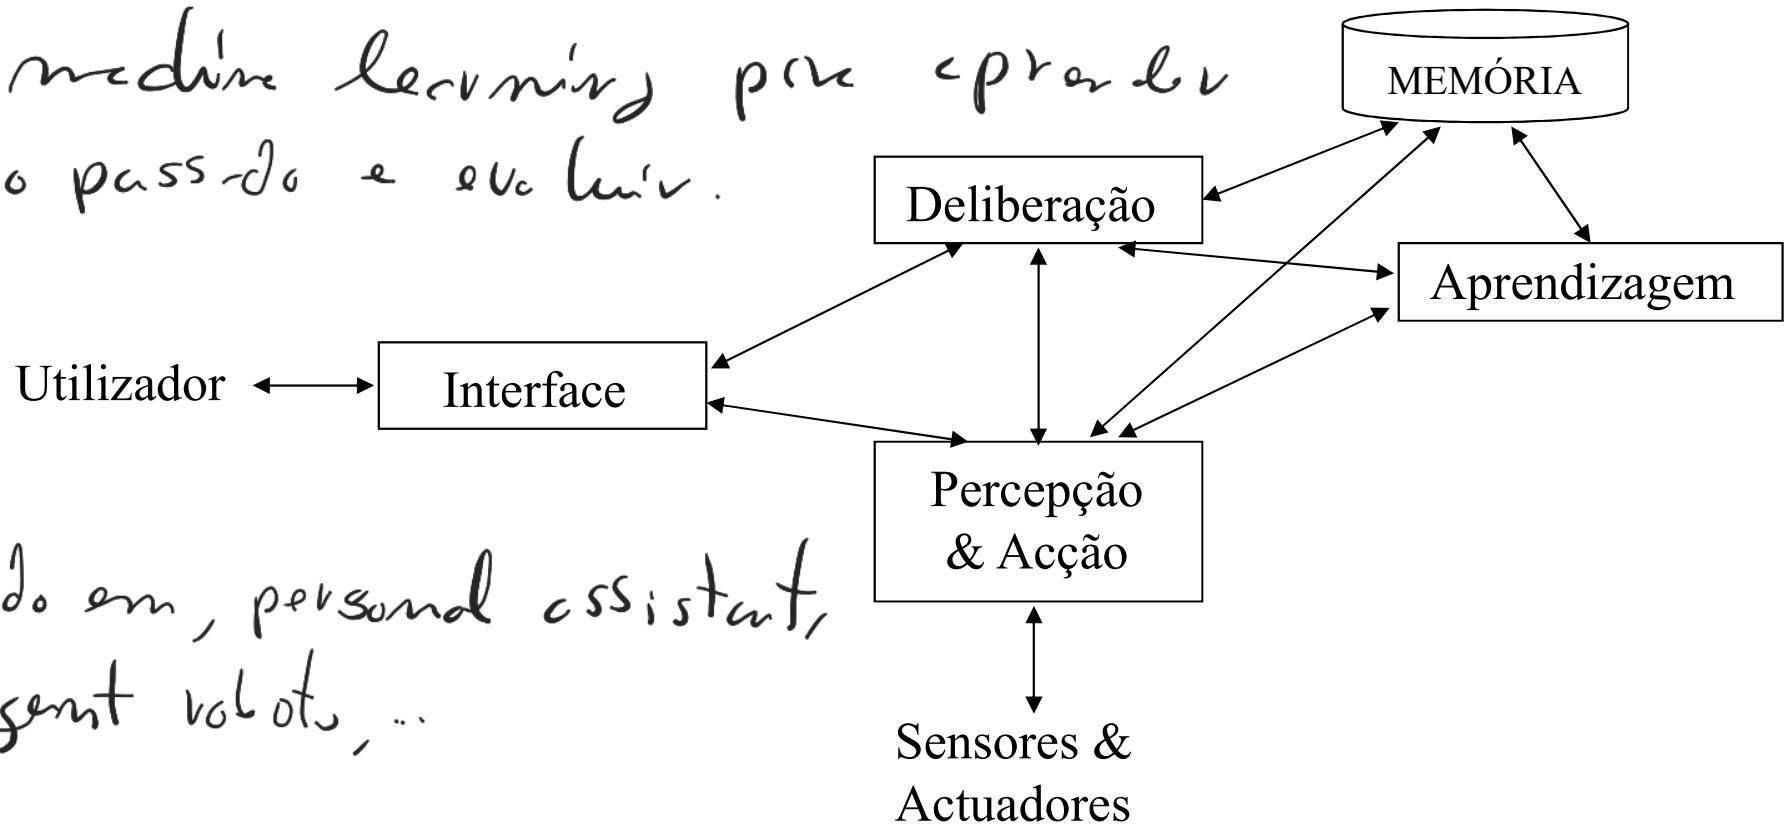
# Arquitecturas de Agentes: Três Camadas

coordena as outras camadas, adapta ao ambiente



# Arquitecturas de Agentes: CARL

Usa machine learning para aprender com o passado e evoluir.



É usado em, personal assistant, intelligent robots, ...

# Tópicos de Inteligência Artificial

- Agentes
  - Noção de agente
  - Objectivo da Inteligência Artificial
  - Agentes reactivos e deliberativos
  - Propriedades do mundo de um agente
  - Arquitecturas de agentes
- Representação do conhecimento
- Técnicas de resolução de problemas

# Representação do conhecimento

- Redes semânticas
  - Redes semânticas genéricas
  - Sistemas de “frames”
  - Herança e raciocínio não-monotônico
  - Relação com diagramas UML
  - Exemplo para aulas práticas
- Lógica proposicional e lógica de primeira ordem
- Linguagem KIF
- Engenharia do conhecimento
- Ontologia geral
- Redes de Bayes

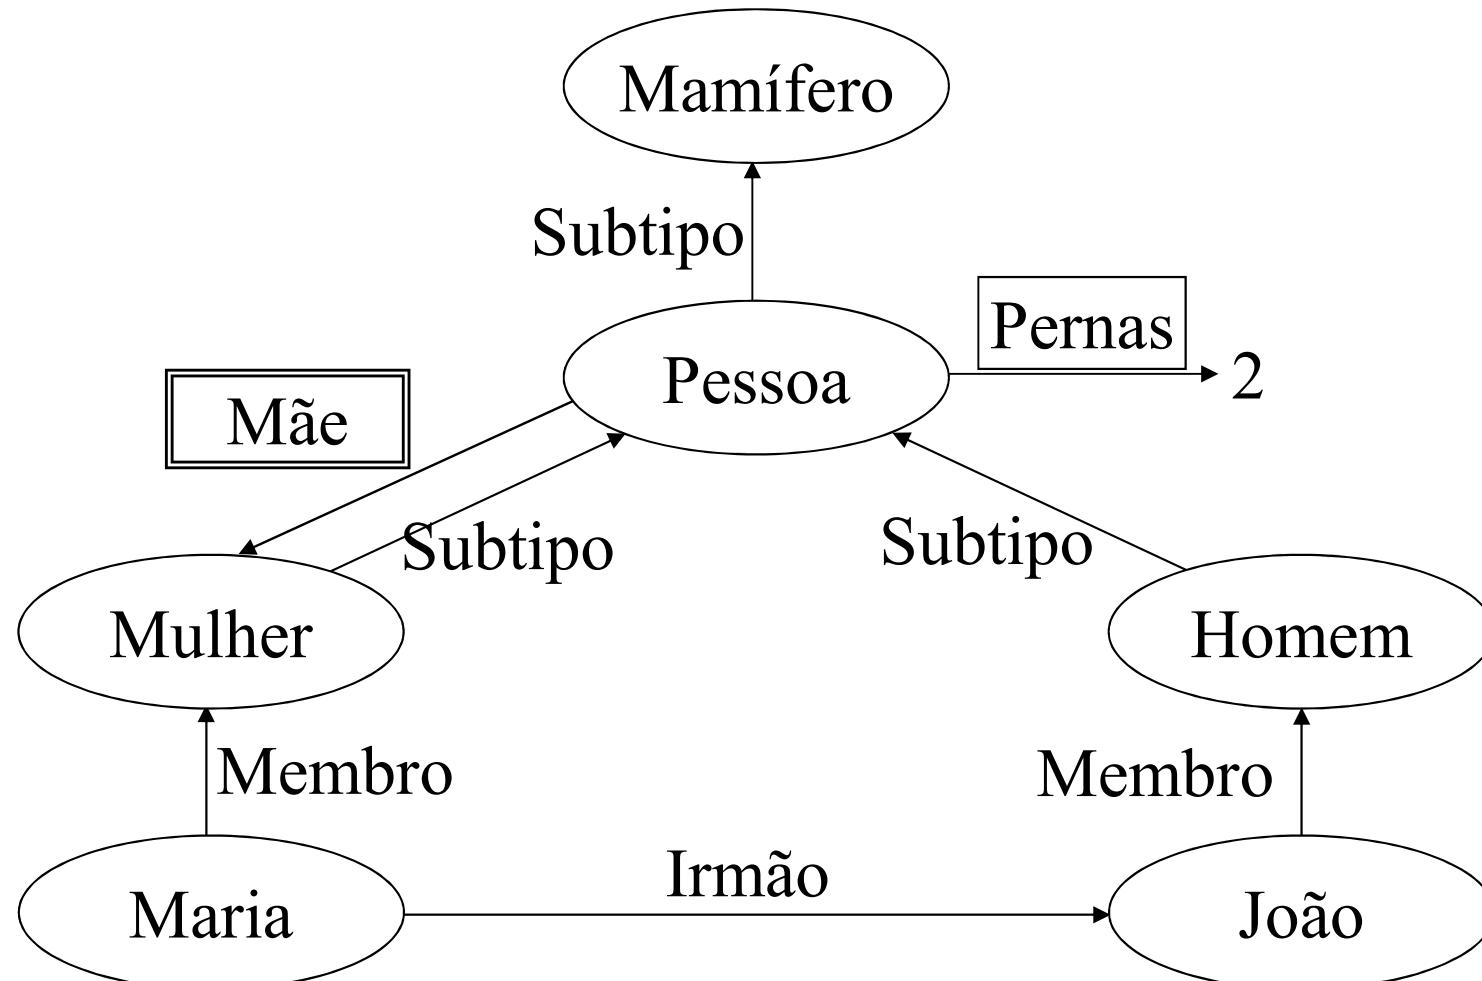
# Redes Semânticas

- Redes semânticas são representações gráficas do conhecimento
- Têm a vantagem da legibilidade
- As redes semânticas podem ser tão expressivas quanto a lógica de primeira ordem

# Redes Semânticas – tipos de relações

- *Sub-tipo* (ou *sub-conjunto* ou ainda *sub-classe*):
  - $A \subset B$
- *Membro* (ou *instância*):
  - $A \in B$
- Relação objecto-objecto:
  - $R(A,B)$
- Relação conjunto-objecto:
  - $\forall x x \in A \Rightarrow R(x,B)$
- Relação conjunto-conjunto:
  - $\forall x x \in A \Rightarrow \exists y (y \in B \wedge R(x,y))$

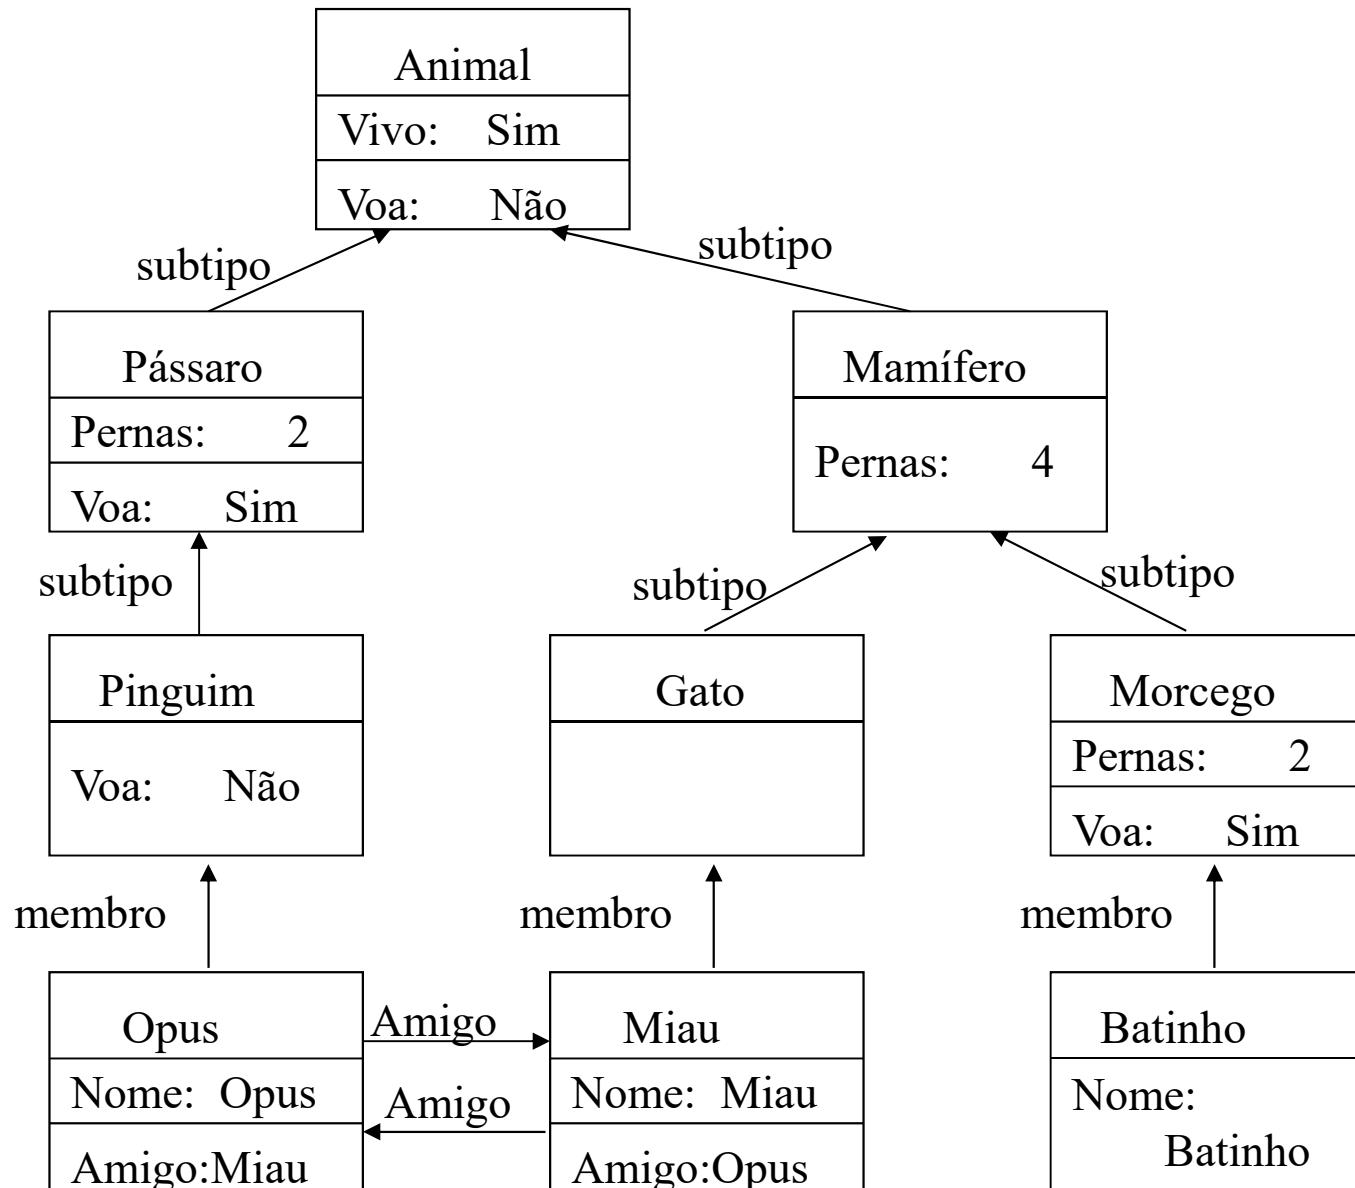
# Redes semânticas – exemplo



# Redes Semânticas - herança

- As relações de *sub-tipo* e *membro* permitem a herança de propriedades:
  - O sub-tipo herda todas as propriedades dos tipos mais abstractos dos quais descende
  - A instância herda todas as propriedades do tipo a que pertence
- A inferência pode ser vista como o seguimento das ligações entre entidades com vista à herança de propriedades
- Pode implementar-se raciocínio não monotónico através do estabelecimento de valores por defeito e o correspondente cancelamento da herança. (ver exemplo)

# Redes Semânticas - exemplo



# Redes Semânticas – Métodos e Demónios

- Normalmente, por razões computacionais, usam-se redes semânticas bastante menos expressivas do que a lógica de primeira ordem
- Deixa-se de lado:
  - Negação
  - Disjunção
  - Quantificação
- Em contra-partida, nomeadamente nos chamados sistemas de *frames*, usam-se métodos e demónios:
  - *Métodos* têm uma semântica similar à da programação orientada por objectos.
  - *Demónios* são procedimentos cuja execução é disparada automaticamente quando certas operações de leitura ou escrita são efectuadas.

# GOLOG – Um gestor de objectos em Prolog

- O GOLOG é um gestor de objectos cuja semântica é próxima das *frames* (Seabra Lopes, 1995)
- Algumas primitivas:
  - `new_frame(Frame)`
  - `new_slot(Slot)`
  - `new_value(Frame,Slot,Value)`
  - `new_relation(Rel,Trans,Restrictions,Inv)`
    - `Trans` ::= `transitive` | `intransitive`
    - `Restrictions` ::= `all` | `none` | `inclusion(Slots)` | `exclusion(Slots)`
  - `call_method(Frame,Method,ParamList)`
  - `new_demon(Frame,Slot,Proc,Access,When,Effect).`
    - `Access` ::= `if_read` | `if_write` | `if_delete` | `if_execute`
    - `When` ::= `before` | `after`
    - `Effect` ::= `alter_value` | `side_effect`

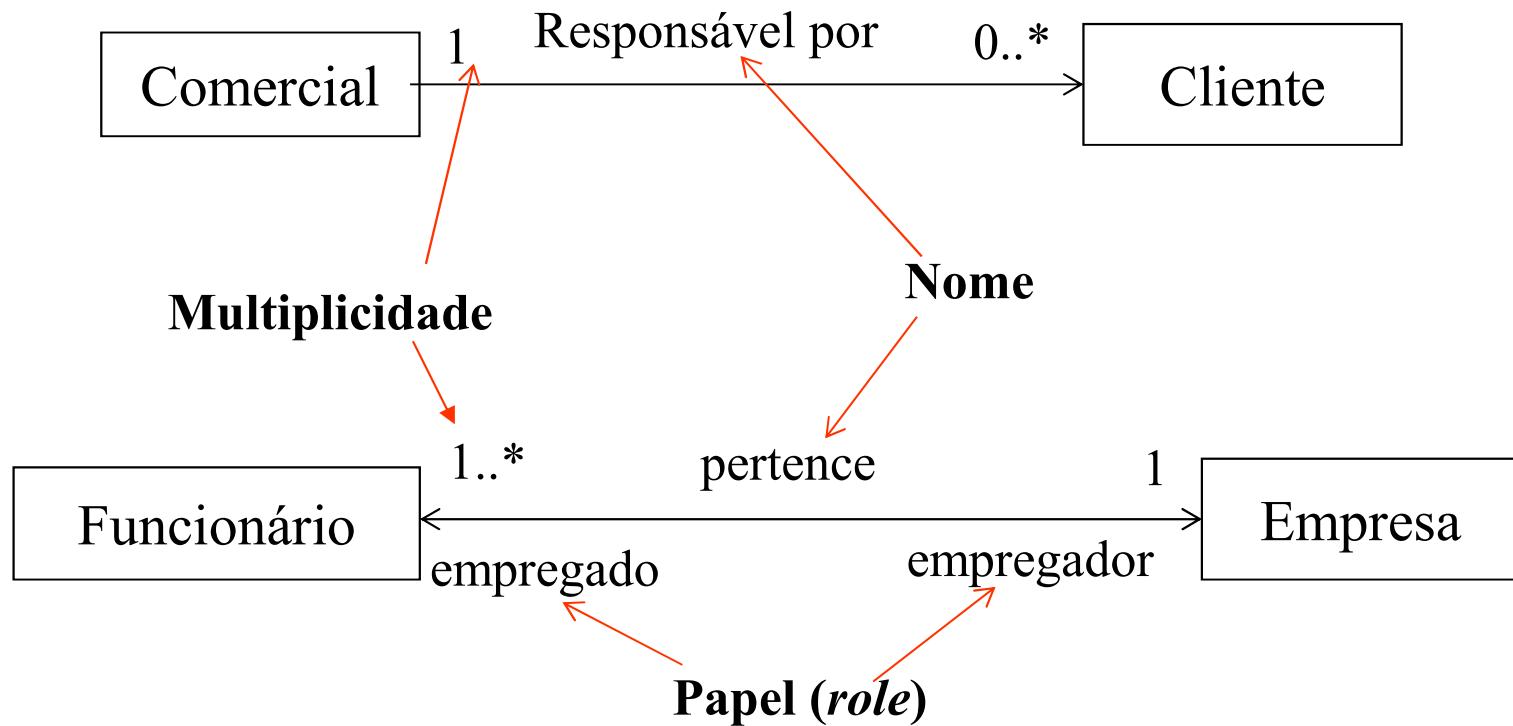
# UML / Diagramas de Classes - 1

- Na linguagem gráfica UML (*Unified Modelling Language*), os diagramas de classes definem as relações existentes entre as diferentes classes de objectos num dado domínio
  - **Classe** – descrição de um conjunto de objectos que partilham os mesmos atributos, operações, relações e semântica; estes objectos podem ser:
    - Objectos físicos
    - Conceitos que não tenham uma existência palpável
  - **Atributo** – uma propriedade de uma classe
  - **Operação (ou método)** – é a implementação de um serviço que pode ser executado por qualquer objecto da classe
  - **Instância** de uma classe – um objecto que pertence a essa classe, ou seja, constitui uma concretização dessa classe
    - As instâncias de uma classe diferenciam-se pelos valores dos atributos
    - As instâncias “herdam” todos os atributos e métodos da sua classe

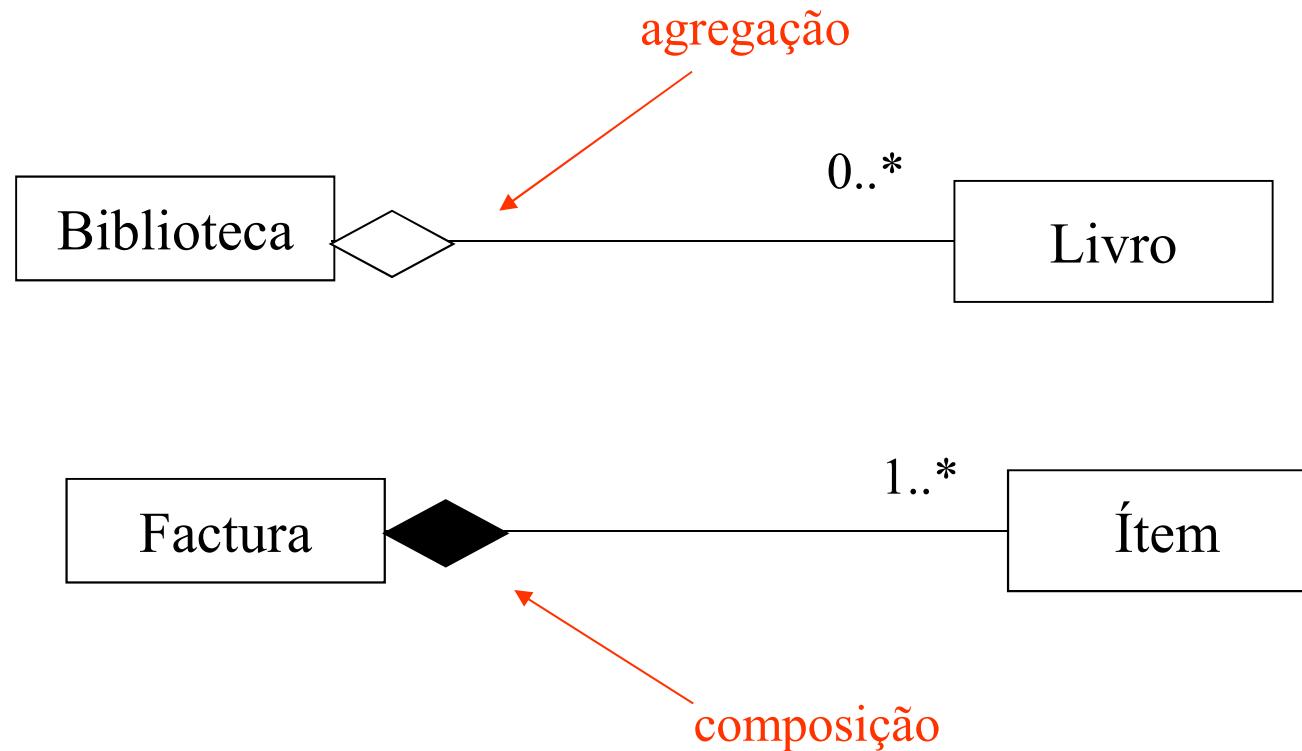
# UML / Diagramas de Classes – 2: Relações

- Um aluno lê um livro
  - **Associação** : classe A “usa a”/ “interage com” classe B
- Um recibo tem vários itens
  - **Composição**: relação todo-parte
- Uma biblioteca tem vários livros
  - **Agregação**: representa relação estrutural entre instâncias de duas classes, em que a classe agregada existe independentemente da outra
- Um aluno é uma pessoa
  - **Generalização**: classe A generaliza classe B e B especializa A (super-classe/sub-classe)

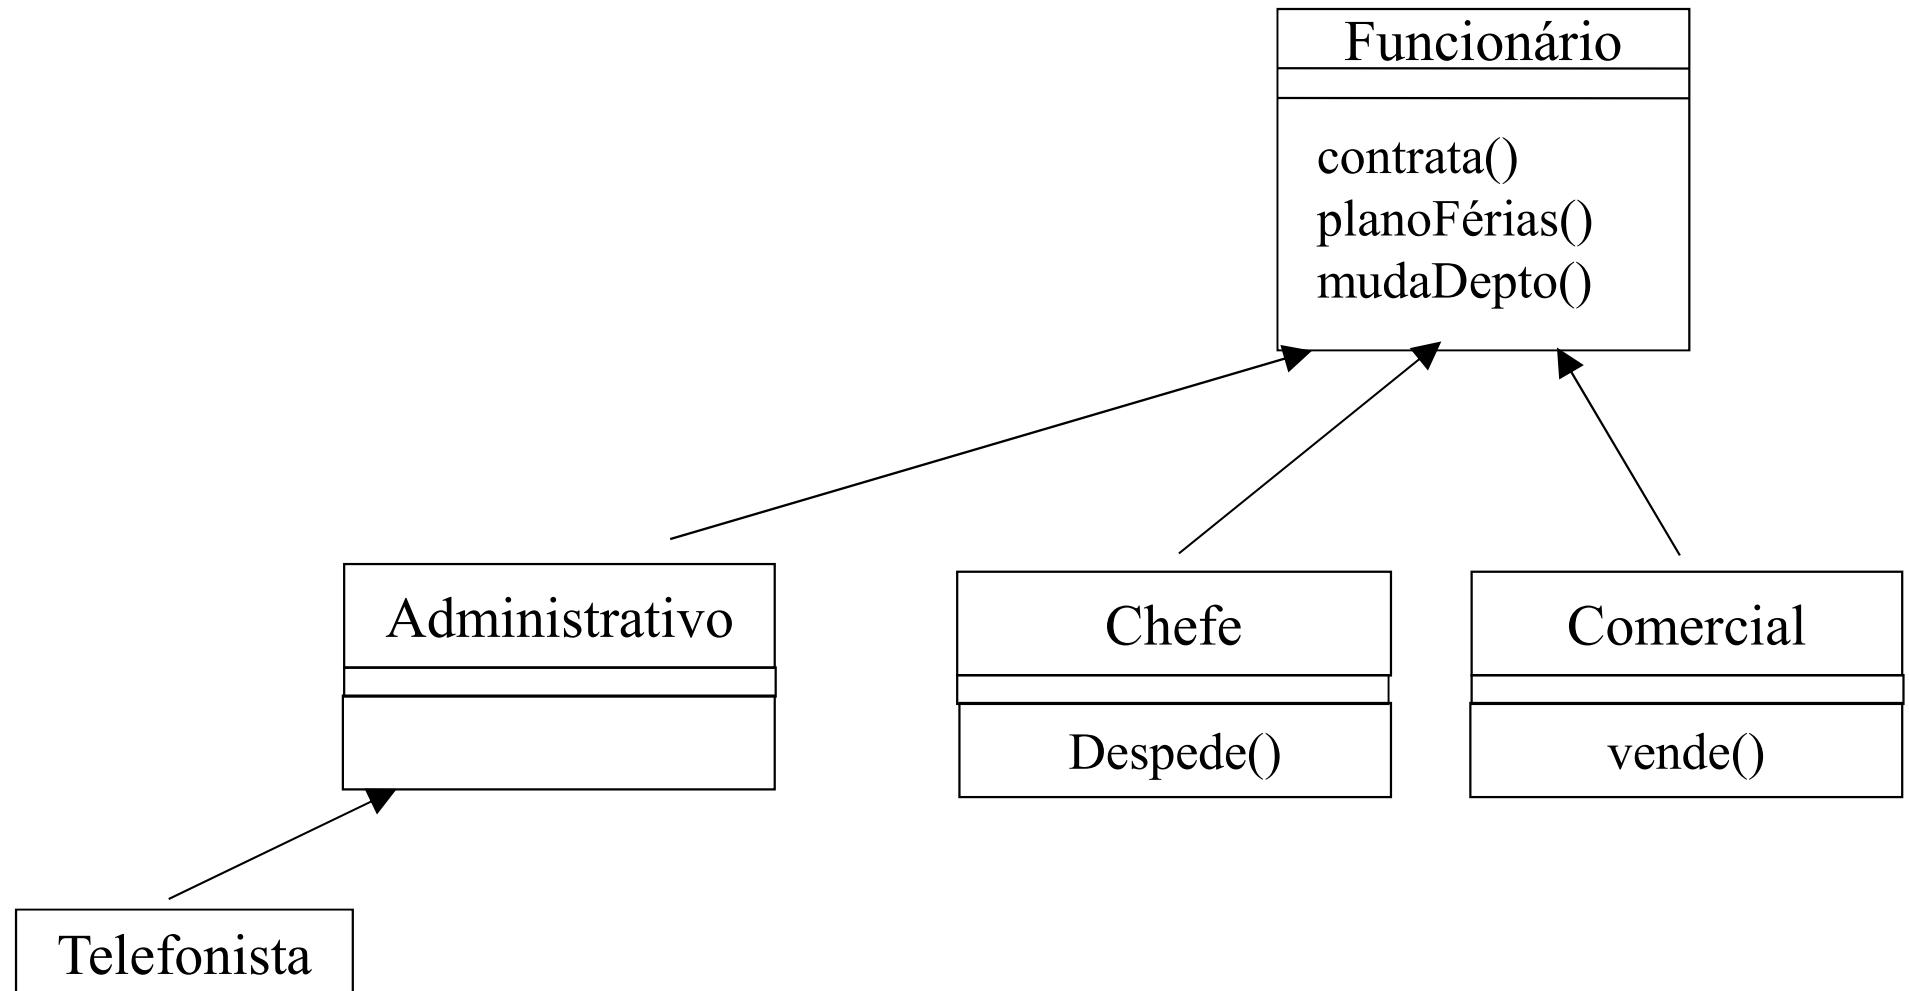
# UML / Diagramas de Classes – 3: Associação



# UML / Diagramas de Classes – 4: Agregação e Composição



# UML / Diagramas de Classes – 5: Generalização



# Redes semânticas *versus* UML

<u>Redes semânticas</u>	<u>UML</u>
subtipo(SubTipo,Tipo)	Generalização em diagramas de classes
membro(Obj,Tipo)	Diagramas de objectos
Relação Objecto/Objecto	Associação, agregação e composição em diagramas de objectos
Relação Objecto/Tipo	não tem
Relação Tipo/Tipo	Associação, agregação e composição em diagramas de classes

# Indução versus Dedução

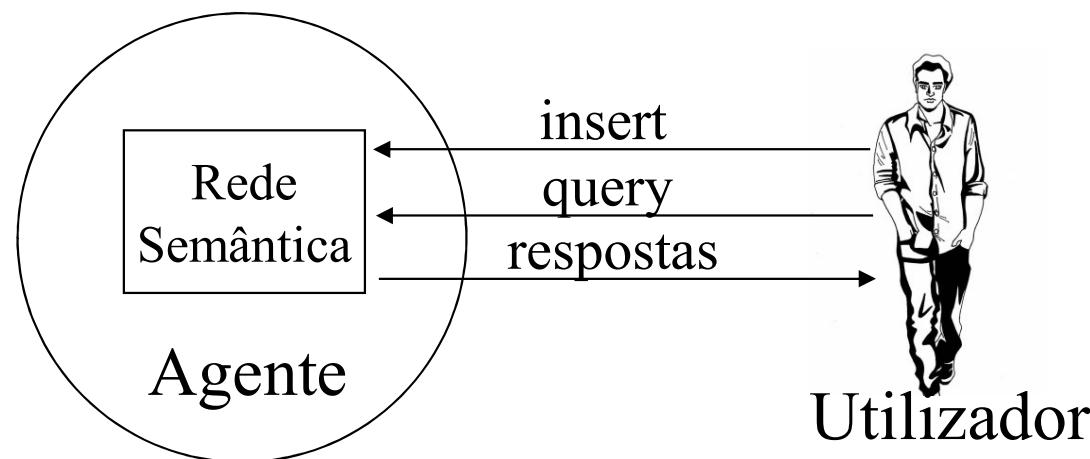
- Dedução – permite inferir casos particulares a partir de regras gerais
  - Preserva a verdade
  - As regras de inferência apresentadas anteriormente são regras dedutivas
- Indução – é o oposto da dedução; permite inferir regras gerais a partir de casos particulares
  - É a base principal da aprendizagem

# Indução

- Exemplo:
  - Casos conhecidos
    - O gato Tareco gosta de leite
    - O gato Pirata gosta de leite
  - Regra inferida
    - Os gatos (normalmente) gostam de leite
  - Nas redes semânticas, a indução pode ser vista como uma “herança de baixo para cima”

# Redes Semânticas em Python

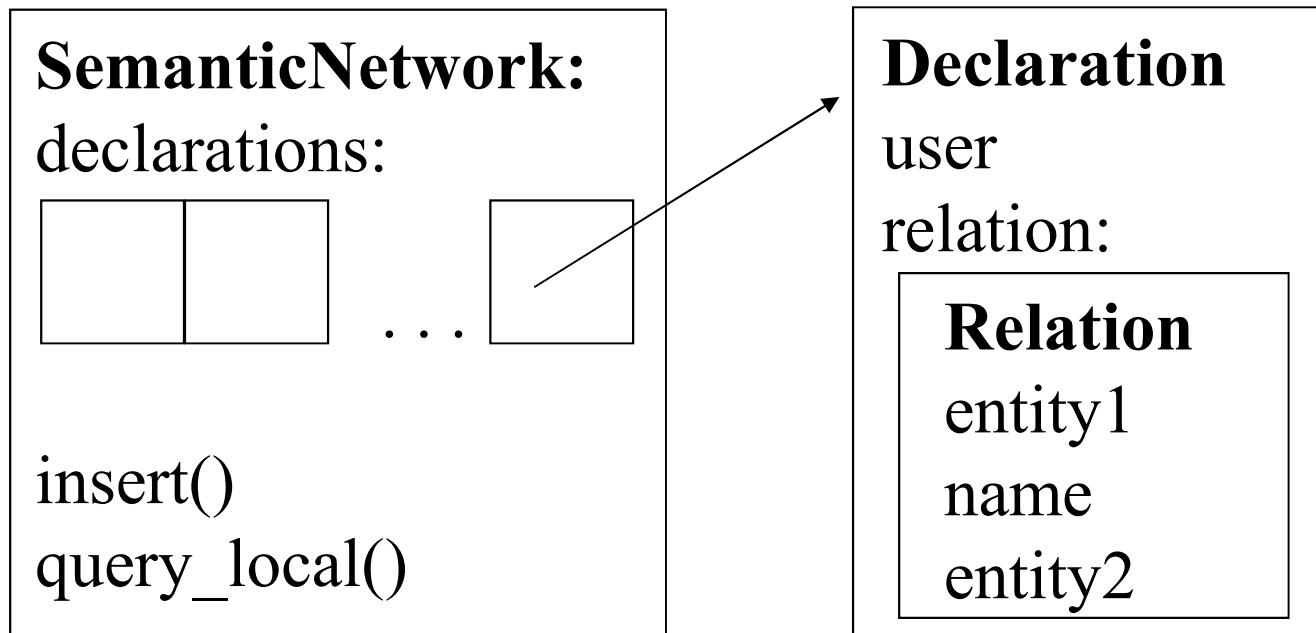
- Vamos criar uma rede semântica, definida como um conjunto de declarações
- Cada declaração associa uma relação semântica ao indivíduo que a declarou
  - Declaration(user,relation)



# Redes Semânticas em Python

- Uma relação pode ser dos três tipos seguintes:
  - Member(obj, type) – um objecto é membro de um tipo
  - Subtype(subtype,supertype) – um tipo é subtipo de outro
  - Association(entity1,name,entity2) – uma entidade (objecto ou tipo) está associada a outra
- Operações principais:
  - insert – introduzir uma nova declaração
  - query\_local – questionar a rede semântica sobre as declarações existentes
- Através da introdução incremental de declarações por diferentes interlocutores, emulamos de forma simplificada um processo de aprendizagem, em que o conhecimento é adquirido através da interacção com outros agentes

# Redes Semânticas em Python



- Nota: ver módulo usado nas aulas práticas

# Representação do conhecimento

- Redes semânticas
  - Redes semânticas genéricas
  - Sistemas de “frames”
  - Herança e raciocínio não-monotônico
  - Relação com diagramas UML
  - Implementação em Python
- Lógica proposicional e lógica de primeira ordem
- Linguagem KIF
- Engenharia do conhecimento
- Ontologia geral
- Redes de Bayes

# Lógicas

- Uma lógica tem:
  - Síntaxe - descreve o conjunto de frases ou fórmulas que é possível escrever.
    - Nota: Estas são as fórmulas bem formadas ou WFF (do inglês *Well Formed Formula*)
  - Semântica - estabelece a relação entre as frases escritas nessa linguagem e os factos que representam.
    - Exemplo: a semântica da lógica proposicional é definida através de tabelas de verdade.
  - Regras de inferência - permitem manipular as frases, gerando umas a partir das outras; as regras de inferência são a base do processo de raciocínio.

# Lógica Proposicional

- Baseada em proposições
  - *Proposição* = frase declarativa elementar que pode ser verdadeira ou falsa
  - Exemplos:
    - “A neve é branca”
    - “O açúcar é um hidrocarbono”
  - Variável proposicional = uma variável que toma o valor de verdade de uma dada proposição
- Uma fórmula em lógica proposicional é composta por uma ou mais variáveis proposicionais ligadas por conectivas lógicas
  - Uma frase proposicional elementar é um frase composta por uma única variável proposicional

# Lógica de Primeira Ordem

- Componentes:
  - *Objectos ou entidades*
    - Exemplos: 1215, DDinis, Aveiro
  - *Expressões funcionais*
    - Exemplos: Potencia(4,3), Pai-de(Paulo)
    - Nota 1: Os objectos podem ser considerados como expressões funcionais cuja aridade é zero
    - Nota 2: A noção de *termo* engloba quer os objectos quer as expressões funcionais
  - *Predicados ou relações*
    - Exemplos: Pai(Rui, Paulo), Irmão(Paulo,Rosa)
    - Nota: Por definição, os argumentos de um predicado são termos.
- Aqui, as frases elementares são os predicados

# Conectivas Lógicas

- Servem para combinar frases lógicas elementares por forma a obter frases mais complexas
- As conectivas lógicas mais comuns são as seguintes:
  - $\wedge$  (conjunção)
  - $\vee$  (disjunção)
  - $\Rightarrow$  (implicação)
  - $\neg$  (negação)

# Variáveis, Quantificadores

- Na lógica de primeira ordem, os argumentos dos predicados podem ser variáveis, usadas para representar termos não especificados
  - Exemplos:  $x, y, pos, soma, pai, \dots$
- Quantificação universal
  - $\forall x A \equiv$  ‘Qualquer que seja  $x$ , a fórmula  $A$  é verdadeira’
  - Se  $A$  é uma fórmula bem formada, então  $\forall x A$  também é uma fórmula bem formada.
- Quantificação existencial
  - $\exists x A \equiv$  ‘Existe um  $x$ , para o qual a fórmula  $A$  é verdade’
  - Se  $A$  é uma fórmula bem formada, então  $\exists x A$  também é uma fórmula bem formada.

# Lógica de Primeira Ordem - Gramática

*Fórmula* → *FórmulaAtómica*

- | *Fórmula Conectiva Fórmula*
- | *Quantificador Variável, ... Fórmula*
- | ‘ $\neg$ ’ *Fórmula*
- | ‘(’ *Fórmula* ’)’

*FórmulaAtómica* → *Predicado* ‘(’ *Termo* ‘,’ ... )’ | *Termo* ‘=’ *Termo*

*Termo* → *Função* ‘(’ *Termo* ‘,’ ... )’ | *Constante* | *Variável*

*Conectiva* → ‘ $\Rightarrow$ ’ | ‘ $\wedge$ ’ | ‘ $\vee$ ’ | ‘ $\Leftrightarrow$ ’

*Quantificador* → ‘ $\exists$ ’ | ‘ $\forall$ ’

*Constante* → A | X1 | Paula | ...

*Variável* → a | x | s | ...

*Predicado* → Portista | Cor | ...

*Função* → Registo | Mãe | ...

# Exemplos

- “Todos em Oxford são espertos”:
  - $\forall x \text{Estuda}(x, \text{Oxford}) \Rightarrow \text{Esperto}(x)$
  - Erro comum: Usar  $\wedge$  em vez de  $\Rightarrow$   
 $\forall x \text{Estuda}(x, \text{Oxford}) \wedge \text{Esperto}(x)$   
Significa “Todos estão em Oxford e todos são espertos”
- “Alguém em Oxford é esperto”:
  - $\exists x \text{Estuda}(x, \text{Oxford}) \wedge \text{Esperto}(x)$
  - Erro comum: Usar  $\Rightarrow$  em vez de  $\wedge$   
 $\exists x \text{Estuda}(x, \text{Oxford}) \Rightarrow \text{Esperto}(x)$   
qualquer estudante de outra universidade forneceria uma interpretação verdadeira.
- “Existe uma pessoa que gosta de toda a gente”
  - $\exists x \forall y \text{Gosta}(x, y)$

# Interpretações em Lógica Proposicional

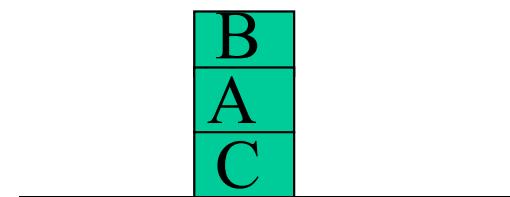
- Na lógica proposicional, uma interpretação de uma fórmula é uma atribuição de valores de verdade ou falsidade às várias proposições que nela ocorrem
  - Exemplo: a fórmula  $A \wedge B$  tem quatro interpretações possíveis.
- Satisfatibilidade - Uma interpretação satisfaz uma fórmula se a fórmula toma o valor ‘verdadeiro’ para essa interpretação.
- Modelo de uma fórmula - uma interpretação que satisfaz essa fórmula.
- Tautologia - uma fórmula cujo valor é ‘verdadeiro’ em qualquer interpretação.

# Interpretações em Lógica de Primeira Ordem

- Uma interpretação de uma fórmula em lógica de primeira ordem é o estabelecimento de uma correspondência entre as várias constantes que ocorrem na fórmula e os objectos do mundo, funções e relações que essas constantes representam.

– Exemplo:

- Objectos: A, B, C, Chão
- Funções: nenhuma
- Relações:
  - Em\_cima\_de: { <B,A>, <A,C>, <C,Chão> }
  - Livre: { <B> }
- Assumindo o estado dado pela figura, esta interpretação constitui um modelo



# Lógica - Regras de Substituição - I

- São válidas quer na lógica proposicional quer na lógica de primeira ordem
- Leis de DeMorgan

$$\neg(A \wedge B) \equiv \neg A \vee \neg B$$

$$\neg(A \vee B) \equiv \neg A \wedge \neg B$$

- Dupla negação:

$$\neg\neg A \equiv A$$

- Definição da implicação:

$$A \Rightarrow B \equiv \neg A \vee B$$

- Transposição:

$$A \Rightarrow B \equiv \neg B \Rightarrow \neg A$$

# Lógica - Regras de Substituição - II

- Comutação

$$A \wedge B \equiv B \wedge A$$

$$A \vee B \equiv B \vee A$$

- Associação:

$$(A \wedge B) \wedge C \equiv A \wedge (B \wedge C)$$

$$(A \vee B) \vee C \equiv A \vee (B \vee C)$$

- Distribuição:

$$A \wedge (B \vee C) \equiv (A \wedge B) \vee (A \wedge C)$$

$$A \vee (B \wedge C) \equiv (A \vee B) \wedge (A \vee C)$$

# Lógica - Regras de Substituição - III

- Leis de DeMorgan generalizadas (estas são específicas da lógica de primeira ordem):

$$\neg(\forall x P(x)) \equiv \exists x \neg P(x)$$

$$\neg(\exists x P(x)) \equiv \forall x \neg P(x)$$

1 -  $\exists_a C(a, H) \text{ and } Q_x x! = a \Rightarrow \neg C(x, H)$

2 -  $E_e \sim I(e, \text{ITA}) \vee \sim I(e, \text{SI})$

3 -  $\exists_m M_m(m, H) \text{ and } Q_m M_m(m, B) \Rightarrow m \in m$

4 -  $Q_p R(p) \Rightarrow G(p, R)$

5 -  $E_s S(s) \text{ and } Q_b B(b) \text{ and } \neg E(b) \rightarrow G(s, B)$  Tópicos de Inteligência Artificial

6 -  $E_b B(b) \text{ and } Q_x P(x) \text{ and } x! = b \Rightarrow BB(b, x)$



# Exercícios

- Representar as seguintes frases em lógica de primeira ordem:
  - Só um aluno chumbou a História
  - Nem todos os estudantes se inscreveram simultaneamente a *Introdução à Inteligência Artificial e Sistemas Inteligentes*
  - A melhor nota a História foi mais elevada do que a melhor nota a Biologia
  - Todos os Portistas gostam de Pinto da Costa
  - Existe um Sportinguista que gosta de todos os Benfiquistas que não são espertos
  - Existe um Barbeiro que barbeia toda a gente menos ele próprio

# CNF e Forma Clausal

- Uma fórmula na *forma normal conjuntiva* (abreviado *CNF*, de *Conjunctive Normal Form*) é uma fórmula que consiste de uma conjunção de cláusulas.
- Uma *cláusula* é uma fórmula que consiste de uma disjunção de literais.
- Um *literal* é uma fórmula atómica (literal positivo) ou a negação de uma fórmula atómica (literal negativo).
  - Nota: na lógica proposicional uma fórmula atómica é uma proposição.
- *Forma clausal* é a representação de uma fórmula CNF através do conjunto das respectivas cláusulas

# Conversão de uma Fórmula Proposicional para CNF e forma clausal

- Através dos seguintes passos:
  - Remover implicações
  - Reduzir o âmbito de aplicação das negações
  - Associar e distribuir até obter a forma CNF
- Exemplo:
  - Fórmula original:  $A \Rightarrow (B \wedge C)$
  - Após remoção de implicações:  $\neg A \vee (B \wedge C)$
  - Forma CNF:  $(\neg A \vee B) \wedge (\neg A \vee C)$
  - Forma clausal:  $\{ \neg A \vee B, \neg A \vee C \}$

# Conversão para forma clausal em Lógica de Primeira Ordem - I

- Renomear variáveis, de forma a que cada quantificador tenha uma variável diferentes
- Remover as implicações
- Reduzir o âmbito das negações, ou seja, aplicar a negação
- Para estas transformações, aplicar as regras de substituição já apresentadas

Exemplo

Fórmula original:

$$\forall x \forall y \neg(p(x,y) \Rightarrow \forall y q(y,y))$$

Variáveis renomeadas:

$$\forall a \forall b \neg(p(a,b) \Rightarrow \forall c q(c,c))$$

Implicações removidas:

$$\forall a \forall b \neg(\neg p(a,b) \vee \forall c q(c,c))$$

Negações aplicadas:

$$\forall a \forall b (p(a,b) \wedge \exists c \neg q(c,c))$$

# Conversão para forma clausal em Lógica de Primeira Ordem - II

- Skolemização
  - Nome dado à eliminação dos quantificadores existenciais
  - Substituir todas as ocorrências de cada variável quantificada existencialmente por uma função cujos argumentos são as variáveis dos quantificadores universais exteriores
- Remover quantificadores universais

## Exemplo (cont.)

Skolemizada aplicada:

$$\forall a \forall b ( p(a,b) \wedge \neg q(f(a,b), f(a,b)) )$$

Quantificadores removidos:

$$p(a,b) \wedge \neg q(f(a,b), f(a,b))$$

# Conversão para forma clausal em Lógica de Primeira Ordem - III

- Converter para CNF
  - Usar as regras de substituição relativas à comutação, associação e distribuição
- Converter para a forma clausal, ou seja, eliminar conjunções
- Renomear variáveis de forma a que uma variável não apareça em mais do que uma fórmula

Exemplo (cont.)

Convertida para a forma clausal:  
 $\{ p(a,b) , \neg q(f(a,b), f(a,b)) \}$

Variáveis renomeadas:

$$\{ p(a_1,b_1) , \neg q(f(a_2,b_2), f(a_2,b_2)) \}$$

# Lógica - Regras de Inferência

- Modus Ponens:  $\{ A, A \Rightarrow B \} \vdash B$
- Modus Tolens:  $\{\neg B, A \Rightarrow B\} \vdash \neg A$
- Sílogismo hipotético:  $\{A \Rightarrow B, B \Rightarrow C\} \vdash A \Rightarrow C\}$
- Conjunção:  $\{ A, B \} \vdash A \wedge B$
- Eliminação da conjunção:  $\{A \wedge B\} \vdash A$
- Disjunção:  $\{ A, B \} \vdash A \vee B$
- Sílogismo disjuntivo (ou resolução unitária):  
 $\{ A \vee B, \neg B \} \vdash A$
- Resolução:  $\{ A \vee B, \neg B \vee C \} \vdash A \vee C$
- Dilema construtivo:  
 $\{ (A \Rightarrow B) \wedge (C \Rightarrow D), A \vee C \} \vdash B \vee D$
- Dilema destrutivo:  
 $\{ (A \Rightarrow B) \wedge (C \Rightarrow D), \neg B \vee \neg D \} \vdash \neg A \vee \neg C$

# Lógica de Primeira Ordem

## - Regras de Inferência específicas

- *Instanciação universal:*  
 $\{\forall x P(x)\} \vdash P(A)$
- *Generalização existencial*  
 $\{P(A)\} \vdash \exists x P(x)$

# Consequências Lógicas, Provas

- Consequência lógica
  - Diz-se que  $A$  é consequência lógica do conjunto de fórmulas em  $\Delta$ , e escreve-se
$$\Delta \models A,$$
se  $A$  toma o valor ‘verdadeiro’ em todas as interpretações para as quais cada uma das fórmulas em  $\Delta$  toma também o valor verdadeiro.
- Definição de Prova
  - Uma sequência de fórmulas  $\{ A_1, A_2, \dots, A_n \}$  é uma prova (ou dedução) de  $A_n$  a partir de um conjunto de fórmulas  $\Delta$  sse cada uma das fórmulas  $A_i$  está em  $\Delta$  ou pode ser inferida a partir das fórmulas  $A_1 \dots A_{i-1}$ .
  - Neste caso escreve-se:  $\Delta \vdash A_n$

# Correcção, Completude

- Correcção - Diz-se que um conjunto de regras de inferência é correcto se todas as fórmulas que gera são consequências lógicas
- Completude - Diz-se que um conjunto de regras de inferência é completo se permite gerar todas as consequências lógicas.
- Um sistema de inferência correcto e completo permite tirar consequências lógicas sem ter que analisar caso a caso as várias interpretações.

# Metateoremas

- Teorema da dedução:
  - Se  $\{ A_1, A_2, \dots, A_n \} \models B$ , então  $A_1 \wedge A_2 \wedge \dots \wedge A_n \Rightarrow B$ , e vice-versa.
- Redução ao absurdo:
  - Se o conjunto de fórmulas  $\Delta$  é satisfatível (logo tem pelo menos um modelo) e  $\Delta \cup \{\neg A\}$  não é satisfatível, então  $\Delta \models A$ .

# Resolução não é Completa

- A resolução é uma regra de inferência correcta (gera fórmulas necessariamente verdadeiras)

$$\{ A \vee B, \neg B \vee C \} \vdash A \vee C$$

- A resolução não é completa.
  - Exemplo - A resolução não consegue derivar a seguinte consequência lógica:

$$\{ A \wedge B \} \models A \vee B$$

# Refutação por Resolução

- A refutação por resolução é um mecanismo de inferência completo
  - Neste caso, usa-se a resolução para provar que a negação da consequência lógica é inconsistente com a premissa (*metateorema da redução ao absurdo*).
  - No exemplo dado, prova-se que
$$(A \wedge B) \wedge \neg(A \vee B)$$
é inconsistente (basta mostrar que é possível derivar a fórmula ‘Falso’).
- Passos da refutação por resolução:
  - Converter a premissa e a negação da consequência lógica para um conjunto de cláusulas.
  - Aplicar a resolução até obter a cláusula vazia.

# Substituições, Unificação

- A aplicação da *substituição*  $s = \{ t_1/x_1, \dots, t_n/x_n \}$  a uma fórmula  $W$  denota-se  $SUBST(W,s)$  ou  $Ws$ ; Significa que todas as ocorrências das variáveis  $x_1, \dots, x_n$  em  $W$  são substituídas pelos termos  $t_1, \dots, t_n$
- Duas fórmulas  $A$  e  $B$  são unificáveis se existe uma substituição  $s$  tal que  $As = Bs$ . Nesse caso, diz-se que  $s$  é uma *substituição unificadora*.
- A *substituição unificadora mais geral* (ou *minimal*) é a mais simples (menos extensa) que permite a unificação.

# Resolução e Refutação na Lógica de Primeira Ordem

- Resolução:  
 $\{ A \vee B, \neg C \vee D \} \vdash \text{SUBST}(A \vee D, g)$   
em que B e C são unificáveis sendo g a sua substituição unificadora mais geral
- A regra da resolução é correcta
- A regra da resolução não é completa
- Tal como na lógica proposicional, também aqui a refutação por resolução é completa

# Resolução com Claúsulas de Horn

- O mecanismo de prova baseado na refutação por resolução é completo e correcto mas não é eficiente (na verdade é NP-completo)
- Uma cláusula de Horn é uma cláusula que tem no máximo um literal positivo
  - Exemplos:

$A$	$\neg A \vee B$
$\neg A \vee B \vee \neg C$	$\neg A \vee \neg B$
- Existem algoritmos de dedução baseados em cláusulas de Horn cuja complexidade temporal é linear
  - As linguagens Prolog e Mercury baseiam-se em cláusulas de Horn

# Representação do conhecimento

- Redes semânticas
  - Redes semânticas genéricas
  - Sistemas de “frames”
  - Herança e raciocínio não-monotônico
  - Relação com diagramas UML
  - Implementação em Python
- Lógica proposicional e lógica de primeira ordem
- Linguagem KIF
- Engenharia do conhecimento
- Ontologia geral
- Redes de Bayes

# KIF (= Knowledge Interchange Format)

- Esta é uma linguagem desenhada para representar o conhecimento trocado entre agentes.
  - A motivação para a criação do KIF é similar à que deu origem a outros formatos de representação, como o PostScript.
- Pode ser usada também para representar os modelos internos de cada agente.
- Características principais:
  - Semântica puramente declarativa (o Prolog é também uma linguagem declarativa, mas a semântica depende em parte do modelo de inferência)
  - Pode ser tão ou mais expressiva quanto a lógica de primeira ordem.
  - Permite a representação de meta-conhecimento (ou seja, conhecimento sobre o conhecimento)

# KIF – características gerais

- O mundo é conceptualizado em termos de objectos e relações entre objectos
- Uma relação é um conjunto arbitrário de listas de objectos.
  - Exemplo: a relação  $<$  é o conjunto de todos os pares  $(x,y)$  em que  $x < y$ .
- O universo de discurso é o conjunto de todos os objectos cuja existência é conhecida, presumida ou suposta.
  - Os objectos podem ser *concretos* ou *abstratos*
  - Os objectos podem ser *primitivos* (não decomponíveis) ou *compostos*

# KIF - Componentes da linguagem

- Caracteres
- Lexemas
  - Lexemas especiais (aqueles que têm um papel pré-definido na própria linguagem)
  - Palavras
  - Códigos de caracteres
  - Blocos de códigos de caracteres
  - Cadeias de caracteres
- Expressões
  - Termos - objectos primitivos ou compostos
  - Frases - expressões com valor lógico
  - Definições - frases verdadeiras por definição

# KIF - termos

- Constante
- Variável individual
- Expressão funcional
  - $(functor arg1 .. argn)$
  - $(functor arg1 .. argn seqvar)$
- Lista
  - $(listof t1 \dots tn)$
- Termo lógico
  - $(if c1 t1 .. cn tn default)$
- Código de caracter, bloco de códigos de caracteres e cadeia de caracteres
- Citação (quotation)
  - $(quote lista)$  ou ‘ $lista$

# KIF - frases

- Constante: true, false
- Equação  
 $(= termo1\ termo2)$
- Inequação  
 $(/=\ termo1\ termo2)$
- Frase relacional  
 $(relação\ t1 .. tn)$
- Frase lógica: construída com as conectivas lógicas ('not', 'and', 'or', ' $\Rightarrow$ ', ' $\Leftarrow$ ', ' $\Leftrightarrow$ ')
- Frase quantificada
  - $(\text{forall } var1 \dots varn\ frase)$
  - $(\text{exists } var1 \dots varn\ frase)$

# KIF - definições

- Definição de objectos
  - Igualdade: (defobject  $s := t$ )  
Exemplo: (defobject nil := (listof))
  - Conjunção: (defobject  $s p1 .. pn$ )
  - etc.
- Definição de funções
  - (deffunction  $f(v1 .. vn) := t$ )
  - Exemplo:
    - (deffunction head (?l) := (if (= (listof ?x @items) ?1) ?x))
- Definição de relações (=predicados)
  - (defrelation  $r(v1 .. vn) := p$ )
  - etc.
  - Exemplos:
    - (defrelation null (?1) := (= ?1 (listof)))
    - (defrelation list (?x) :=  
(exists (@1) (= ?x (listof (@1)))))

# KIF - meta-conhecimento

- Pode formalizar-se conhecimento sobre o conhecimento
- O mecanismo da citação (quotation) permite tratar expressões como objectos
- Por exemplo a ocorrência da palavra `joão` numa expressão designará uma pessoa; entretanto a expressão (`quote joão`) ou ‘`joão` designa a própria palavra `joão` e não o objecto ou pessoa a que ela se refere.
- Outros exemplos:  
`(acredita joão '(material lua queijo))`  
`(=> (acredita joão ?p) (acredita ana ?p))`
- Graficamente, podemos ilustrar da forma seguinte:



# KIF - dimensões de conformação

- KIF é uma linguagem altamente expressiva
- No entanto, KIF tende a sobrecarregar os sistemas de geração e de inferência
- Por isso, foram definidas várias dimensões de conformação
- Um perfil de conformação é uma selecção de níveis de conformação para cada uma das dimensões referidas

# KIF - perfis de conformação

- Foram definidos os seguintes perfis de conformação:
  - Lógica - atómica, conjuntiva, positiva, lógica, baseada em regras (de Horn ou não, recursivas ou não)
  - Complexidade dos termos - termos simples (constantes e variáveis), termos complexos
  - Ordem - *proporcional*, *primeira ordem* (contém variáveis, mas os functores e as relações são constantes), *ordem superior* (os functores e relações podem ser variáveis)
  - Quantificação - conforme se usa ou não
  - Meta-conhecimento - conforme se usa ou não

# Representação do conhecimento

- Redes semânticas
  - Redes semânticas genéricas
  - Sistemas de “frames”
  - Herança e raciocínio não-monotônico
  - Relação com diagramas UML
  - Implementação em Python
- Lógica proposicional e lógica de primeira ordem
- Linguagem KIF
- Engenharia do conhecimento
- Ontologia geral
- Redes de Bayes

# Engenharia do Conhecimento

- Uma *base de conhecimento* (BC) é um conjunto de representações de *factos* e *regras* de funcionamento do mundo; factos e regras recebem a designação genérica de *frases*.
- Engenharia do conhecimento é o processo ou actividade de construir bases de conhecimento. Isto envolve:
  - Estudar o domínio de aplicação – frequentemente através de entrevistas com peritos (processo de *aquisição de conhecimento*)
  - Determinar os objectos, conceitos e relações que será necessário representar
  - Escolher um vocabulário para entidades, funções e relações (por vezes chamado *ontologia*)
  - Codificar conhecimento genérico sobre o domínio (um conjunto de *axiomas*)
  - Codificar descrições para problemas concretos, interrogar o sistema e obter respostas.
  - Por vezes o domínio é tão complexo que não é praticável codificar à mão todo o conhecimento necessário. Neste caso usa-se *aprendizagem automática*.

# Identificação de objectos, conceitos e relações - 1

- Na modelação em análise de sistemas e engenharia de software coloca-se o mesmo problema
  - Assim, para um problema complexo de representação do conhecimento, não é descabido seguir uma metodologia de análise em boa parte similar às que se usam nos sistemas de informação
- Algumas das palavras que usamos para descrever um domínio em linguagem natural dão naturalmente origem a nomes de objectos, conceitos e relações
  - Substantivos comuns → *conceitos* (também chamados *classes* ou *tipos*)
  - Substantivos próprios → *objectos* (também chamados *instâncias*)
  - Verbo “ser” → pode indicar uma relação de *instanciação* (entre objecto e tipo) ou de *generalização* (entre subtipo e tipo)
  - Verbos “ter” e “conter” → podem indicar uma relação de composição
  - Outros verbos → podem sugerir outras relações relevantes

# Identificação de objectos, conceitos e relações - 2

- Convém avaliar a importância para o problema das palavras utilizadas bem como dos objectos, conceitos e relações subjacentes
  - Não considerar substantivos que identifiquem objectos, conceitos ou relações irrelevantes para o problema
  - Quando vários substantivos aparecem a referir-se ao mesmo conceito, escolher o mais representativo ou adequado
- Um conceito mais abstracto pode ser criado atribuindo-lhe o que é comum a outros dois ou mais conceitos previamente identificados

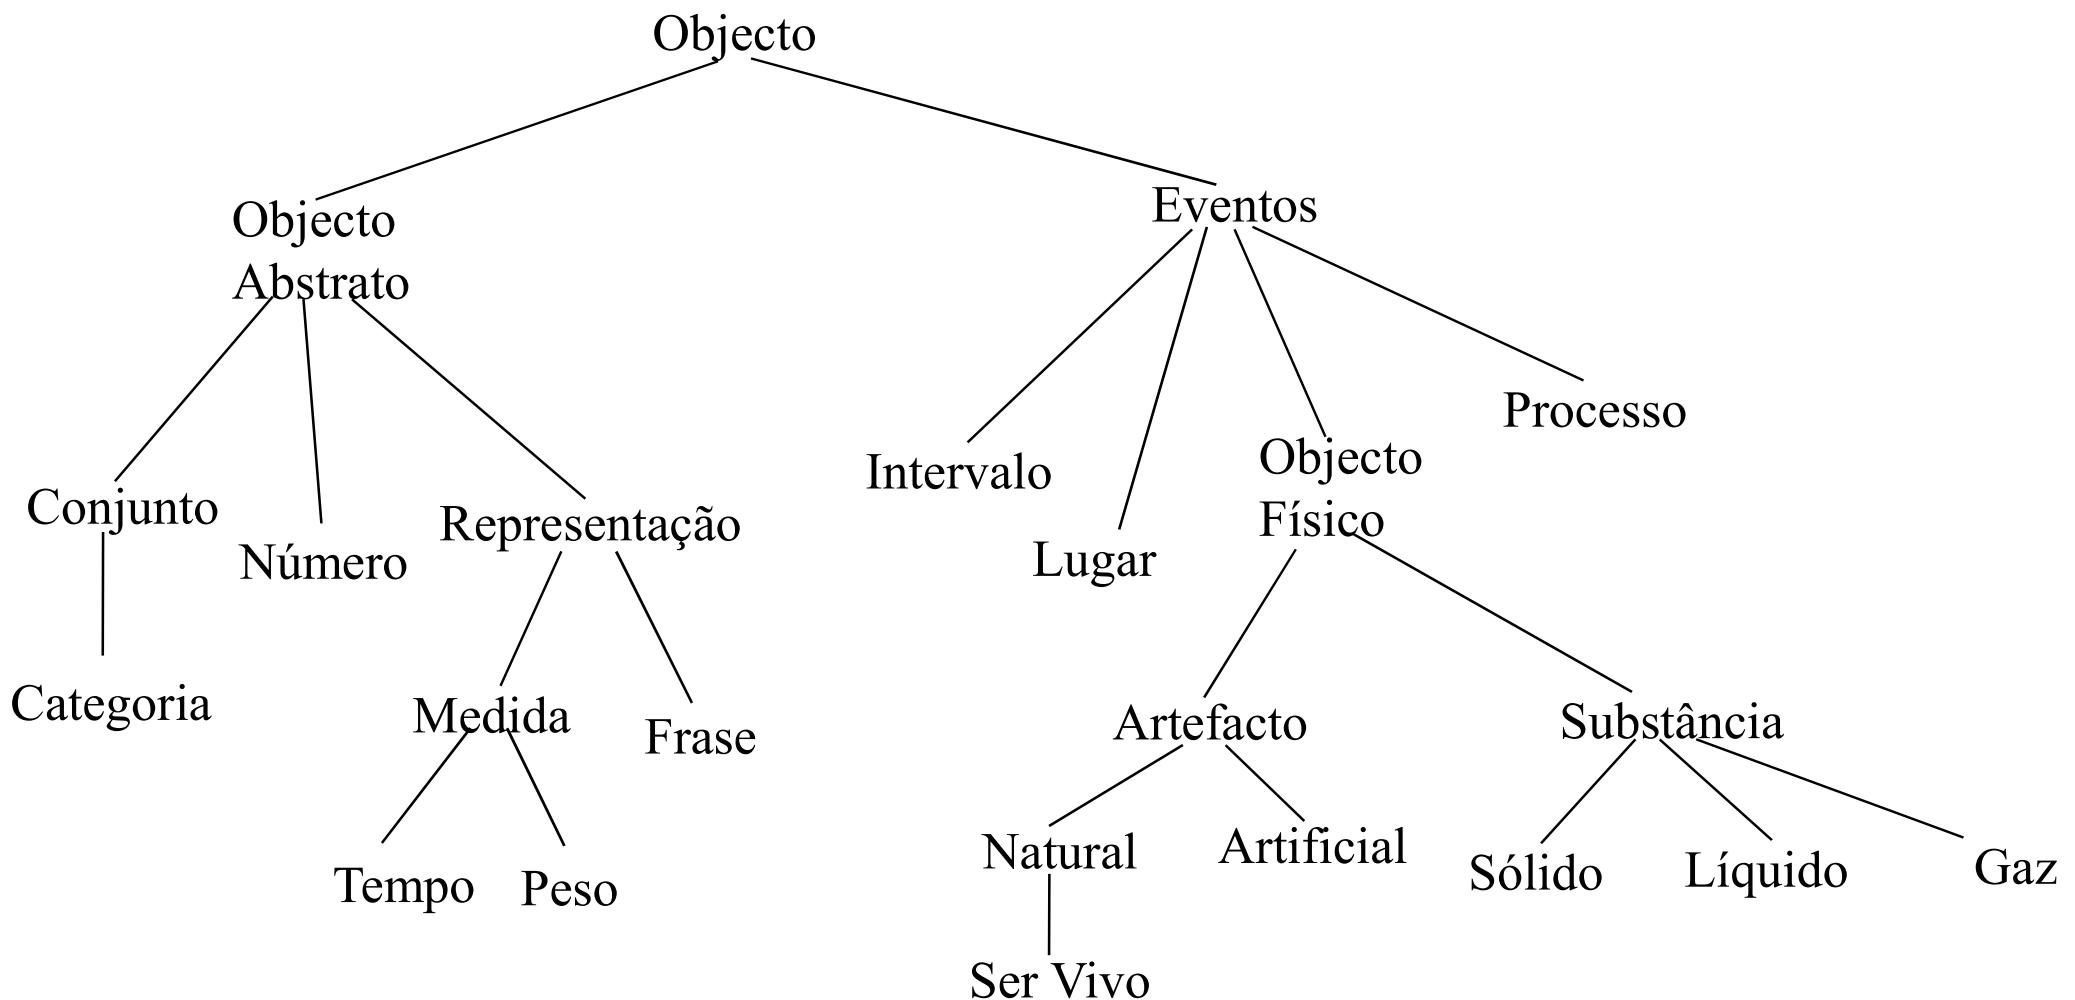
# Ontologias

- Uma ontologia é um vocabulário sobre um domínio conjugado com relações hierárquicas como *membro* e *subtipo* e eventualmente outras.
- O objectivo de uma ontologia é captar a essência da organização do conhecimento num domínio.

# Ontologia Geral

- Uma ontologia geral, aplicável a uma grande variedade de domínios de aplicação, envolve as seguintes noções:
  - Categorias, tipos ou classes
  - Medidas numéricas
  - Objectos compostos
  - Tempo, espaço e mudanças
  - Eventos e processos (eventos contínuos)
  - Objectos físicos
  - Substâncias
  - Objectos abstractos e crenças

# Uma possível ontologia geral



# Representação do conhecimento

- Redes semânticas
  - Redes semânticas genéricas
  - Sistemas de “frames”
  - Herança e raciocínio não-monotônico
  - Relação com diagramas UML
  - Implementação em Python
- Lógica proposicional e lógica de primeira ordem
- Linguagem KIF
- Engenharia do conhecimento
- Ontologia geral
- Redes de Bayes

# Redes de crença bayesianas

- Também conhecidas simplesmente como “redes de Bayes”
- Permitem representar conhecimento impreciso em termos de um conjunto de variáveis aleatórias e respectivas dependências
  - As dependências são expressas através de probabilidades condicionadas
  - A rede é um grafo dirigido acíclico

# Axiomas das probabilidades

- Para uma qualquer proposição  $a$ , a sua probabilidade é um valor entre 0 e 1:

$$0 \leq P(a) \leq 1$$

- Proposições necessariamente verdadeiras têm probabilidade 1

$$P(\text{true}) = 1$$

- Proposições necessariamente falsas têm probabilidade 0

$$P(\text{false}) = 0$$

- A probabilidade da disjunção é a soma das probabilidades subtraída da probabilidade da intercepção:

$$P(a \vee b) = P(a) + P(b) - P(a \wedge b)$$

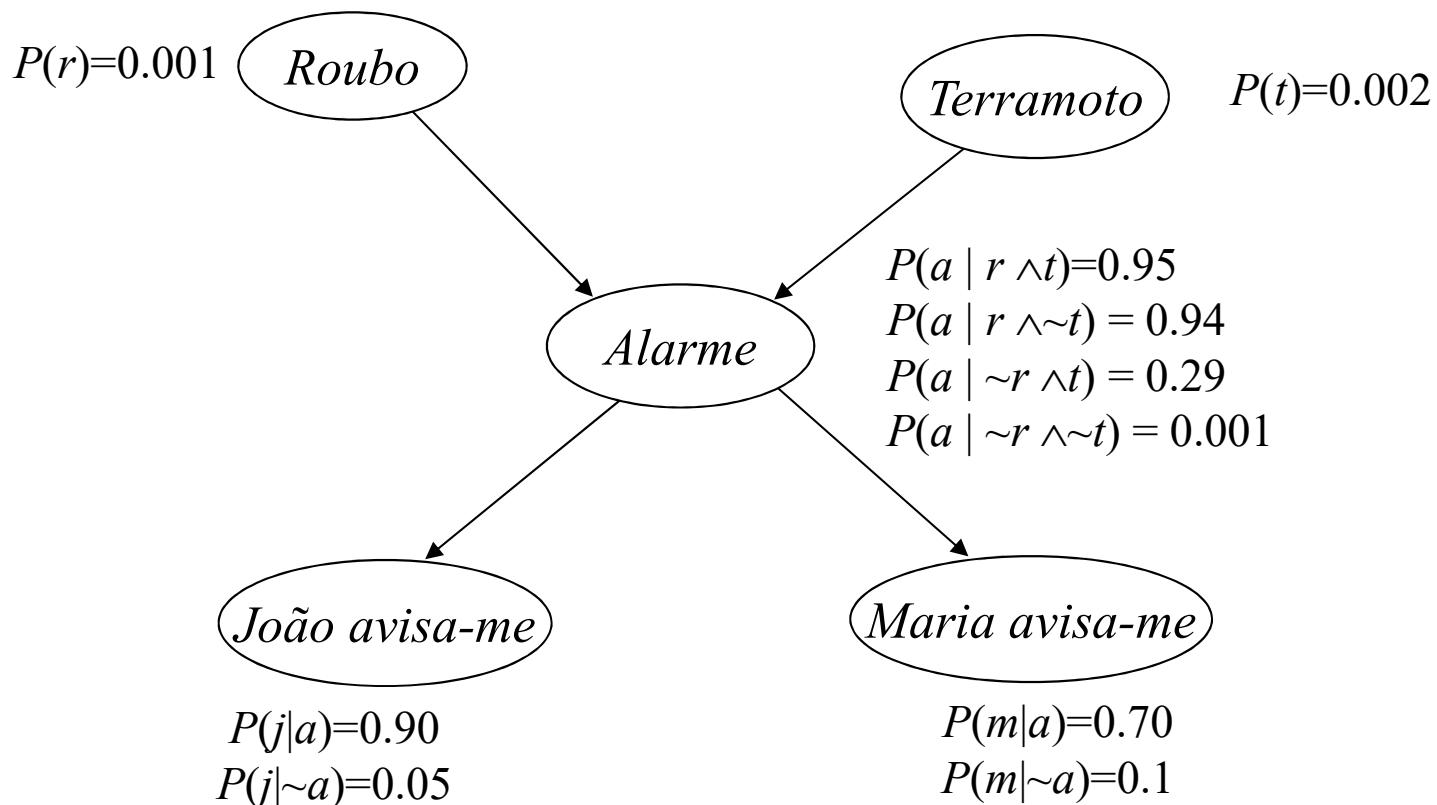
# Probabilidades condicionadas

- Uma probabilidade condicionada  $P(a|b)$  identifica a probabilidade de ser verdadeira a proposição  $a$  na condição de (isto é, sabendo nós que) a proposição  $b$  é verdadeira
- Pode calcular-se da seguinte forma:

$$P(a | b) = \frac{P(a \wedge b)}{P(b)}$$

# Redes de crença bayesianas – exemplo

- Por simplicidade, focamos em variáveis aleatórias booleanas:



# Redes de crença bayesianas – probabilidade conjunta

- A probabilidade conjunta identifica a probabilidade de ocorrer uma dada combinação de valores de todas as variáveis da rede:

$$P(x_1 \wedge \dots \wedge x_n) = \prod_{i=1}^n P(x_i | \text{pais}(x_i))$$

- Assim, no exemplo anterior, a probabilidade de o alarme tocar e o João e a Maria ambos avisarem num cenário em que não há roubo nem terramoto, é dada por:

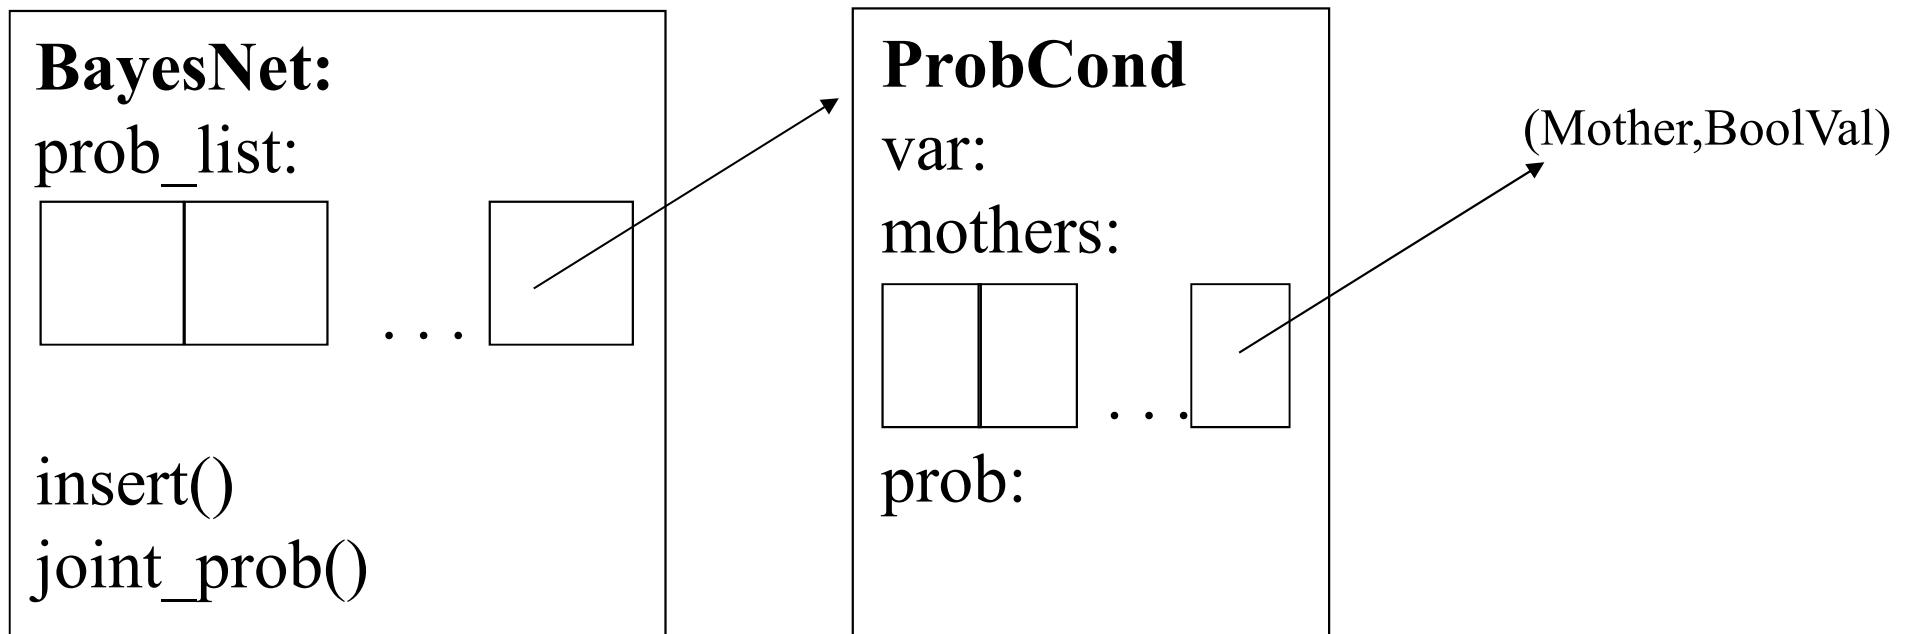
Ex

$$\begin{aligned} & P(j \wedge m \wedge a \wedge \neg t \wedge \neg r) \\ &= P(j | a) \times P(m | a) \times P(a | \neg r \wedge \neg t) \times P(\neg r) \times P(\neg t) \\ &= 0.90 \times 0.70 \times 0.001 \times 0.999 \times 0.998 \\ &= 0.000628 \end{aligned}$$

# Redes Bayesianas em Python

- Vamos criar uma rede de crença bayesiana, representada com base numa lista de probabilidades condicionadas
  - Classe `BayesNet()`
- A probabilidade condicionada de uma dada variável ser verdadeira, dados os valores (`True` ou `False`) das variáveis mães, é representado pela seguinte classe:
  - Classe `ProbCond(var,mother_vals,prob)`
  - Exemplo: `ProbCond("a", [ ("r",True), ("t",True) ], 0.95)`
- Operações principais:
  - `insert` – introduzir uma nova probabilidade condicionada na rede
  - `joint_prob` – obter a probabilidade conjunta para uma dada conjunção de valores de todas as variáveis da rede

# Redes de crença em Python



- Nota: ver módulo usado nas aulas práticas

# Redes de crença bayesianas – probabilidade individual

- A probabilidade individual é a probabilidade de um valor específico (*verdadeiro* ou *falso*) de uma variável
- Calcula-se somando as probabilidades conjuntas das situações em que essa variável tem esse valor específico
- O cálculo das probabilidades conjuntas pode restringir-se à variável considerada e às outras variáveis das quais depende (ascendentes na rede bayesiana)
  - Exemplo: o conjunto dos ascendentes de “João avisa” é {“alarme”, “roubo” e “terremoto”}

# Redes de crença bayesianas – probabilidade individual

$$P(x_i = v_i) = \sum_{\substack{a_j \in \{v, f\} \\ j=1, \dots, k}} P(x_i \wedge a_1 \wedge \dots \wedge a_k)$$

- Seja:
  - $C = \{x_1, \dots, x_n\}$  – conjunto de variáveis da rede
  - $x_i \in C$  – uma qualquer variável da rede
  - $v_i \in \{v, f\}$  – valor de  $x_i$  cuja probabilidade se pretende calcular
  - $\{a_1, \dots, a_k\} \subset C$  – conjunto das variáveis da rede que são ascendentes de  $x_i$

# Tópicos de Inteligência Artificial

- Agentes
- Representação do conhecimento
- Técnicas de resolução de problemas
  - Técnicas de pesquisa em árvore
  - Técnicas de pesquisa em grafo
  - Técnicas de pesquisa por melhorias sucessivas
  - Técnicas de pesquisa com propagação de restrições
  - Técnicas de planeamento

# Resolução de problemas em IA

- Um *problema* é algo (um objectivo) cuja solução não é imediata
- Por isso, a resolução de um problema requer a *pesquisa de uma solução*

# Resolução de problemas em IA

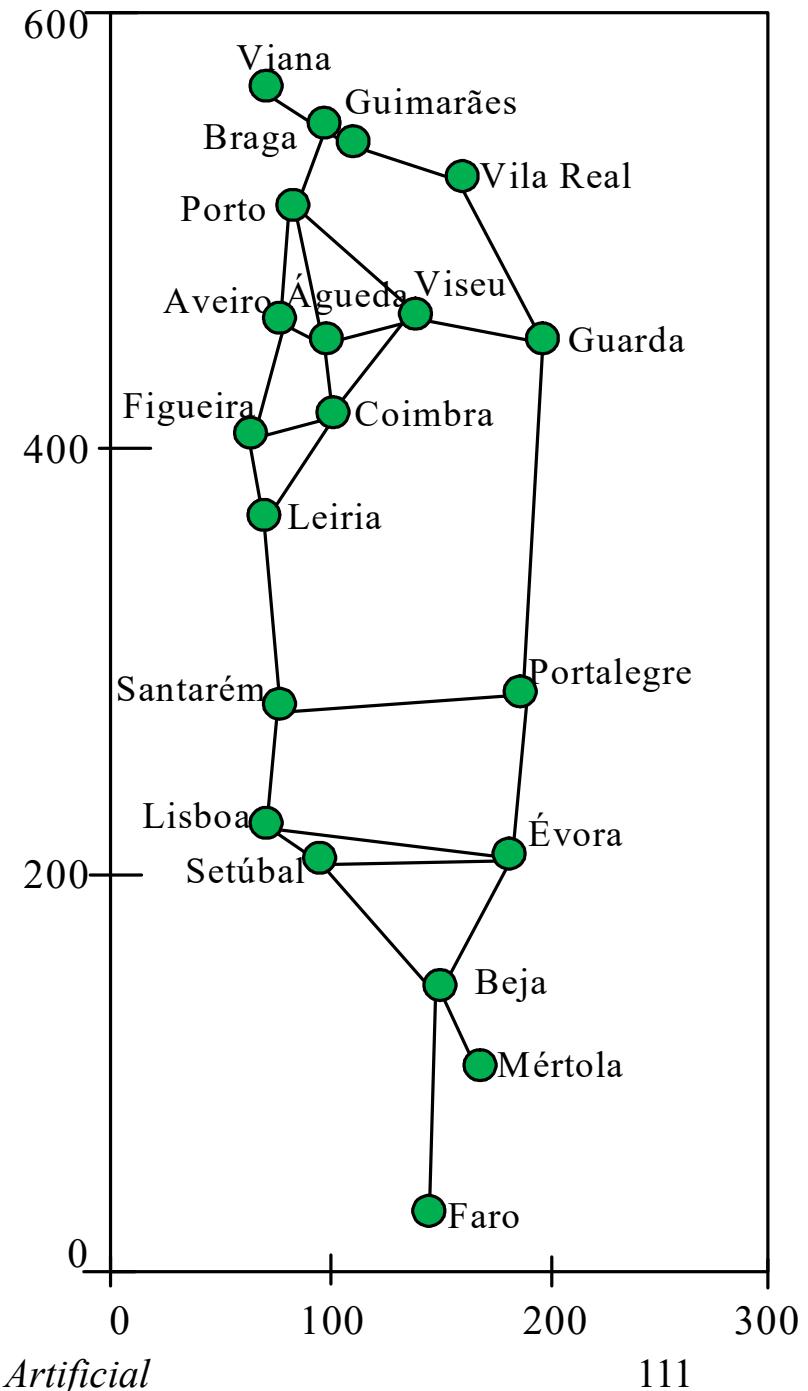
- Um *problema* é algo cuja solução não é imediata
- Exemplos de problemas:
  - Dado um conjunto de axiomas, demonstrar um novo teorema
  - Dado um mapa, determinar o melhor caminho entre dois pontos.
  - Dada uma situação num jogo de xadrez, determinar uma boa jogada.
  - Determinar a melhor distribuição das portas lógicas no circuito VLSI
  - Dada as peças de um produto a montar, determinar a melhor sequência de montagem.

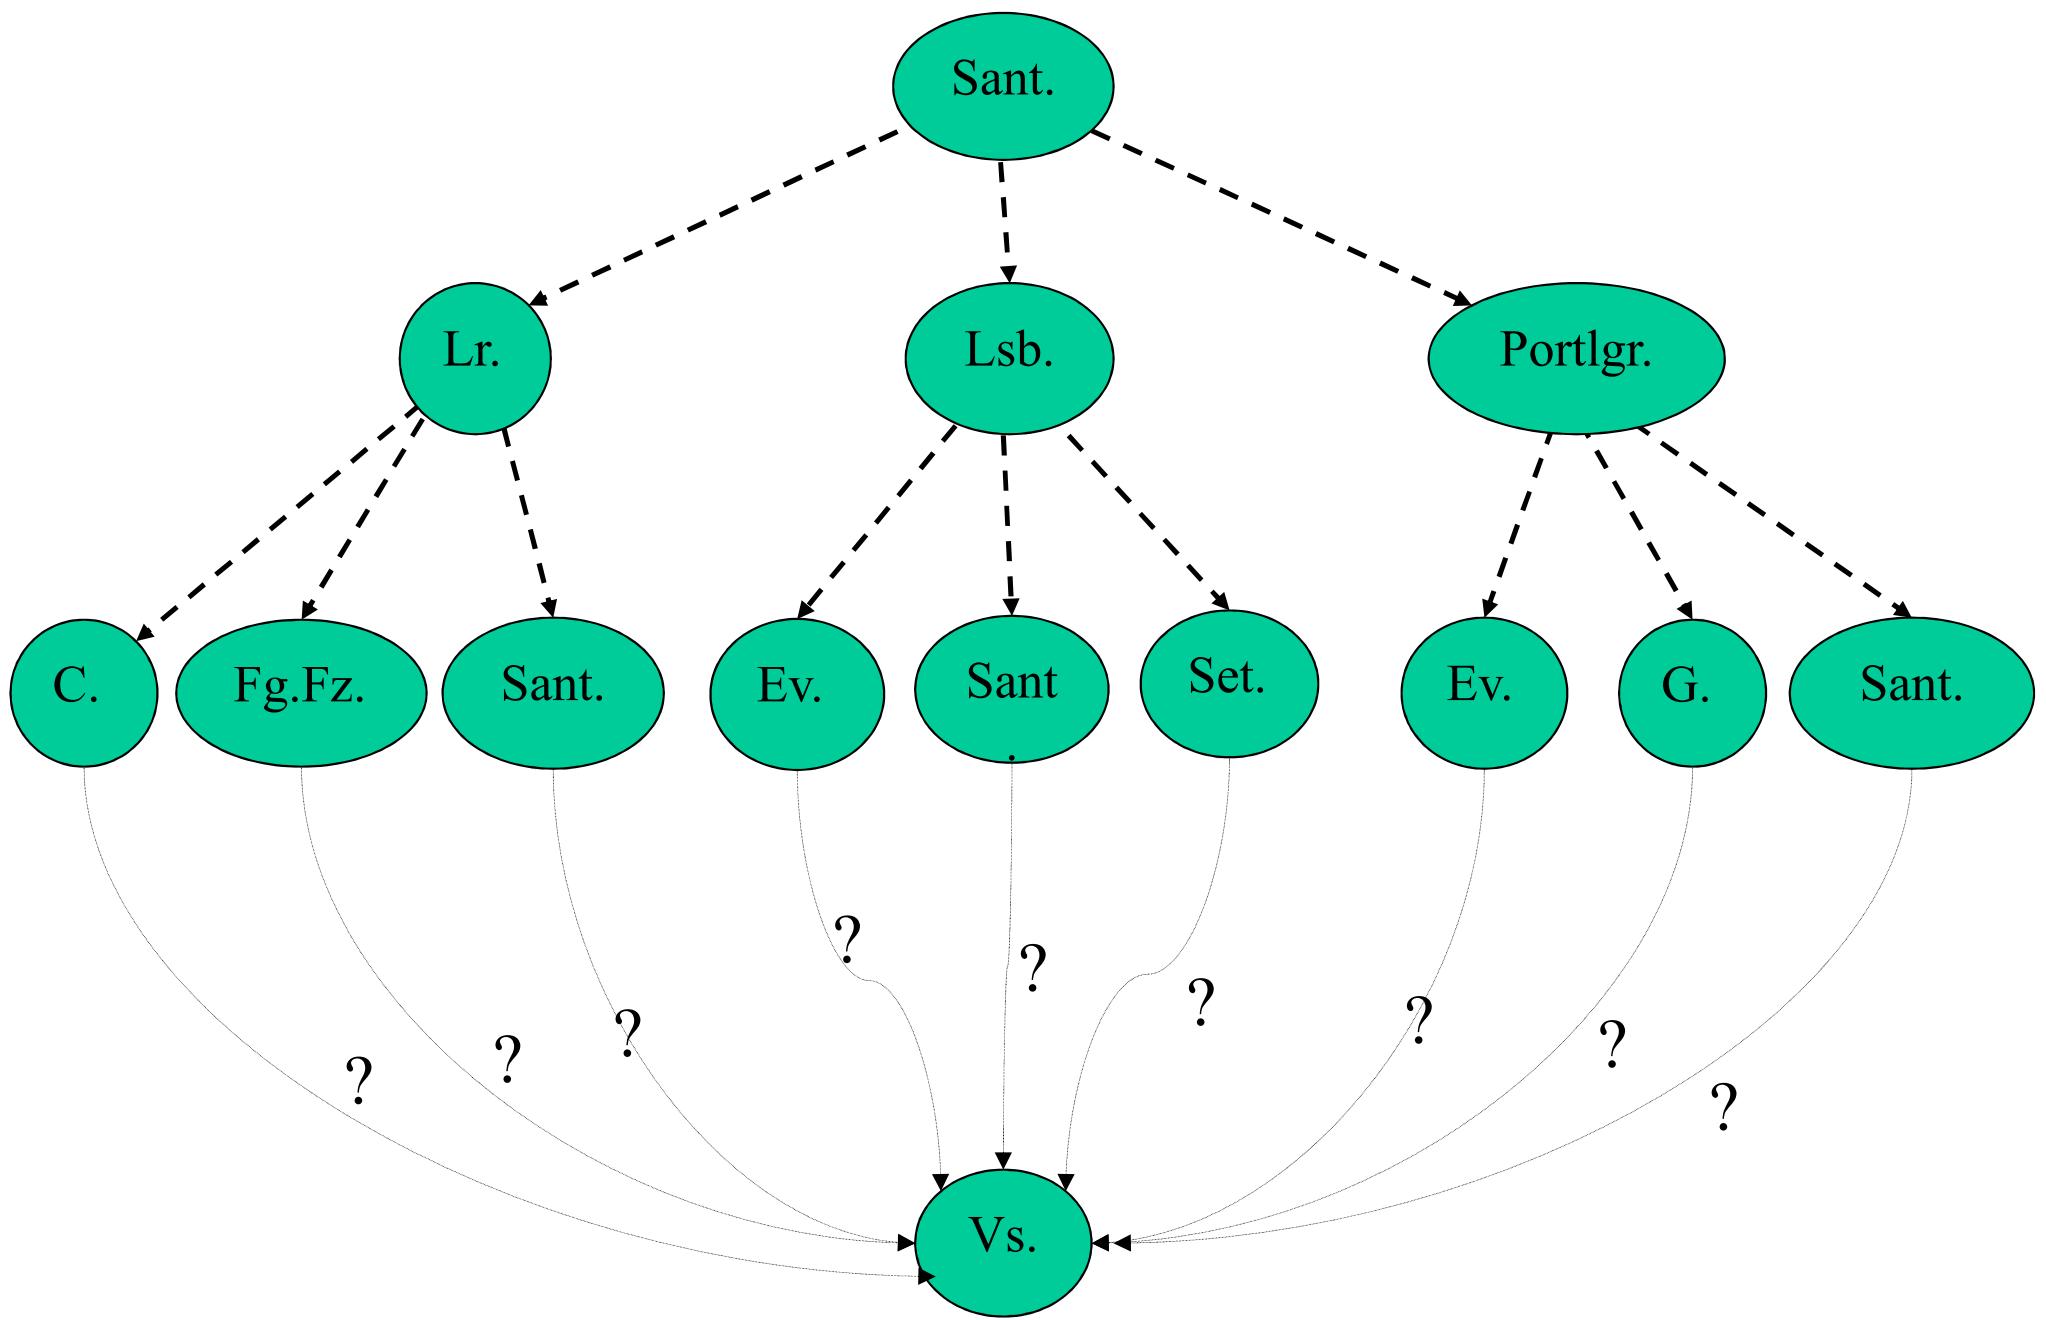
# Formulação de problemas e pesquisa de soluções

- A formulação de um problema inclui:
  - Descrição do ponto de partida – o estado inicial
  - Exemplos
    - A situação no jogo de xadrez
    - A descrição de um mapa e a localização inicial do viajante
  - Um conjunto de transições de estados
  - Um função que diz se um dado estado satisfaz o objectivo
  - Por vezes também uma função que avalia o custo de uma solução
- A pesquisa de uma solução é um processo que, de forma recursiva ou iterativa, vai executando transições de estados até que um estado gerado satisfaça o objectivo.

# Aplicação: determinar um percurso num mapa topológico

- Dados:
  - Distâncias por estrada entre cidades vizinhas
- Exemplo:
  - Determinar um caminho de Santarém para a Viseu





# Estratégias de pesquisa

- Pesquisa em árvore
  - Estratégias de pesquisa cega (não informada):
    - Em largura
    - Em profundidade
    - Em profundidade com limite
    - Em profundidade com limite crescente
  - Estratégias de pesquisa informada
    - Pesquisa A\* e suas variantes (custo uniforme, gulosa)
    - Advanced techniques (graph-search, IDA\*, RBFS, SMA\*)
- Pesquisa com propagação de restrições
- Pesquisa por melhorias sucessivas
- Planeamento

# Pesquisa em árvore – algoritmo genérico

`pesquisa(Problema,Estratégia) retorna a Solução, ou ‘falhou’`

`Árvore ← árvore de pesquisa inicializada com o estado inicial do Problema`

`Ciclo:`

`se não há candidatos para expansão, retornar ‘falhou’`

`Folha ← uma folha escolhida de acordo com Estratégia`

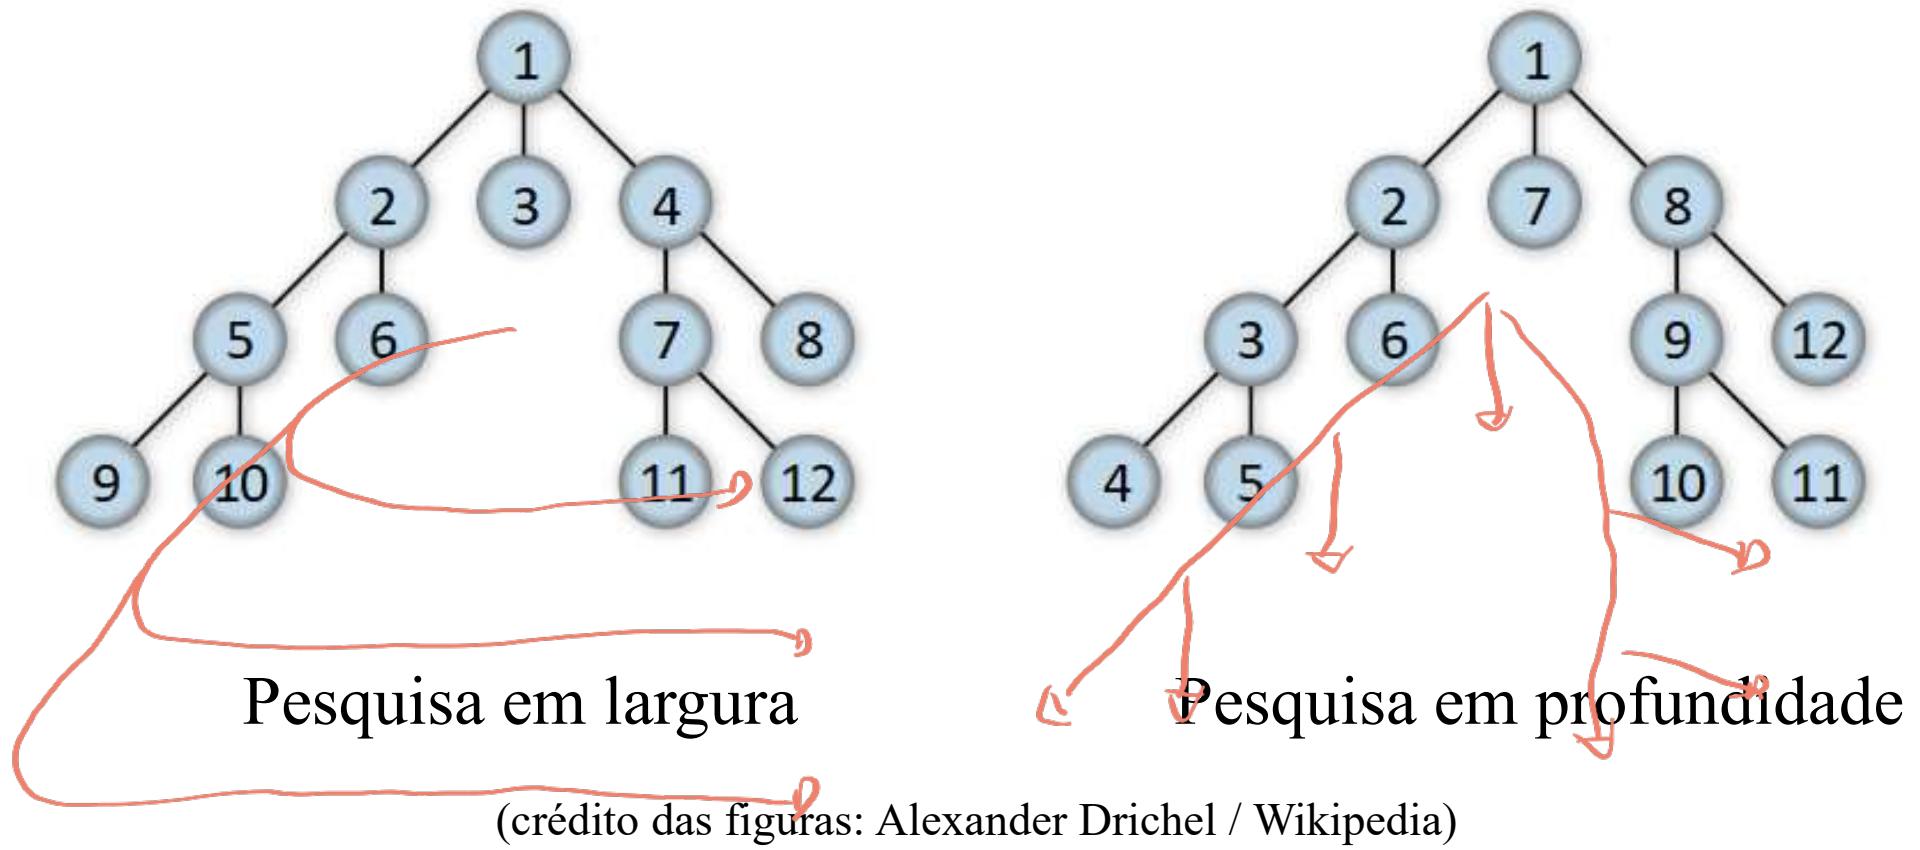
`se Folha contém um estado que satisfaz o objectivo`

`então retornar a Solução correspondente`

`senão expandir Folha e adicionar os nós resultantes à Árvore`

`Fim do ciclo;`

# Percursos na árvore de pesquisa



# Pesquisa em árvore – implementação baseada numa fila

`pesquisa_em_arvore(Problema, AdicionarFila) retorna a Solução, ou ‘falhou’`

`Fila ← [ fazer_nó(estado inicial do Problema) ]`

`Ciclo`

`se Fila está vazia, retornar ‘falhou’`

`Nó ← remover_cabeça(Fila)`

`se estado(Nó) satisfaz o objectivo`

`então retornar a solução(Nó)`

`senão Fila ← AdicionarFila(Fila, expansão(Nó))`

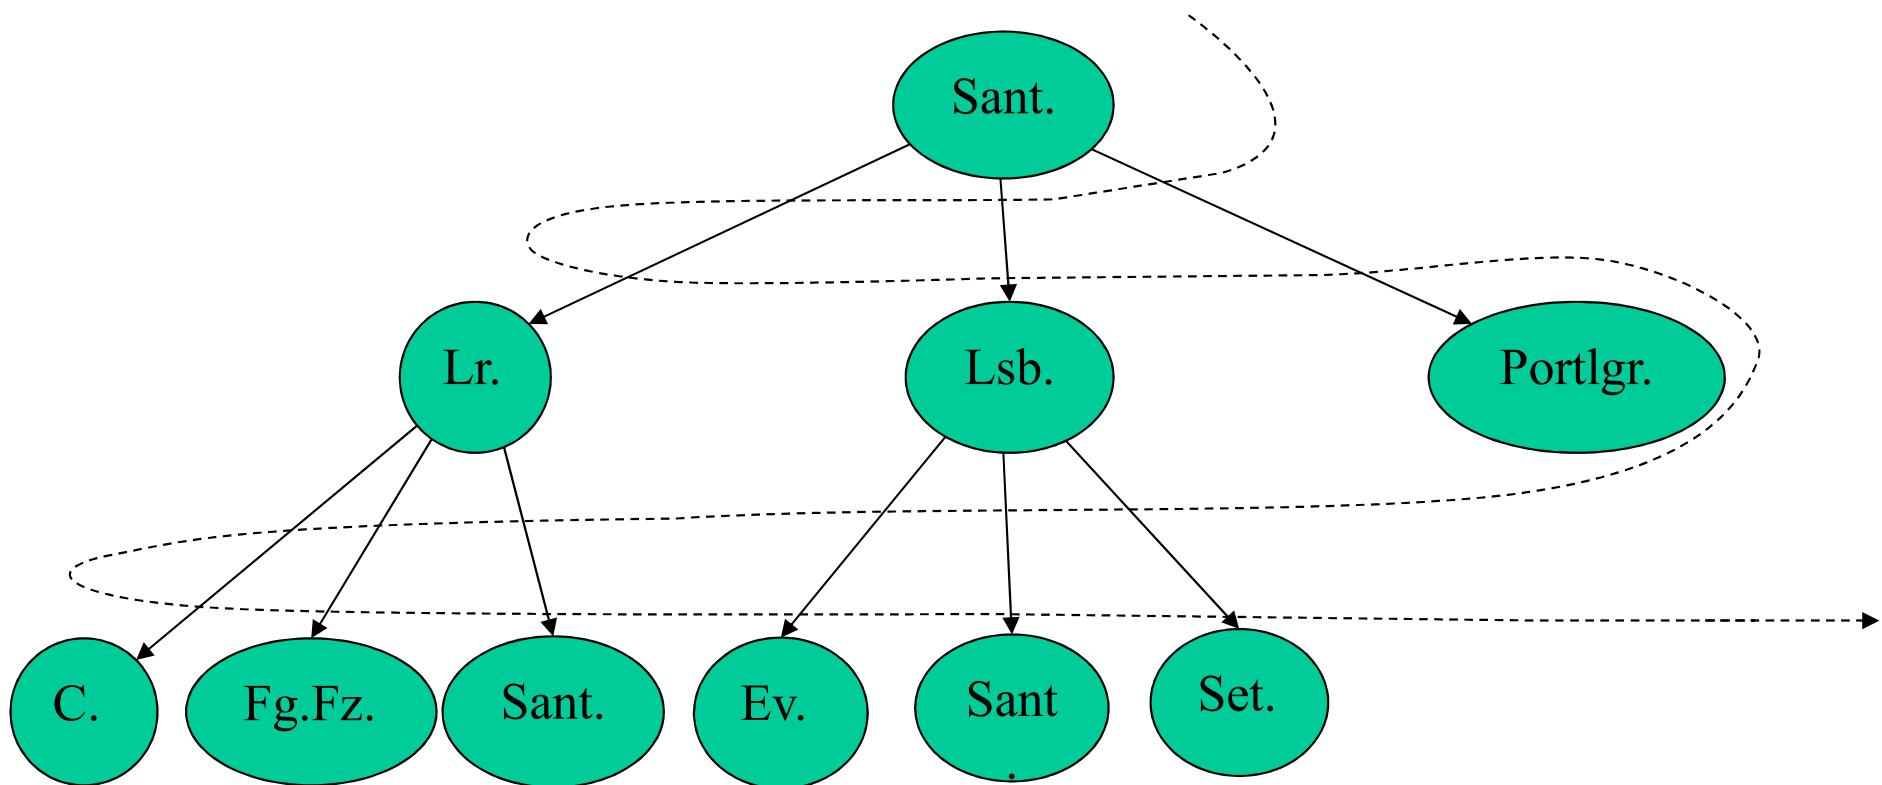
`pesquisa_em_largura(Problema) retorna a Solução, ou ‘falhou’`

`retornar pesquisa_em_arvore(Problema, juntar_no_fim)`

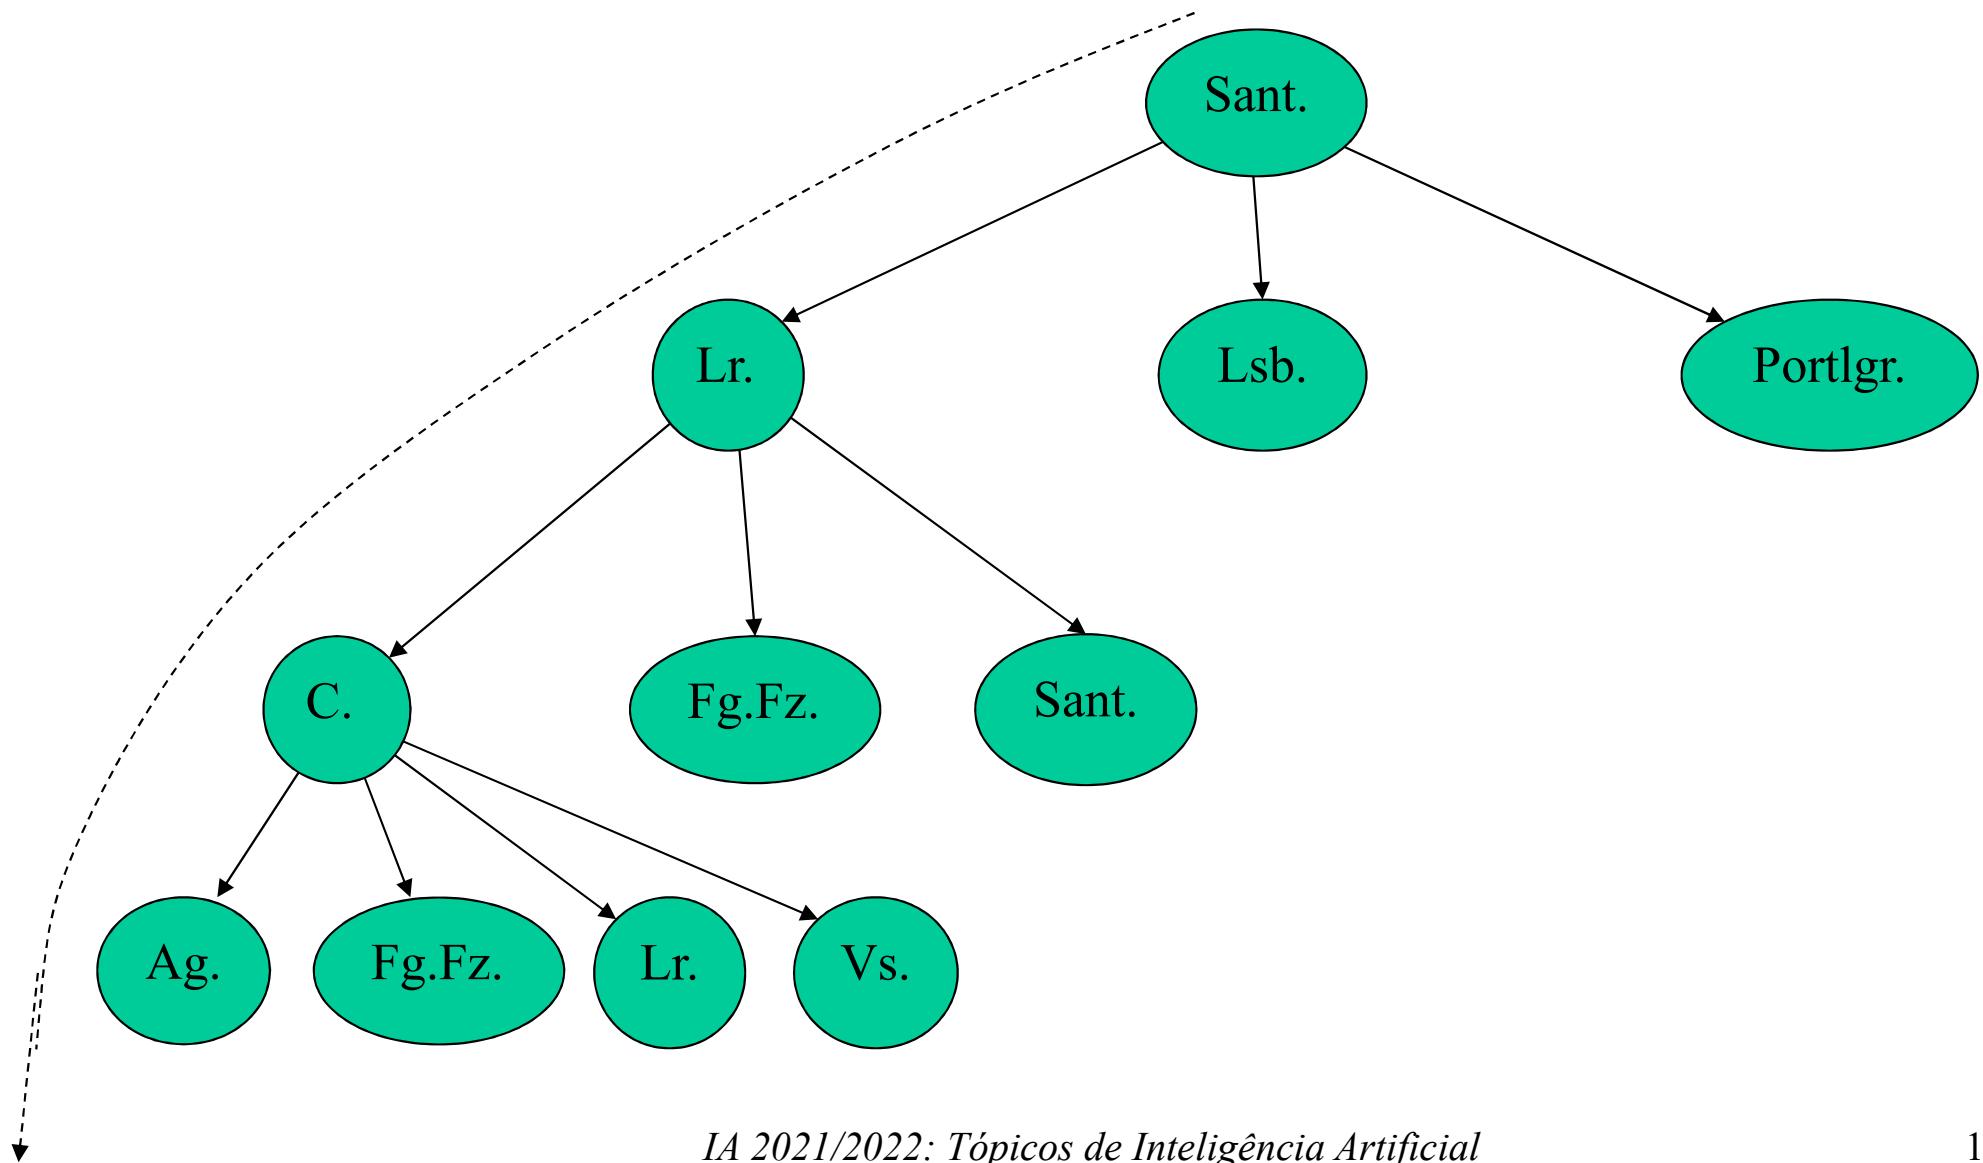
`pesquisa_em_profundidade(Problema) retorna a Solução, ou ‘falhou’`

`retornar pesquisa_em_arvore(Problema, juntar_à_cabeça)`

# Pesquisa em largura



# Pesquisa em profundidade



# Pesquisa em Árvore em Python

- Vamos criar um conjunto de classes para suporte à resolução de problemas por pesquisa em árvore
  - Classe **SearchDomain()** – classe abstracta que formata a estrutura de um domínio de aplicação
  - Classe **SearchProblem(domain,initial,goal)** – classe para especificação de problemas concretos a resolver
  - Classe **SearchNode(state,parent)** – classe dos nós da árvore de pesquisa
  - Classe **SearchTree(problem)** – classe das árvores de pesquisa, contendo métodos para a geração de uma árvore para um dado problema

# Pesquisa em Árvore em Python

**SearchTree:**  
problem:

**SearchProblem**  
domain:

**SearchDomain**  
*actions()*  
*result()*  
*cost()*  
*heuristic()*

initial:

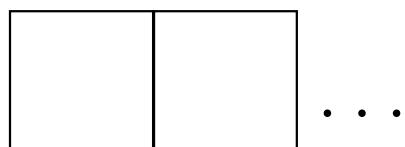
goal:

*test\_goal()*

strategy:

*search()*

open\_nodes:



- Nota: Ver módulo usado nas aulas práticas

**SearchNode**  
state:  
parent:

# Pesquisa em profundidade - variantes

- Pesquisa em profundidade *sem repetição de estados* – para evitar ciclos infinitos, convém garantir que estados já visitados no caminho que liga o nó actual à raiz da árvore de pesquisa não são novamente gerados.
- Pesquisa em profundidade *com limite* – não são considerados para expansão os nós da árvore de pesquisa cuja profundidade é igual a um dado limite.
- Pesquisa em profundidade *com limite crescente* – consiste no seguinte procedimento:
  - 1) Tenta-se resolver o problema por pesquisa em profundidade com um dado limite  $N$
  - 2) Se foi encontrada uma solução, retornar.
  - 3) Incrementar  $N$ .
  - 4) Voltar ao passo 1.

# Pesquisa informada (“melhor primeiro”)

`pesquisa_informada(Problema,FuncAval)` retorna a Solução, ou ‘falhou’

Estratégia  $\leftarrow$  estratégia de gestão de fila de acordo com FuncAval

`pesquisa_em_arvore(Problema,Estratégia)`

	Corsura	profundidade
completeness	Sim	Sim
complexidade temporal	$O(\exp(n))$	melhor caso : $O(n)$ pior caso : $O^{122}(\exp(n))$
complexidade espacial	IA 2021/2022: Tópicos de Inteligência Artificial	

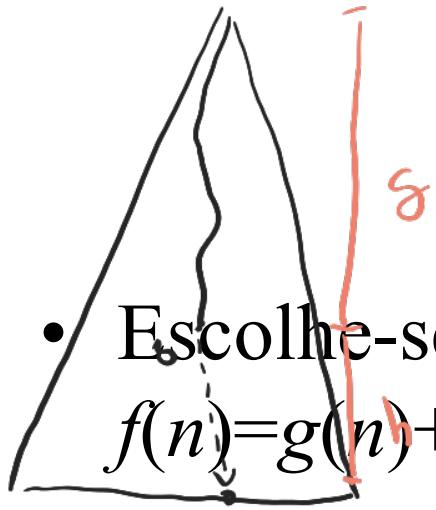
optimalidade

Comp → Sim  
custo → Não

Não

# Avaliação das estratégias de pesquisa

- Completude – uma estratégia é completa se é capaz de encontrar uma solução quando existe uma solução
- Complexidade temporal – quanto tempo demora a encontrar a solução
- Complexidade espacial – quanto espaço de memória é necessário para encontrar uma solução
- Optimalidade – a estratégia de pesquisa consegue encontrar melhor solução.

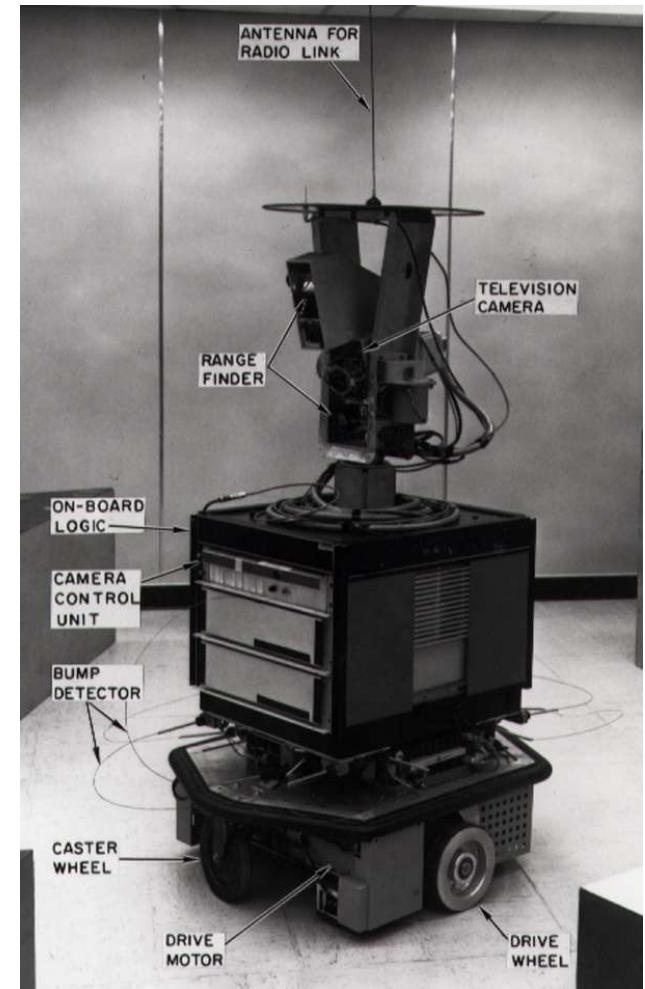


# Pesquisa A\*

- Escolhe-se o nó em que a função de custo total  $f(n)=g(n)+h(n)$  tem o menor valor
  - $g(n)$  = custo desde o nó inicial até ao nó  $n$
  - $h(n)$  = custo estimado desde o nó  $n$  até à solução [heurística]
- A função heurística  $h(n)$  diz-se *admissível* se nunca sobrestima o custo real de chegar a uma solução ~~atômica~~ óptima partindo de  $n$ .
- Se for possível garantir que  $h(n)$  é admissível, então a pesquisa A\* encontra sempre (um)a solução óptima.
- A pesquisa A\* é também completa.

# Shakey the Robot

- A pesquisa A\* foi inventada em 1968 para optimizar o planeamento de caminhos deste robô



# Pesquisa A\* - variantes

- *Pesquisa de custo uniforme*

- $h(n) = 0$
- $f(n) = g(n)$
- É um caso particular da pesquisa A\*
- Também conhecido como algoritmo de Dijkstra
- Tem um comportamento parecido com o da pesquisa em largura
- Caso exista solução, a primeira solução encontrada é óptima

- *Pesquisa gulosa*

- Ignora custo acumulado  $g(n)$
- $f(n) = h(n)$
- Dado que o custo acumulado é ignorado, não é verdadeiramente um caso particular da pesquisa A\*
- Tem um comportamento que se aproxima da pesquisa em profundidade
- Ao ignorar o custo acumulado, facilmente deixa escapar a solução óptima

# Pesquisa num grafo de estados - motivação

- Em inglês: “*graph search*”
- Frequentemente, o espaço de estados é um grafo.
- Ou seja, transições a partir de diferentes estados podem levar ao mesmo estado.
- Isto leva a que a pesquisa fique menos eficiente.
- Portanto, o que se deve fazer é memorizar os estados já visitados por forma a evitar tratá-los novamente.
- Memoriza-se apenas o melhor caminho até cada estado

# Pesquisa num grafo de estados

- Tal como no algoritmo anterior, trabalha-se com uma fila de nós
  - Chama-se fila de nós ABERTOS (nós ainda não expandidos, ou folhas)
  - Em cada iteração, o primeiro nó em ABERTOS é seleccionado para expansão
- Adicionalmente, usa-se também uma lista de nós FECHADOS (os já expandidos)
  - Necessário para evitar repetições de estados

# Pesquisa num grafo de estados - algoritmo

- 1. Inicialização
  - $N_0 \leftarrow$  nó do estado inicial;  $ABERTOS \leftarrow \{ N_0 \}$
  - $FECHADOS \leftarrow \{ \}$
- 2. Se  $ABERTOS = \{ \}$ , então acaba sem sucesso.
- 3. Seja  $N$  o primeiro nó de  $ABERTOS$ .
  - Retirar  $N$  de  $ABERTOS$ .
  - Colocar  $N$  em  $FECHADOS$ .
- 4. Se  $N$  satisfaz o objectivo, então retornar a solução encontrada.
- 5. Expandir  $N$ :
  - $CV \leftarrow$  conjunto dos vizinhos sucessores de  $N$
  - Para cada  $X \in CV - (ABERTOS \cup FECHADOS)$ , ligá-lo ao antecessor directo,  $N$
  - Para cada  $X \in CV \cap (ABERTOS \cup FECHADOS)$ , ligá-lo a  $N$  caso o melhor caminho passe por  $N$
  - Adicionar os novos nós a  $ABERTOS$
  - Reordenar  $ABERTOS$
- 6. Voltar ao passo 2.

# Pesquisa num grafo de estados

- Tal como a pesquisa em árvore, a “pesquisa em grafo” ou “graph search” utiliza uma árvore de pesquisa
- No entanto, a pesquisa em árvore normal ignora a possibilidade de o espaço de estados ser um grafo
  - Mesmo que o espaço de estados seja um grafo, a pesquisa em árvore trata-o como se fosse uma árvore
- Pelo contrário, a pesquisa em grafo leva em conta que o espaço de estados é normalmente um grafo e garante que a árvore de pesquisa não tem mais do que um caminho para cada estado

# Avaliação da pesquisa em árvore

## - factores de ramificação

- Seja:
  - N – número de nós da árvore de pesquisa no momento em que se encontra a solução
  - X – Número de nós expandidos (não terminais)
  - d – comprimento do caminho na árvore correspondente à solução
- *Ramificação média* – número médio de filhos por nó expandido:

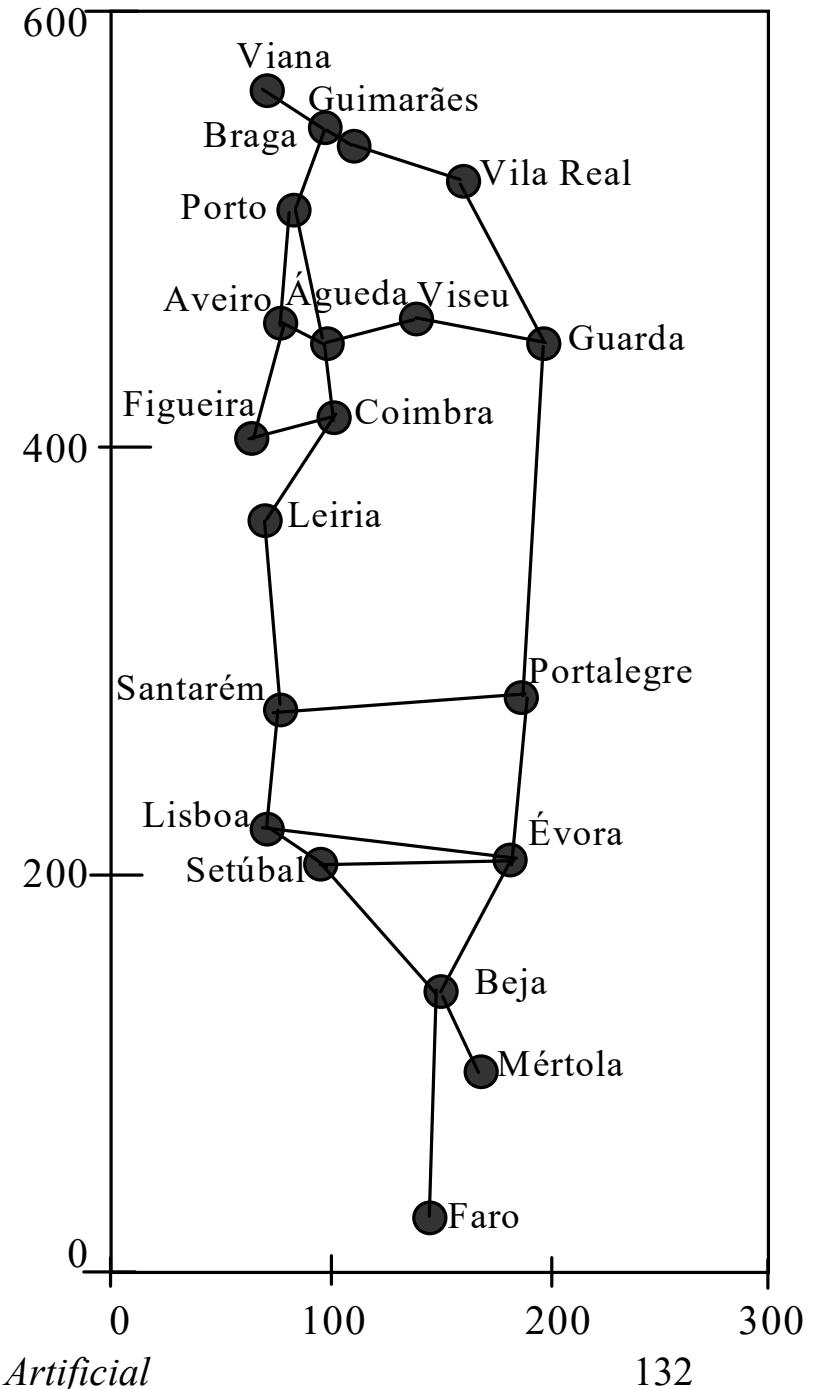
$$RM = \frac{N - 1}{X}$$

Nota: a ramificação média é um indicador da dificuldade do problema.

- *Factor de ramificação efectivo* – número de filhos por nó, B, numa árvore com ramificação constante e com profundidade constante  $d$ . Portanto:  
 $1 + B + B^2 + \dots + B^d = N$  ou seja:  $\frac{B^{d+1} - 1}{B - 1} = N$  (resolve-se por métodos numéricos).
  - O factor de ramificação efectiva é um indicador da eficiência da técnica de pesquisa utilizada.

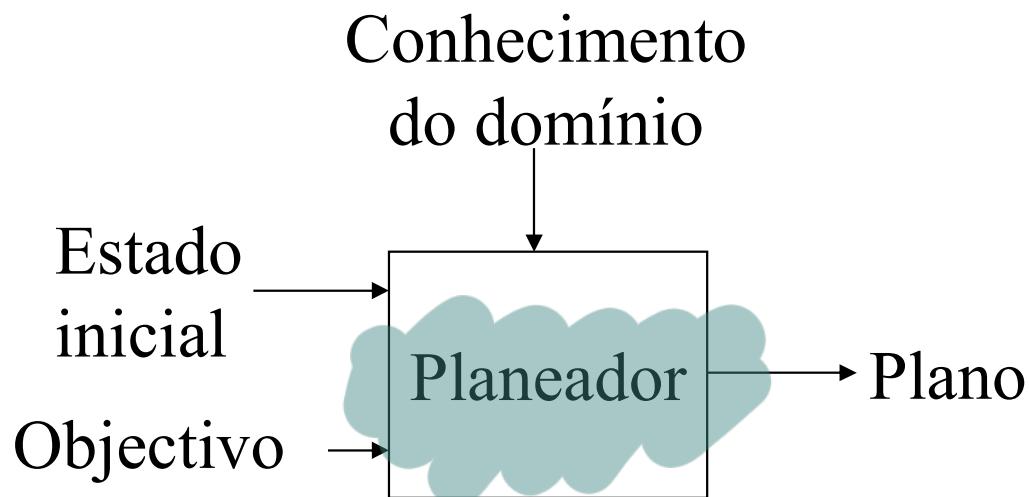
# Aplicação: planear um passeio turístico

- Dados:
  - Coordenadas entre cidades
  - Distâncias por estrada entre cidades vizinhas
- Calcular:
  - O melhor caminho entre duas cidades.
- Usando:
  - Pesquisa em largura
  - Pesquisa A\*



# Aplicação: planeamento de sequências de acções

- O problema consiste em determinar uma sequência de acções a desempenhar por um agente por forma a que, partindo de um dado *estado inicial*, se atinja um dado *objectivo*.
- O *conhecimento do domínio* inclui uma descrição das *condições de aplicabilidade* e *efeitos* das acções possíveis.

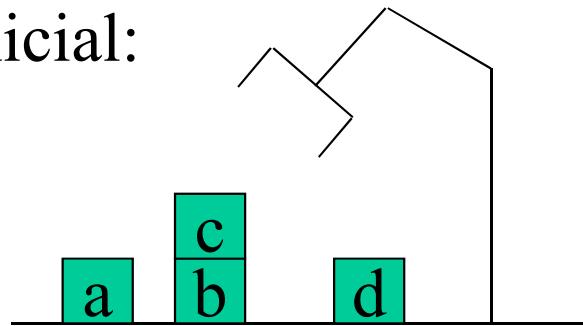


# Representação de acções em problemas de planeamento

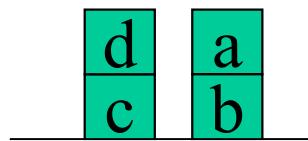
- STRIPS – planeador desenvolvido por volta de 1970, por Fikes, Hart e Nilsson
- A funcionalidade de um dado tipo de operação é definida, no formalismo STRIPS, através de uma estrutura chamada *operador*, que inclui a seguinte informação:
  - *Pré-condições* - um conjunto de fórmulas atómicas que representam as condições de aplicabilidade deste tipo de operação.
  - *Efeitos negativos (delete list)* – um conjunto de fórmulas atómicas que representam propriedades do mundo que deixam de ser verdade ao executar-se a operação.
  - *Efeitos positivos (add list)* – um conjunto de fórmulas atómicas que representam propriedades do mundo que passam a ser verdade ao executar-se a operação.

# Exemplo: planeamento no mundo dos blocos

Estado inicial:



Objectivo:



Plano:  
[ desempilhar(c,b),  
poisar(c),  
levantar(d),  
empilhar(d,c),  
levantar(a),  
empilhar(a,b) ]

Especificação de acções. Exemplo: empilhar(X,Y)

- Pré-condições: [ no\_robot(X), livre(Y) ]
- Efeitos negativos: [ no\_robot(X), livre(Y) ]
- Efeitos positivos: [ em\_cima(X,Y), robot\_livre ]

# Pesquisa A\* - heurísticas

- Uma heurística é tanto melhor quanto mais se aproximar do custo real
  - A qualidade de uma heurística pode ser medida através do factor de ramificação efectiva
  - Quanto melhor a heurística, mais baixo será esse factor
- Em alguns domínios, há funções de estimação de custos que naturalmente constituem heurísticas admissíveis
  - Exemplo: Distância em linha recta no domínio dos caminhos entre cidades
- Em muitos outros domínios práticos, não há uma heurística admissível que seja óbvia
  - Exemplo: Planeamento no mundo dos blocos

# Pesquisa A\* - cálculo de heurísticas admissíveis em problemas simplificados

- Um problema simplificado (*relaxed problem*) é um problema com menos restrições do que o problema original
  - É possível gerar automaticamente formulações simplificadas de problemas a partir da formulação original
  - A resolução do problema simplificado será feita usando pouca ou nenhuma pesquisa
  - Pode-se assim “inventar” heurísticas, escolhendo a melhor, ou combinando-as numa nova heurística
- IMPORTANTE: O custo de uma solução óptima para um problema simplificado constitui uma heurística admissível para o problema original

# Pesquisa A\* - combinação de heurísticas

- Se tivermos várias heurísticas admissíveis ( $h_1, \dots, h_n$ ), podemos combiná-las numa nova heurística:
  - $H(n) = \max(\{h_1(n), \dots, h_n(n)\})$
- Esta nova heurística tem as seguintes propriedades:
  - Admissível
  - Dado que é uma melhor aproximação ao custo real, vai ser uma heurística melhor do que qualquer das outras

# Pesquisa A\* em aplicações práticas

- Principais vantagens
  - Completa
  - Óptima
- Principais desvantagens
  - Na maior parte das aplicações, o consumo de memória e tempo de computação têm um comportamento exponencial em função do tamanho da solução
  - Em problemas mais complexos, poderá ser preciso utilizar algoritmos mais eficientes, ainda que sacrificando a optimalidade
  - Ou então, usar heurísticas com uma melhor aproximação média ao custo real, ainda que não sendo estritamente admissíveis, e não garantindo portanto a optimalidade da pesquisa

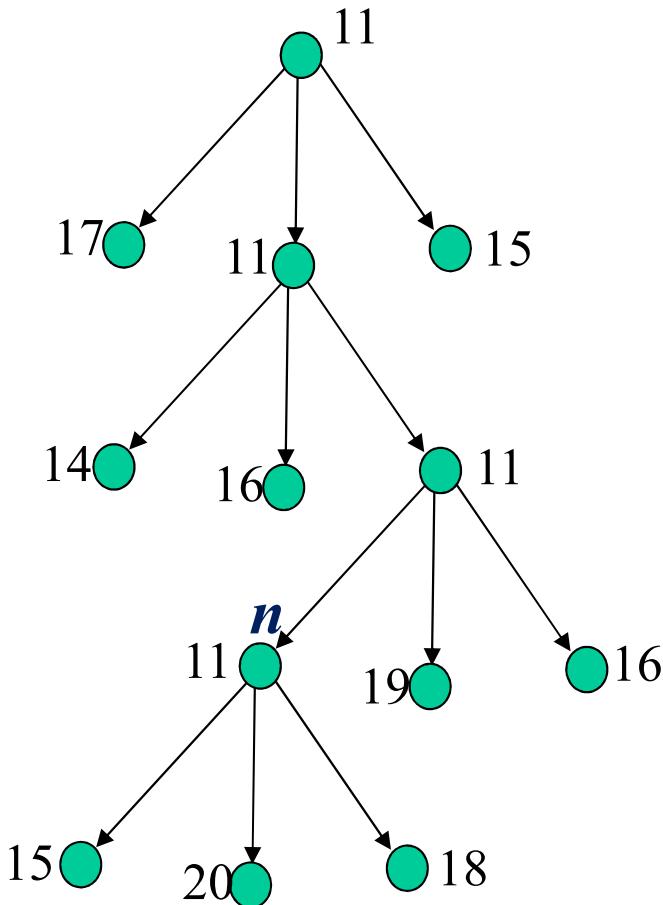
# IDA\*

- Semelhante à pesquisa em profundidade com aprofundamento iterativo
- A limitação à profundidade é estabelecida indirectamente através de um limite na função de avaliação  $f(n) = g(n) + h(n) \leq f_{max}$ 
  - Ou seja: Qualquer nó  $n$  com  $f(n) > f_{max}$  não será expandido
- Passos do algoritmo:
  1.  $f_{max} = f(\text{raiz})$
  2. Executar pesquisa em profundidade com limite  $f_{max}$
  3. Se encontrou solução, retornar solução encontrada
  4.  $f_{max} \leftarrow$  menor  $f(n)$  que tenha sido superior a  $f_{max}$  na última execução do A\*
  5. Voltar ao passo 2

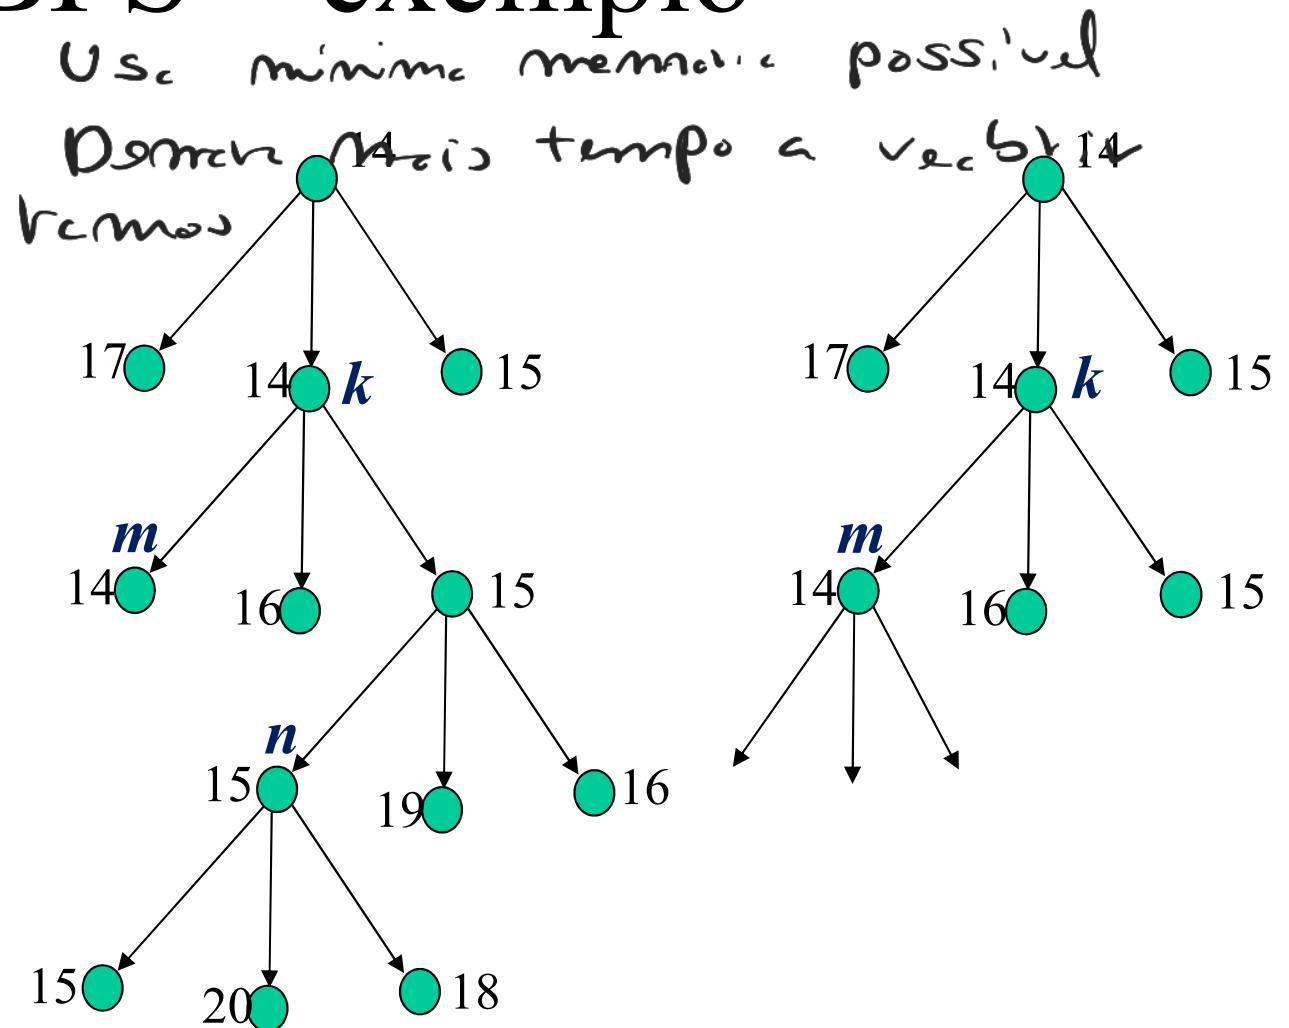
# RBFS

- Pesquisa recursiva melhor-primeiro (*Recursive Best-First Search*)
- Para cada nó  $n$ , o algoritmo não guarda o valor da função de avaliação  $f(n)$ , mas sim o menor valor  $f(x)$ , sendo  $x$  uma folha descendente do nó  $n$ 
  - Sempre que um nó é expandido, os custos armazenados nos ascendentes são actualizados
- Funciona como pesquisa em profundidade com retrocesso
  - Quando a folha  $m$  com menor custo  $f(m)$  não é filha do último nó expandido  $n$ , então o algoritmo retrocede até ao ascendente comum de  $m$  e  $n$

# RBFS – exemplo



Nó  $n$  acaba de ser expandido



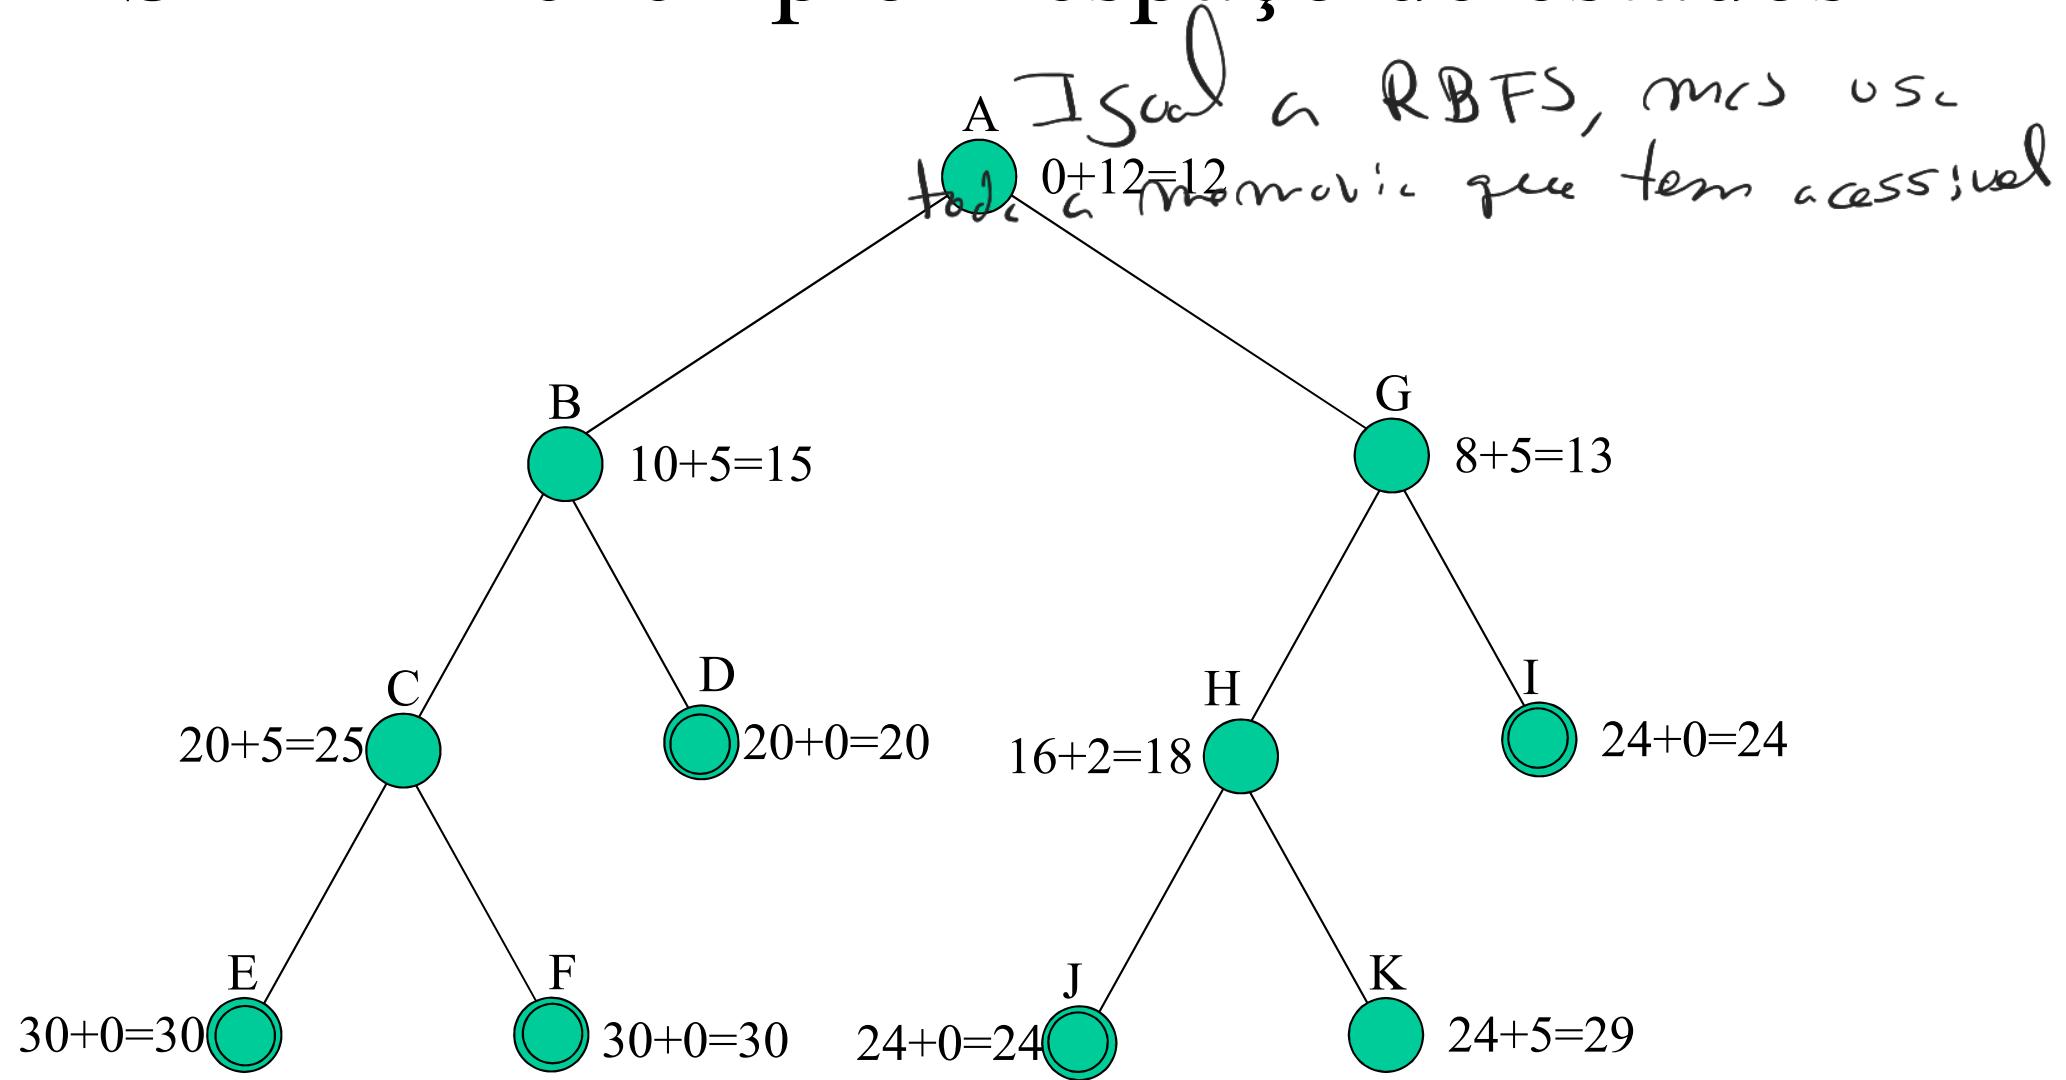
Custos foram actualizados

Algoritmo retrocedeu até ao nó  $k$ ;  
Expansão segue pelo nó  $m$

# SMA\*

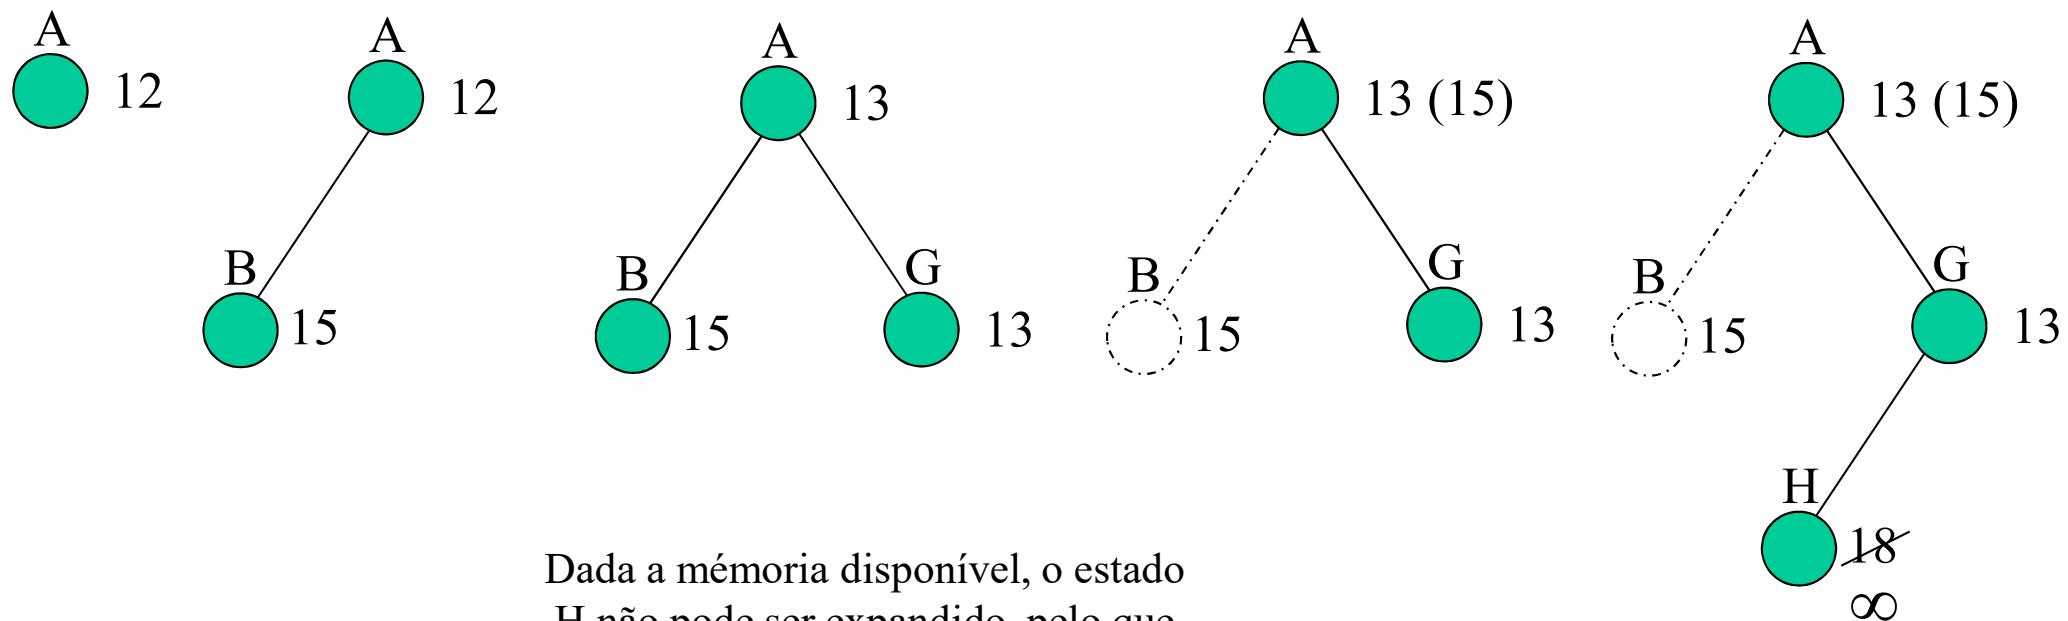
- A\* com memória limitada simplificado (*simplified memory-bounded A\**)
- Usa a memória disponível
  - Contraste com IDA\* e RBFS: estes foram desenhados para poupar memória, independentemente de ela existir de sobra ou não
- Quando a memória chega ao limite, esquece (remove) o nó  $n$  com maior custo  $f(n)=g(n)+h(n)$ , actualizando em cada um dos nós ascendentes o “custo do melhor nó esquecido”
- Só volta a gerar o nó  $n$  quando o custo do melhor nó esquecido registado no antecessor de  $n$  for inferior aos custos dos restantes nós
- Em cada iteração, é gerado apenas um nó sucessor
  - Existindo já um ou mais filhos de um nó, apenas se gera ainda outro se o custo do nó pai for menor do que qualquer dos custos dos filhos
  - Quando se gerou todos os filhos de um nó, o custo do nó pai é actualizado como no RBFS

# SMA\* - exemplo – espaço de estados

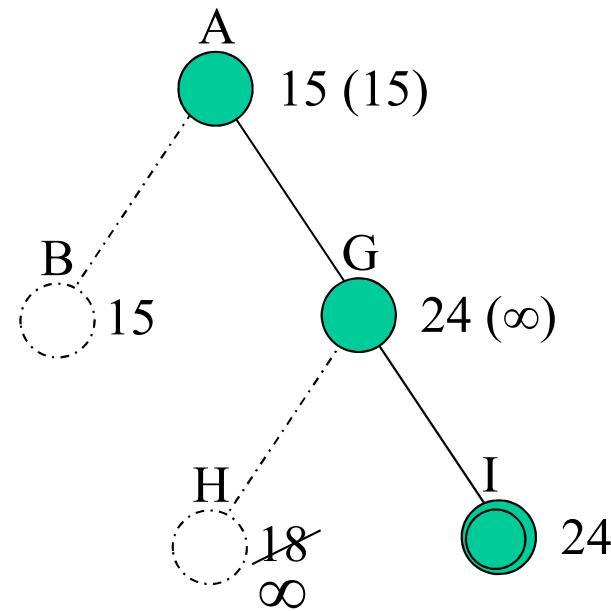
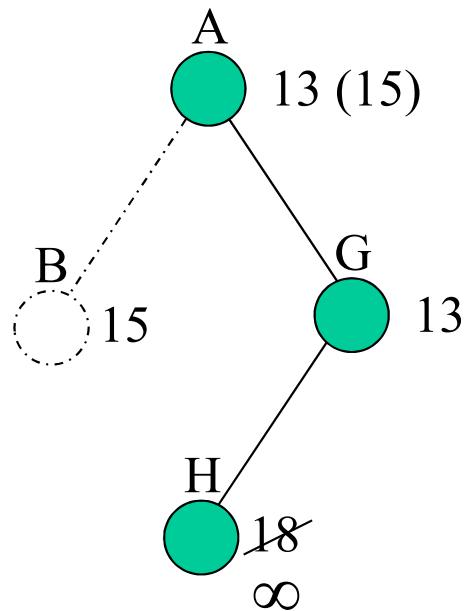


# SMA\* - exemplo

- Neste exemplo: memória = 3 nós
  - Melhores custos de nós esquecidos anotados entre parêntesis



# SMA\* - exemplo (cont.)



- Chegámos a uma solução (estado I)
- Se quisermos continuar: Das restantes folhas já exploradas, a que tinha o estado B era a melhor, por isso a pesquisa retrocede e continua expandindo esse folha

# Estratégias de pesquisa

- Pesquisa em árvore
- Pesquisa com propagação de restrições
- Pesquisa por melhorias sucessivas
- Planeamento

# Pesquisa para problemas de atribuição

- Nos problemas de atribuição pretende-se atribuir valores a um conjunto de variáveis, respeitando um conjunto de restrições.
- Exemplos:
  - Problema das 8 rainhas - distribuir 8 rainhas num tabuleiro de xadrez de forma a que haja uma e uma só rainha em cada linha e em cada coluna e não haja mais do que uma rainha em cada diagonal.
  - Invenção de palavras cruzadas – dada uma matriz de palavras cruzadas vazia, preencher os espaços brancos com letras, de forma a que a matriz possa ser usada como passatempo de palavras cruzadas.
- Técnicas de resolução de problemas de atribuição:
  - Método construtivo – usando técnicas de pesquisa em árvore
    - Em cada passo da pesquisa atribui-se um valor a uma variável
  - Método construtivo combinado com propagação de restrições
  - Resolução por melhorias sucessivas

# Pesquisa com propagação de restrições em problemas de atribuição

- Construir um grafo de restrições:
  - Em cada nó do grafo está uma variável
  - Um arco dirigido liga um nó  $i$  a um nó  $j$  se o valor da variável de  $j$  impõe restrições ao valor da variável de  $i$ .
  - Um arco  $(i,j)$  é *consistente* se, para cada valor da variável  $i$ , existe um valor da variável  $j$  que não viola as restrições.
- Tipicamente, usa-se uma estratégia de pesquisa em profundidade; em cada iteração da pesquisa, faz-se o seguinte:
  - 1) Seleciona-se arbitrariamente um dos valores possíveis para uma das variáveis (descartam-se os restantes)
  - 2) Restringem-se os conjuntos de valores possíveis das restantes variáveis por forma a que os arcos do grafo de restrições continuem consistentes.
- Nota: Neste caso, cada estado da pesquisa não representa uma situação ou configuração possível do mundo, como acontece no problema dos blocos; o estado é constituído pelos conjuntos de valores possíveis para as variáveis.

# Pesquisa com propagação de restrições em problemas de atribuição - algoritmo

1. Inicialização: o nó inicial da árvore de pesquisa é composto por todas as variáveis e todos os valores possíveis para cada uma delas
2. Se pelo menos uma variável tem um conjunto de valores vazio, falha e retrocede; se não puder retroceder, a pesquisa falha
3. Se todas as variáveis têm exactamente um valor possível, tem-se uma solução; retornar com sucesso
4. Expansão: Escolher arbitrariamente uma variável  $V_k$  e, de entre os valores possíveis, um dado valor  $X_{kl}$  – descartar os restantes valores possíveis dessa variável
5. Propagação de restrições: para cada arco  $(i,j)$  no grafo de restrições, remover os valores na variável  $V_i$  por forma a que o arco fique consistente
6. Caso tenha sido preciso remover valores na origem de algum arco, voltar a repetir o passo 5.
7. Voltar ao passo 2.

# Propagação de restrições - algoritmo

- Os passos 5 e 6 do algoritmo anterior executam a propagação de restrições
- Esta parte do processo é suportada por uma fila de arestas do grafo de restrições
  - Inicialmente, a fila contém as arestas que apontam para a variável cujo valor foi fixado

```
propagarRestricoes(grafoRestricoes,FilaArestas) retorna o grafo de restrições com
domínios possivelmente mais limitados
enquanto FilaArestas não vazia fazer {
    ( $X_j, X_i$ )  $\leftarrow$  remover cabeça de FilaArestas
    remover valores inconsistentes em  $X_j$ 
    se removeu valores, então
        para cada vizinho  $X_k$ , acrescentar ( $X_k, X_j$ ) a FilaArestas
}
```

# Tipos de restrições

- Restrições unárias – envolvem apenas uma variável
  - Podem ser satisfeitas através de pré-processamento do domínio de valores da variável – aproveitam-se apenas os valores que satisfazem a restrição
- Restrições binárias – envolvem duas variáveis
  - Uma restrição binária é directamente representada por uma aresta no grafo de restrições
- Restrições de ordem superior – envolvem três ou mais variáveis
  - Através da introdução de variáveis auxiliares, uma restrição de ordem superior pode ser transformada num conjunto de restrições binárias e/ou unárias

# Exemplo: quebra-cabeças critpoaritmético

$$\begin{array}{r} \text{T} \ \text{W} \ \text{O} \\ + \ \text{T} \ \text{W} \ \text{O} \\ \hline \text{F} \ \text{O} \ \text{U} \ \text{R} \end{array}$$

- Variáveis principais: F, O, R, T, U, W ( $\in \{ 0 .. 9 \}$ )
- Variáveis internas:  $X_1$  (transporte das unidades para as dezenas) e  $X_2$  (transporte das dezenas para as centenas) ( $\in \{ 0, 1 \}$ )
- Restrições:
  - Todas as variáveis são diferentes [ restrição sobre 6 variáveis ]
  - $2 \cdot O = R + 10 \cdot X_1$  [ restrição sobre 3 variáveis ]
  - $2 \cdot W + X_1 = U + 10 \cdot X_2$  [ restrição sobre 4 variáveis ]
  - $2 \cdot T + X_2 = O + 10 \cdot F$  [ restrição sobre 4 variáveis ]

# Restrições de ordem superior – conversão para restrições binárias

- No exemplo anterior, a restrição ternária  $2 \cdot O = R + 10 \cdot X_1$  pode ser transformada no seguinte conjunto de restrições:
  - Restrições binárias:
    - $O = \text{primeiro}(Aux)$
    - $R = \text{segundo}(Aux)$
    - $X_1 = \text{terceiro}(Aux)$
  - Restrição unária:
    - $2 \cdot \text{primeiro}(Aux) = \text{segundo}(Aux) + 10 \cdot \text{terceiro}(Aux)$
- $Aux$  é uma variável auxiliar cujo domínio é o produto cartesiano dos domínios de  $O$ ,  $R$  e  $X_1$ .
  - Ou seja:  $Aux \in \{0..9\} \times \{0..9\} \times \{0, 1\}$
  - A restrição unária sobre  $Aux$  pode ser satisfeita através de pré-processamento

# Estratégias de pesquisa

- Pesquisa em árvore
- Pesquisa com propagação de restrições
- Pesquisa por melhorias sucessivas
  - Montanhismo (*hill-climbing*)
  - Recozimento simulado (*Simulated annealing*)
  - Algoritmos genéticos
- Planeamento

# Pesquisa por melhorias sucessivas

- Também conhecida como **pesquisa local**
  - A partir de uma dada configuração inicial, fazem-se refinamentos sucessivos até obter uma configuração satisfatória
  - A solução inicial pode ser aleatória
- Técnicas mais comuns:
  - Reparação heurística
    - É a versão mais básica deste tipo de pesquisa: reparações à solução inicial vão sendo aplicadas de acordo com uma heurística local.
    - No caso de problemas de satisfação de restrições, a heurística pode ser:
      - Fazer a reparação que, naquele momento, mais contribui para reduzir os conflitos entre variáveis, dadas as restrições.
  - Montanhismo
  - Recozimento simulado
  - Algoritmos genéticos

# Pesquisa por melhorias sucessivas: montanhismo

- A pesquisa é vista como um problema de optimizar uma função
- O espaço de soluções é visto como uma paisagem de vales (zonas de soluções menos satisfatórias) e colinas (zonas de soluções melhores).
- Tem semelhanças com a pesquisa em profundidade e com a pesquisa gulosa, diferenciando-se pelo seguinte:
  - Escolhe-se sempre o sucessor com melhor valor da função de avaliação
  - Não há retrocesso (*backtracking*)
  - Quando o valor da função no nó actual é superior ao valor da função em qualquer dos seus sucessores, a pesquisa pára. ( atingiu-se um máximo local )
- Problemas:
  - Máximos locais, planaltos, ravinas

# Montanhismo: variantes

- **Montanhismo estocástico** – escolhe aleatoriamente entre os sucessores que melhoraram a função de avaliação
- **Montanhismo de primeira escolha** – escolhe sucessores aleatoriamente até encontrar um com melhor função de avaliação que o estado actual
- **Montanhismo com reinício aleatório** – executar o montanhismo várias vezes, partindo de estados iniciais aleatórios, e escolhe a melhor solução
- **Recozimento simulado** (página seguinte)

# Pesquisa por melhorias sucessivas: recozimento simulado

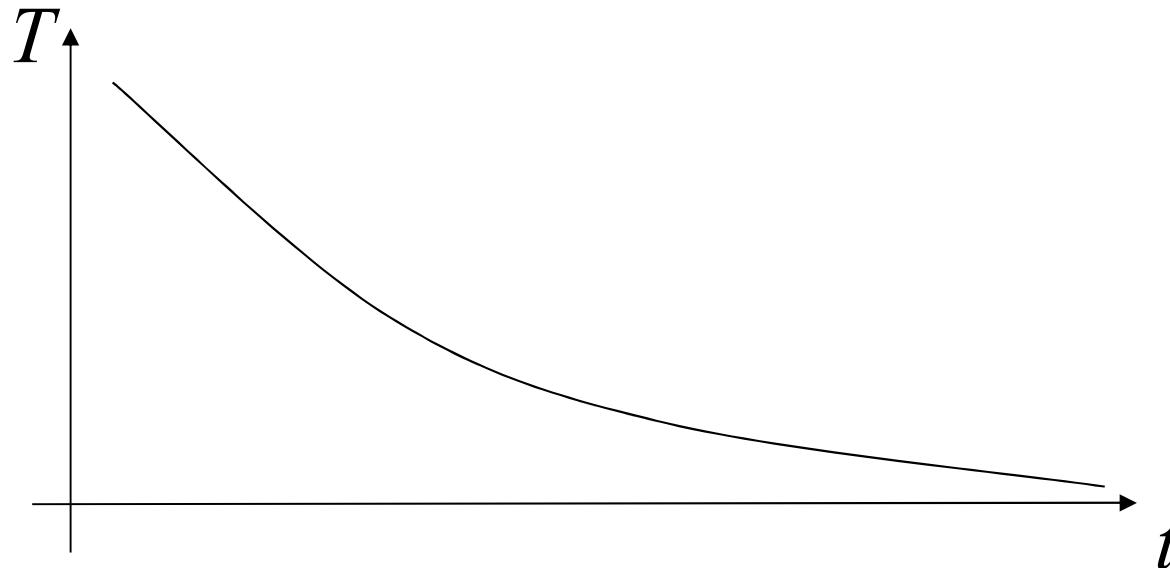
- *Recozimento simulado (Simulated Annealing)* é uma variante da pesquisa por montanhismo na qual podem ser aceites refinamentos que, localmente, piorem a solução.
  - O nome inspira-se no processo industrial chamado *recozimento*.
    - Recozer = “deixar esfriar lentamente (um produto de cerâmica ou de vidro) num forno especial, logo após o seu fabrico”.
- Começou a ser usado circa 1980 para resolver problemas de configuração de circuitos VLSI
- Particularidades:
  - O sucessor é seleccionado aleatoriamente
  - Quando o valor da função no nó actual é superior ao valor da função no sucessor, o sucessor é aceite com uma probabilidade que diminui exponencialmente em função da perda na função de avaliação.
  - Pesquisa termina quando um indicador designado “temperatura” chega a zero.

# Recozimento simulado: algoritmo

```
recozimento_simulado(Problema,Regime_termico,Aval)
(* A função Regime_termico dá a temperatura em função do tempo. *)
Nó  $\leftarrow$  fazer_nó(estado inicial do Problema)
repetir para  $t=0 \dots \infty$ : {
     $T \leftarrow \text{Regime\_termico}(t)$ 
    se  $T=0$ , retornar a solução de Nó
     $\text{Prox} \leftarrow$  um sucessor de Nó gerado aleatoriamente
     $\text{Ganho} \leftarrow \text{Aval}(\text{Prox}) - \text{Aval}(\text{Nó})$ 
    se  $\text{Ganho} > 0$ ,  $\text{Nó} \leftarrow \text{Prox}$ 
    senão, com probabilidade  $\exp(\text{Ganho}/T)$ , fazer:  $\text{Nó} \leftarrow \text{Prox}$ 
}
```

- Nota: Se a temperatura  $T$  diminuir de forma suficientemente lenta, o recozimento simulado encontra um máximo global. (solução óptima)

# Recozimento simulado: regime térmico

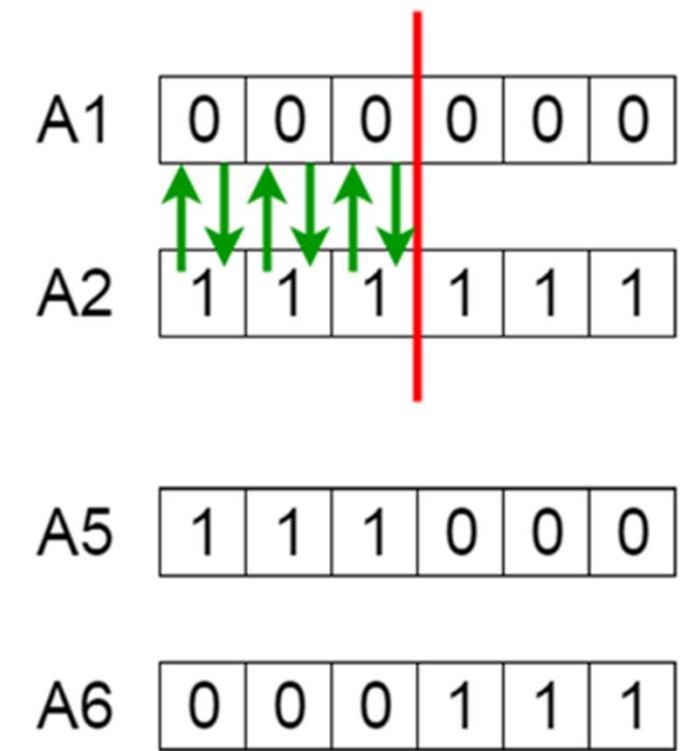
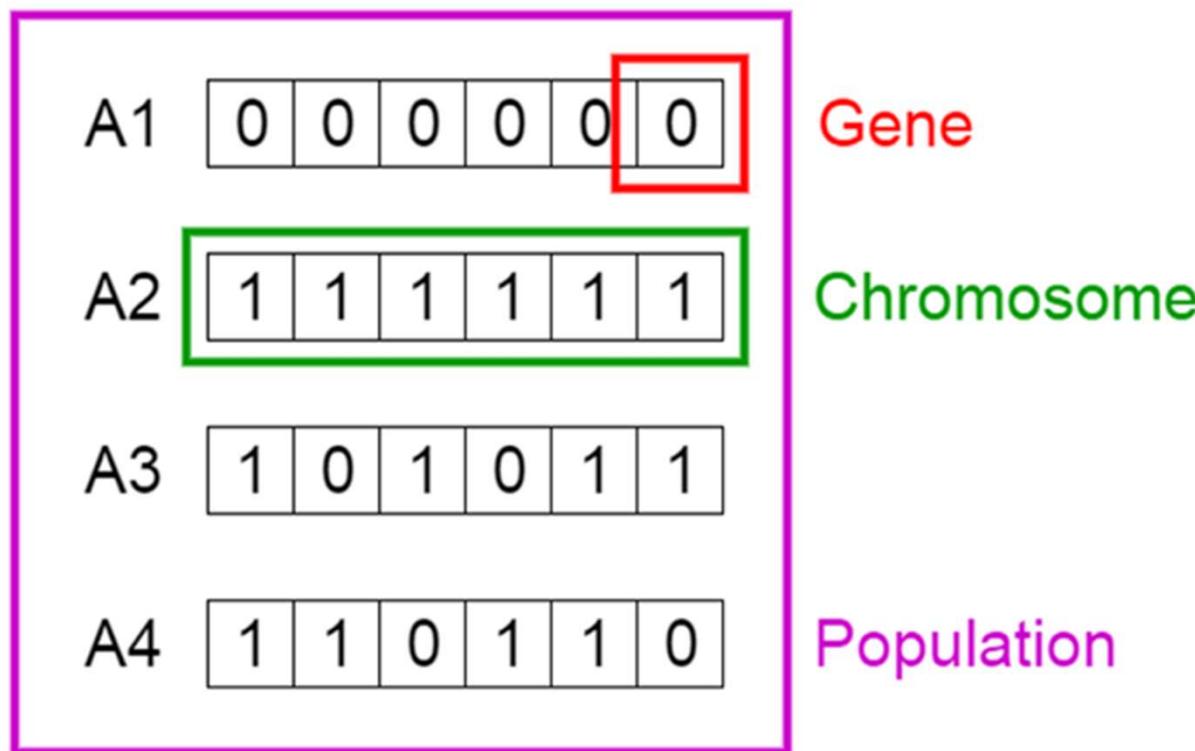


- $t \rightarrow \infty$
- $T \rightarrow 0$
- $Ganho/T \rightarrow -\infty$  ( dado que o Ganho é negativo)
- Probabilidade:  $\exp(Ganho/T) \rightarrow 0$
- Ou seja: À medida que o tempo passa, a pesquisa arrisca cada vez menos quanto a aceitar alterações com ganho negativo

# Pesquisa local alargada (*local beam search*)

- **Pesquisa local alargada** – semelhante ao montanhismo mas, em cada iteração, são mantidos  $k$  estados, e os melhores  $k$  sucessores são passados para a iteração seguinte [NOTA: podem ser seleccionados vários sucessores de alguns dos  $k$  estados e nenhum sucessor de alguns dos outros ]
- **Pesquisa alargada estocástica** – semelhante à pesquisa local alargada, mas os  $k$  sucessores são seleccionados aleatoriamente
- **Algoritmos genéticos** – variante da pesquisa alargada estocástica em que os sucessores são gerados por combinação de dois estados, e não apenas por modificação de um único estado

# Algoritmos Genéticos



# Estratégias de pesquisa

- Pesquisa em árvore
- Pesquisa com propagação de restrições
- Pesquisa por melhorias sucessivas
- Planeamento

# Planeamento: STRIPS, o primeiro planeador

$\text{STRIPS}(EI, Objectivos)$  %  $EI$  é argumento de entrada/saída

$Plano \leftarrow []$

**repetir** {

$C \leftarrow$  uma condição em  $Objectivos$  não satisfeita em  $EI$

$OP \leftarrow$  um operador que pode ter  $C$  como efeito positivo

$A \leftarrow$  acção, dada por uma completa instanciação de  $OP$

$PC \leftarrow$  pré-condições de  $A$

$SubPlano \leftarrow \text{STRIPS}(EI, PC)$

$Plano \leftarrow \text{concatenar}(Plano, \text{concatenar}(SubPlano, [A]))$

$EI \leftarrow$  novo estado, resultante da aplicação de  $A$  em  $EI$

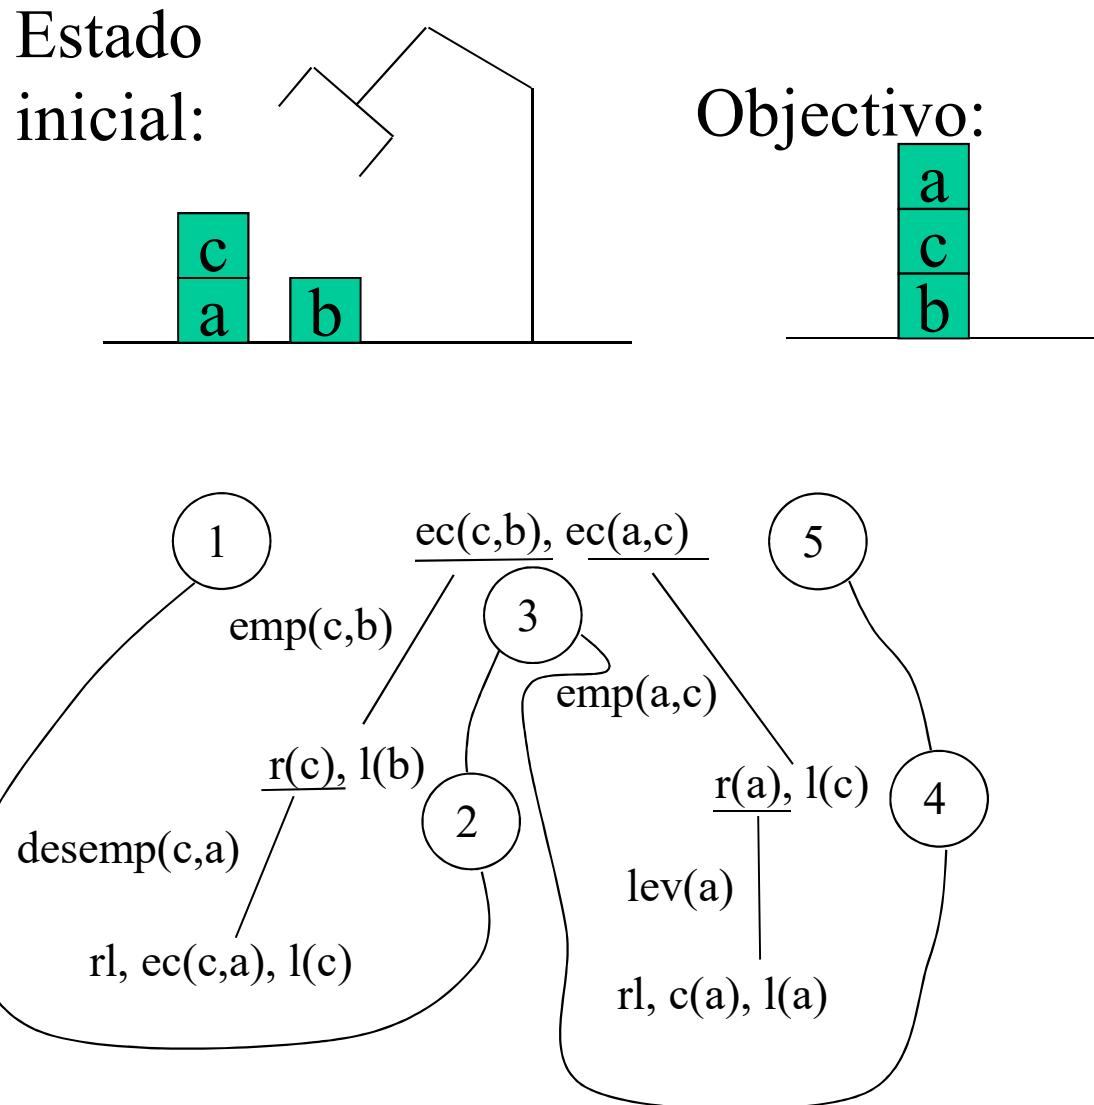
**se**  $Objectivos$  satisfeitos em  $EI$ ,

**retornar**  $Plano$

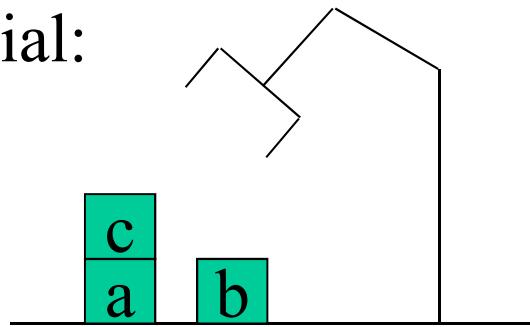
}

# STRIPS: exemplo

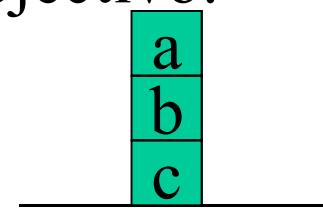
- Abreviaturas de condições:
  - Bloco em cima de bloco:  $ec(A,B)$
  - Bloco no chão:  $c(B)$
  - Bloco no robô:  $r(X)$
  - Robô livre:  $rl$
  - Bloco livre:  $l(X)$
- Abreviaturas de operadores:
  - Empilhar:  $emp(A,B)$
  - Desempilhar:  $desemp(A,B)$
  - Levantar:  $lev(X)$
  - Poisar:  $p(X)$
- Plano:
  - $desemp(c,a), emp(c,b), lev(a), emp(a,c)$
- Sucessão de estados:
  - 1:  $ec(c,a), c(a), l(c), c(b), l(b), rl$
  - 2:  $r(c), l(a), c(a), c(b), l(b)$
  - 3:  $ec(c,b), l(c), l(a), c(b), c(a), rl$
  - 4:  $r(a), ec(c,b), c(b), l(c)$
  - 5:  $ec(a,c), ec(c,b), c(b), rl$



Estado  
inicial:



Objectivo:



- Dependendo da ordem pela qual o STRIPS trata os objectivos, os seguintes planos poderão ser gerados:
  - [ desempilhar(c,a), poisar(c), levantar(a), empilhar(a,b), desempilhar(a,b), poisar(a), levantar(b), empilhar(b,c), levantar(a), empilhar(a,b) ]
  - [ levantar(b), empilhar(b,c), desempilhar(b,c), poisar(b), desempilhar(c,a), poisar(c), levantar(a), empilhar(a,b), desempilhar(a,b), poisar(a), levantar(b), empilhar(b,c), levantar(a), empilhar(a,b) ]
- Nenhum deles é óptimo
  - Na verdade, o algoritmo STRIPS não consegue gerar um plano óptimo para este problema

# Planeamento no espaço de soluções

- Em todas as aproximações ao planeamento anteriormente apresentadas, cada nó da pesquisa corresponde a um estado do mundo → *planeamento no espaço de estados*.
- Uma técnica alternativa consiste em partir de um plano vazio e adicionar sucessivamente operações e restrições de sequenciamento → *planeamento no espaço de soluções*.
- Neste caso, cada nó da pesquisa corresponde a uma solução parcial para o problema.
- Operações de transformação da solução:
  - Adicionar um operador
  - Re-ordenar operadores
  - Instanciar um operador

# Planeamento Hierárquico – a técnica ABSTRIPS

- O planeamento é realizado numa hierarquia de níveis de abstração.
- Um valor de “criticalidade” é atribuído a cada uma das condições que podem aparecer na descrição do estado do mundo.
- Algoritmo:
  1.  $CM \leftarrow$  valor inicial para o nível de criticalidade mínima.
  2. Gerar um um plano que satisfaça todas as condições com nível de criticalidade  $\geq CM$ .
  3.  $CM \leftarrow CM-1$
  4. Usando o plano anterior como guia, gerar um plano que satisfaça todas as condições com criticalidade  $\geq CM$ .
  5. **se** todas as condições estão satisfeitas, **retornar** a solução.
  6. **voltar** ao passo 3.

# ABSTRIPS: exemplo

## – planeamento inicial para CM=2

- Dois níveis de criticalidade:

- $ec(A,B) - 2$
- $c(B) - 1$
- $r(X) - 2$
- $rl - 1$
- $l(X) - 1$

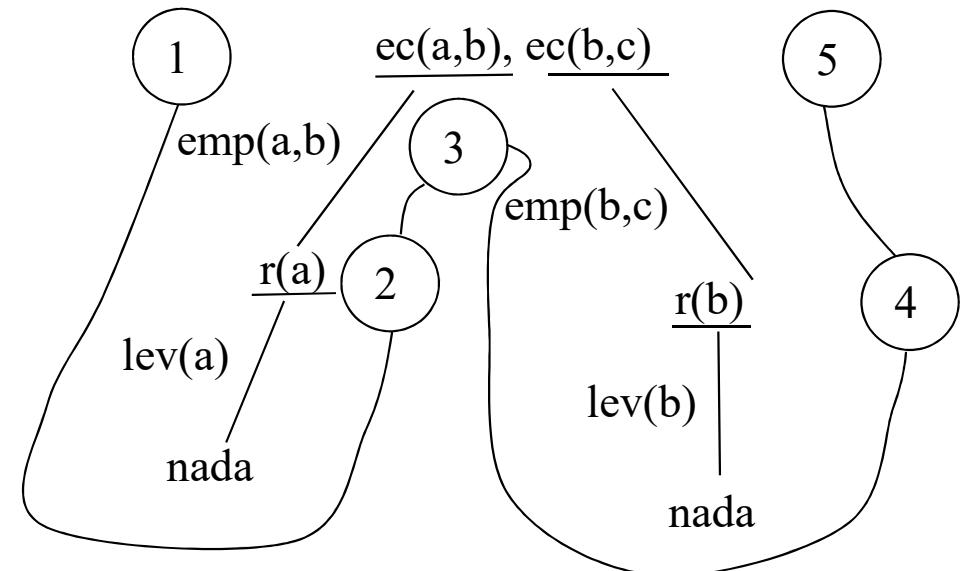
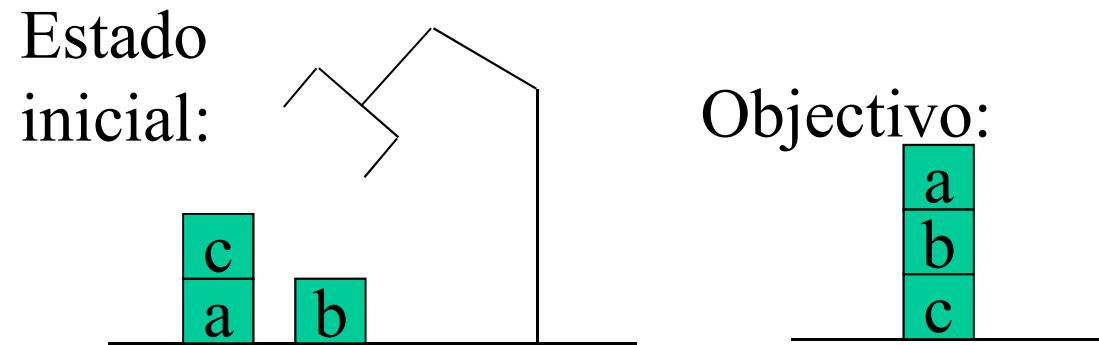
- Plano inicial:

- $lev(a), emp(a,b), lev(b), emp(b,c)$

- Sucessão de estados:

- 1:  $ec(c,a)$
- 2:  $ec(c,a), r(a)$
- 3:  $ec(c,a), ec(a,b)$
- 4:  $ec(c,a), ec(a,b), r(b)$
- 5:  $ec(c,a), ec(a,b), ec(b,c)$

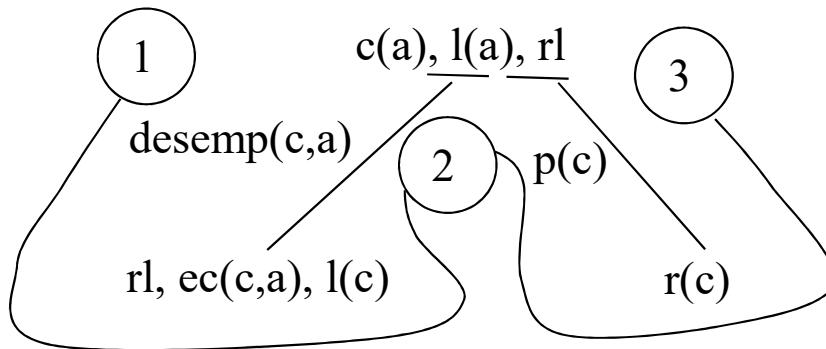
- Os estados não são consistentes!



# ABSTRIPS: exemplo

## – Planeamento para CM=1

- As precondições de criticalidade 1 da primeira acção,  $\text{lev}(a)$ , não estão reunidas, pelo que é preciso determinar um plano para as atingir



- Plano:
  - $\text{desemp}(c,a), p(c)$
- Sucessão de estados:
  - 1:  $\text{ec}(c,a), c(a), l(c), c(b), l(b), rl$
  - 2:  $r(c), l(a), c(a), c(b), l(b)$
  - 3:  $rl, c(c), l(c), l(a), c(a), c(b), l(b)$

# Operadores com fórmulas não atómicas e condicionais

- Literal – uma formula atómica (literal positivo) ou negação de uma fórmula atómica (literal negativo)
- Fórmula de aplicabilidade do operador pode ser:
  - Fórmula atómica
  - Negação de uma fórmula
  - Conjunção de fórmulas
  - Disjunção de fórmulas
  - Fórmula quantificada existencialmente
  - Fórmula quantificada universalmente
- Fórmula de efeitos do operador pode ser:
  - Literal
  - Conjunção de literais
  - Efeitos condicionais: when <fórmula de aplicabilidade> <fórmula de efeitos>
  - Fórmula de efeitos quantificada universalmente
  - Conjunção de fórmulas de efeitos
- Ver “PDDL - Planning Domain Definition Language”.

# PDDL - exemplo

```
(:action stop
:parameters (?f - floor)
:precondition (lift-at ?f)
:effect (and
          (forall (?p - passenger)
                 (when (and (boarded ?p) (destin ?p ?f) )
                           (and (not (boarded ?p)) (served ?p))))
          (forall (?p - passenger)
                 (when (and (origin ?p ?f) (not (served ?p)))
                           (boarded ?p))))))
```

# PDDL - exemplo

```
(:action drive-truck
:parameters (?truck - truck
            ?loc-from ?loc-to - location
            ?city - city)
:precondition (and (at ?truck ?loc-from) (in-city ?loc-from ?city)
                    (in-city ?loc-to ?city))
:effect (and (at ?truck ?loc-to)
              (not (at ?truck ?loc-from))
              (forall (?x - obj)
                     (when (and (in ?x ?truck))
                           (and (not (at ?x ?loc-from))
                                (at ?x ?loc-to)))))))
```

# Aprendizagem

- Aprendizagem é qualquer mudança num sistema que lhe permite ter um melhor desempenho ao executar pela segunda vez uma tarefa [Simon, 1983]
- Aprendizagem é um processo orientado por objectivos através do qual se melhora o conhecimento usando a experiência e o próprio conhecimento [Michalski, 1994]

**Aprendizagem = Inferência + Memorização**

# Aprendizagem: tipos de inferência

- Inferência **dedutiva** – preserva a verdade
  - Especialização dedutiva – restringir o conjunto de referência  
Se  $\{ \forall x \ x \in A \Rightarrow p(x), B \subset A \} \vdash \forall x \ x \in B \Rightarrow p(x)$
  - Generalização dedutiva – alargar o conjunto de referência
  - Dedução simples
  - Abstracção
- Inferência **indutiva** – não preserva a verdade, mas é essencial para a aprendizagem
  - Generalização indutiva – alarga o conjunto de referência; é o inverso da especialização dedutiva  
Se  $\{ \forall x \ x \in B \Rightarrow p(x), B \subset A \} \vdash \forall x \ x \in A \Rightarrow p(x)$
  - Especialização indutiva – o inverso da generalização dedutiva
  - Abdução – gera uma premissa a partir da qual se poderá deduzir uma dada observação
  - Concretização – Adiciona detalhes sobre o conjunto de referência.

# Aprendizagem: níveis de supervisão

- Supervisão
  - Aprendizagem **supervisionada** – cada exemplo contém uma instância do conceito a aprender, que está devidamente identificado
    - Redes neurais, árvores de decisão, etc.
  - Aprendizagem **semi-supervisionada** – apenas uma (pequena) pequena parte dos exemplos contém informação do conceito a aprender
  - Aprendizagem **por reforço** – o agente aprende o seu comportamento tendo em conta as recompensas (positivas ou negativas) que recebe pelas suas ações
  - Aprendizagem **não supervisionada** – neste caso é o próprio processo de aprendizagem que descobre um novo conceito
    - Algoritmos de agrupamento (*clustering*)

# Aprendizagem: os dados

- Quantidade de exemplos
  - Muitos exemplos
    - Redes neurais, árvores de decisão
  - Um ou poucos exemplos
    - Aprendizagem baseada em explicações (EBL): usa generalização dedutiva
    - Aprendizagem analógica / baseada em casos (CBR)
- Utilização de símbolos e números
  - Aprendizagem simbólica – o conhecimento aprendido está representado numa forma equivalente a lógica proposicional ou de primeira ordem
    - Regras, árvores de decisão, EBL, CBR
  - Aprendizagem conectionista / sub-simbólica
    - Redes neurais, redes de Bayes, árvores de regressão

# Aprendizagem baseada em colecções de exemplos: motivação

- Como aprender a prever qual vai ser a evolução do lucro numa empresa de produtos informáticos?

Idade	Competição	Tipo	Lucro
Velha	Não	Software	Desce
Intermédia	Sim	Software	Desce
Intermédia	Não	Hardware	Sobe
Velha	Não	Hardware	Desce
Nova	Não	Hardware	Sobe
Nova	Não	Software	Sobe
Intermédia	Não	Software	Sobe
Nova	Sim	Software	Sobe
Intermédia	Sim	Hardware	Desce
Velha	Sim	Software	Desce

# Aprendizagem com colecções de exemplos: protocolo básico (I)

- Um conjunto de **atributos** ou características
  - $A = \{ A_1, \dots, A_n \}$
- Cada atributo pode assumir valores dentro de um conjunto finito de valores simbólicos.
  - $A_i = \{ A_{il}, \dots, A_{ik} \}$
- Os objectos do domínio estão organizados em **classes**
  - $C = \{ C_1, \dots, C_m \}$
- O problema é aprender a **reconhecer a classe** (=classificar) do objecto dada uma descrição desse objecto em termos dos atributos em A

# Aprendizagem com colecções de exemplos: protocolo básico (I)

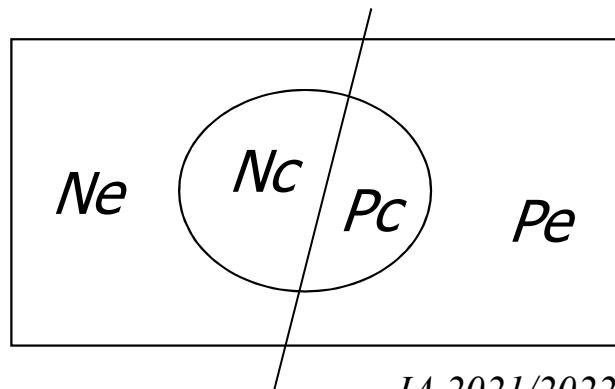
- O processo de aprendizagem baseia-se numa colecção de exemplos de treino,  $S$ .
- É gerada uma função  $f: A \rightarrow C$  tal que:
  - $\forall x x \in S f(x) = classe(x)$
- Por generalização indutiva chega-se a:
  - $\forall x f(x) = classe(x)$
- Isto chama-se **Aprendizagem por Indução**

# Aprendizagem de regras: pesquisa em profundidade (gulosa)

- Para cada classe  $C$ , fazer o seguinte
  1.  $Regras \leftarrow \emptyset$
  2.  $Pos \leftarrow$  conjunto dos exemplos da classe  $C$
  3.  $Neg \leftarrow$  restantes exemplos
  4.  $Antecedente \leftarrow Verdade$
  5. Selecionar um novo  $Teste$
  6.  $Antecedente \leftarrow Antecedente \wedge Teste$
  7. Se  $Antecedente$  ainda cobre alguns exemplos em  $Neg$ , voltar a 5.
  8.  $Regras \leftarrow Regras \cup \{ Antecedente \Rightarrow C \}$
  9.  $Pos \leftarrow Pos - \{ \text{exemplos cobertos pelo } Antecedente \}$
  10. Se  $Pos \neq \emptyset$ , voltar a 4.

# Aprendizagem de regras: critérios

- Estão nesta categoria algoritmos bem conhecidos como o AQ e o CN2
- Critérios de comparação e selecção de regras para refinamento
  - $Pc/Tc$  – sendo  $Pc$  o número de exemplos positivos cobertos e  $Tc = Pc+Nc$  o número total de exemplos cobertos
  - $Pc+Ne$  – sendo  $Pc$  o número de exemplos positivos cobertos e  $Ne$  o número de exemplos negativos excluídos



# Aprendizagem de árvores de decisão: algoritmo

- A árvore de decisão é gerada através de um processo recursivo descendente (*TDIDT – Top-Down Induction of Decision Trees*)

TDIDT(*Exemplos*)

se todos os *Exemplos* pertencem a uma classe  $C$ ,

então  $\text{Arvore.classe} = C$ ;

senão:

$A \leftarrow$  atributo de teste para *Exemplos*

$\text{Arvore.teste} \leftarrow A$

para cada valor  $a_i$  de  $A$ :

$E_i \leftarrow$  subjconjunto de *Exemplos* em que  $A=a_i$

$\text{Arvore.subarv}_i \leftarrow \text{TDIDT}(E_i)$

retornar  $\text{Arvore}$

# Árvores de decisão: selecção do atributo de teste (I)

- Podemos ver o domínio dos exemplos como uma fonte de mensagens, cada uma delas representando uma das classes possíveis
- Baseado na **Teoria da Informação**
  - Entropia *apriori*:  $H(C) = -\sum p(C_i) \times \log_2(p(C_i))$
  - Entropia *aposteriori*, dado o valor de um atributo:  
$$H(C|a_{j,k}) = -\sum_i p(C_i|a_{j,k}) \times \log_2(p(C_i|a_{j,k}))$$
  - Entropia global *aposteriori*:  
$$H(C|A_j) = \sum_k p(a_{j,k}) \times H(C|a_{j,k})$$

# Árvores de decisão: selecção do atributo de teste (III)

- **Ganho de informação**
  - Ou seja, redução da entropia

$$I(C;A_j) = H(C) - H(C|A_j)$$

- As probabilidades podem ser estimadas com base nos exemplos disponíveis
- Nota: Este método funciona mal quando os atributos têm muitos valores possíveis

# Árvores de decisão: selecção do atributo de teste (II)

- **Razão do ganho**
  - $H(A_j) = -\sum p(a_{j,k}) \times \log_2(p(a_{j,k}))$
  - $R(C;A_j) = I(C;A_j) / H(A_j)$
  - Resolve o problema dos atributos com muitos valores.
  - Quando  $H(A_j)$  se aproxima de zero, a razão do ganho fica instável; por isso, são excluídos à partida os atributos cujo ganho de informação seja inferior à média

# Árvores de decisão: selecção do atributo de teste (III)

- **Critério GINI**

- Impureza *apriori*

- $\bullet \quad G = \sum_{m \neq n} p(C_m) \times p(C_n)$

- Impureza *aposteriori*:

- $\bullet \quad G(A_j) = \sum p(a_{j,k}) \times \sum_{m \neq n} p(C_m | a_{j,k}) \times p(C_n | a_{j,k})$

# Alguns problemas (I)

- Tratamento do **ruído** – por vezes, os exemplos de treino contém ruido, ou seja, particularidades não representativas do domínio que podem levar o algoritmo de aprendizagem a fazer uma generalização incorrecta.
- **Atributos numéricos** – como usá-los nas regras ou nas árvores de decisão?
- Atributos com valores não especificados nos exemplos

# Alguns problemas (II)

- Levar em conta o **custo de cálculo** de cada atributo
- **Aprendizagem incremental**
- Aprendizagem por indução em **lógica de primeira ordem**
  - FOIL

# Árvores de decisão: tratamento do ruído

- Parar a expansão da árvore quando o número de exemplos disponíveis é inferior a um dado limiar
- Ter um estimativa do erro, e parar a expansão quando a estimativa do erro começa a subir
- Ter um estimativa do erro, e parar a expansão quando essa estimativa sobe para além de um dado limiar.
- Expandir completamente a árvore e no fim podá-la.

# Avaliação de algoritmos de aprendizagem supervisionada

- **Complexidade computacional**
  - Tanto na aprendizagem como na utilização
- **Legibilidade** – a representação do conhecimento aprendido deve ser tão legível quanto possível
  - Especialmente relevante em sistemas de apoio à decisão
- **Precisão** – o conhecimento aprendido deve ser tão preciso quanto possível
  - No caso de problemas de classificação, a precisão é avaliada experimentalmente como a percentagem de erros de classificação num conjunto de exemplos de teste (não usados na aprendizagem).

# Avaliação experimental da precisão em aprendizagem supervisionada (I)

- Partição dos exemplos disponíveis em dois subconjuntos:
  - Subconjunto de treino – exemplos usados para a aprendizagem (p. ex. 2/3 de todos os exemplos)
  - Subconjunto de teste – exemplos usados na avaliação experimental da precisão (p. ex. 1/3)

# Avaliação experimental da precisão em aprendizagem supervisionada (II)

- **Validação-cruzada- $k$** 
  - Divide-se o conjunto de exemplos disponíveis em  $k$  subconjuntos
  - Para cada subconjunto  $S_i$ , treinar usando todos os outros e testar em  $S_i$
  - A precisão é dada pela percentagem global de erros (após todas as iterações treino-teste)
- **Um-de-fora**
  - Equivale à validação-cruzada- $k$ , para o caso em que  $k$  é o número total de exemplos disponíveis

